https://hjfy.top/arxiv/2312.11460

混合内部模型：通过模拟机器人响应学习敏捷足式运动

Junfeng Long[1]*, Zirui Wang[1,2]*, Quanyi Li[1], Jiawei Gao[1,3], Liu Cao[1,3], Jiangmiao Pang[1]✉
[1]OpenRobotLab, Shanghai AI Laboratory, [2]Zhejiang University, [3]Tsinghua University

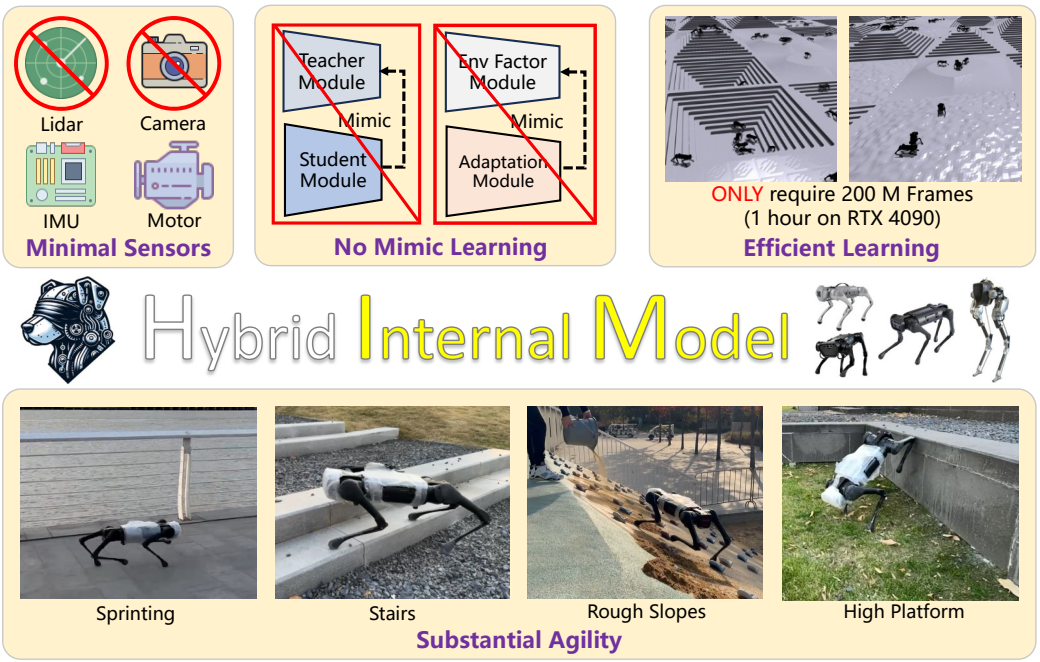


图 1: 我们的运动策略可使机器人在任何地形上行走，并抵御各种干扰。关键洞察在于交替估计环境动力学与机器人的响应。

Abstract

稳健的运动控制依赖于精确的状态估计。然而，大多数腿式机器人的传感器只能提供部分且带有噪声的观测数据，使得状态估计尤其具有挑战性，尤其是在地形摩擦系数和高程图等外部状态方面。受经典内部模型控制原理的启发，我们将这些外部状态视为干扰，并引入混合内部模型（HIM）来根据机器人的响应进行估计。该响应我们称为混合内部嵌入，它包含了机器人显式的速度信息和隐式的稳定性表示，分别对应于运动任务的两个主要目标：显式地跟踪速度以及隐式地保持稳定性。我们采用对比学习优化该嵌入，使其接近机器人的后续状态，其中响应自然被包含在内。HIM 具有多个显著优势：仅需机器人本体感知信息，即关节编码器和惯性测量单元（IMU）提供的观测；创新性地保持了仿真参考与现实之间的一致性观测，避免了模仿学习中的信息丢失；利用批量级别的信息，对噪声更具鲁棒性，并保持更优的样本效率；仅需在 RTX 4090 上训练 1 小时，即可使四足机器人在任何扰动下穿越任意地形。大量真实世界实验表明其具备出色的敏捷性，即

*Equal Contributions. ✉ Corresponding Author. Project page at this URL.

使在训练过程中从未遇到的高难度任务和场景中也表现优异，展现出卓越的开放世界泛化能力。

1 引言

近年来，基于学习的四足机器人运动控制方法取得了显著成果 (Hwangbo et al., 2019; Peng et al., 2020; Yang et al., 2020; Xie et al., 2021; Imai et al., 2022; Yu et al., 2021; Yang et al., 2022; Margolis et al., 2022; Rudin et al., 2022; Agrawal et al., 2022; Yang et al., 2023b; Margolis & Agrawal, 2023; Yang et al., 2023b)，在野外环境 (Lee et al., 2020; Miki et al., 2022b) 或低成本硬件平台 (Kumar et al., 2021; Wu et al., 2022) 中展现出超越传统控制方法的敏捷性。得益于大量且多样的仿真数据，这些算法使四足机器人能够直接在真实环境中工作，不仅能够完成简单动作，还能执行如操作 (Fu et al., 2022; Ji et al., 2023; Cheng et al., 2023) 和跑酷 (Yang et al., 2023a; Zhuang et al., 2023; Caluwaerts et al., 2023) 等复杂技能。

为了实现显著的敏捷性，必须为四足机器人提供准确且完整的外部状态 (Hartley et al., 2018)。然而，大多数机载传感器仅能提供关于本体感知和周围环境的部分且带有噪声的观测，这阻碍了鲁棒机器人系统的开发。作为解决方案，近期基于学习的方法通常采用两阶段训练策略。首先，在仿真环境中训练一个“理想策略”（oracle policy），该策略可访问如地形摩擦系数和高程图等外部状态，并应用领域随机化以增强在各种地形条件下的泛化能力。随后，通过模仿学习将该策略中的知识迁移至另一个策略，此时外部状态被禁用 (Miki et al., 2022a) 或从其他信息中推断得出 (Kumar et al., 2021)。尽管此类方法取得了令人期待的结果，但其性能仍受以下两点限制：(1) 尽管领域随机化有助于仿真到现实（sim2real）的迁移，但引入的噪声限制了模型的进一步优化，尤其是在直接学习回归绝对环境参数时更为明显；(2) 这种两阶段训练范式使训练过程复杂化，并不可避免地在模仿学习阶段造成信息丢失，无论该模仿是通过模仿学习 (Miki et al., 2022a) 实现，还是通过适应方法 (Kumar et al., 2021) 实现。此外，某些解决方案还需要额外的外感受传感器，例如摄像头 (Agarwal et al., 2023) 或激光雷达 Rudin et al. (2022)，而这些传感器的配置在不同机器人平台上各不相同。因此，在通用平台上的策略训练与部署极具挑战性。

在本工作中，我们提出一种方法，该方法中策略网络在整个训练过程中无需访问任何外部状态。更具体地说，我们的方法称为混合内部模型（HIM），将所有外部状态（如高程图和地面摩擦）视为系统扰动。受经典内部模型控制（IMC） (Rivera et al., 1986) 的启发，该方法通过模拟系统响应来估计扰动，我们尝试根据机器人的模拟响应来估计这些系统扰动。以速度和稳定性为特征，该响应被称为混合内部嵌入，其从一系列历史观测中提取。由于该响应自然嵌入于机器人的后续状态之中，因此通过对比学习对混合内部嵌入进行优化，使其与未来状态更加接近。我们使用近端策略优化（PPO）来训练策略网络，并将其与部分观测和混合内部嵌入一同输入。在每次 PPO 迭代中，通过混合内部最优化（HIO）对嵌入进行优化，使策略能够隐式地推断并区分来自外部环境的扰动。结果表明，该策略可部署于多种真实场景中。此外，对比学习使策略对噪声更具鲁棒性，批量级信息进一步提升了样本效率。另一方面，我们的方法轻量化且适用于所有足式机器人平台，只要它们能提供来自 IMU 和关节传感器的基本本体感知信息即可。

我们在 Isaac Gym (Makoviychuk et al., 2021) 中训练我们的方法，并将其部署在 Unitree Aliengo、A1 和 Go1 机器人上。我们在仿真和真实世界两种场景下，通过精心设计的基准测试和评估指标对方法性能进行了评估与消融实验。实验表明，HIM 可以仅使用最少的传感器，即关节编码器和 IMU，便使机器人在任意地形上穿越并抵抗任何扰动。该策略仅需 200 百万样本即可收敛，且在 RTX 4090 GPU 上部署仅耗时 1 小时。我们还观察到，该方

法在高难度任务（如长距离台阶）以及训练过程中从未出现过的场景（如组合地形和可变形斜坡）中表现优异，展现出在开放世界中的卓越泛化能力。我们希望这一简单而高效的方法能为社区带来新的启示。

2 相关工作

历史上，腿式机器人的算法主要植根于传统的基于控制的方法，这主要归功于其固有的稳定性和鲁棒性。大多数这类工作使用基于模型的控制器来定义控制器 (Bosworth et al., 2015; Xiang et al., 2010; Yin et al., 2007; Sreenath et al., 2011; Hutter et al., 2016; Bledt et al., 2018)。然而，这些控制器难以适应物理特性变化极大的情况，如冰面、崎岖地形或可变形材料。与此同时，借助各种物理仿真器 (Todorov et al., 2012; Panerati et al., 2021)，尤其是支持大规模并行仿真的 Isaac Gym (Makoviychuk et al., 2021)，腿式运动的深度强化学习（DRL）展示了其巨大的潜力。这促使了使用通过 RL 训练的学成控制器，这些控制器能够适应仿真器中动态变化 (Tan et al., 2018; Lee et al., 2020; Kumar et al., 2021; Fu et al., 2021; Rudin et al., 2022)，并可部署到现实世界的机器人上。

尽管 sim2real 框架表现出吸引人的特性，但在两个方面仍存在仿真与真实机器人之间的差距。首先，大多数真实机器人无法获取外部状态，例如高程图、接触力等。其次，现实世界的观测总是存在噪声。为解决这一问题，先前的方法采用模仿学习来弥补环境信息的缺失。模仿学习方法可分为两大框架：适应框架和师生框架。使用适应框架的方法包括Kumar et al. (2021)、Agrawal et al. (2022)、Margolis & Agrawal (2023)，而使用师生框架的方法包括Lee et al. (2020)、Chen et al. (2019)、Margolis et al. (2022)、Wu et al. (2022)。尽管这些方法在一定程度上缓解了 sim-to-real 问题，但参考策略与可部署策略之间仍存在巨大的性能下降。

同时，还有一类方法通过引入动力学学习来提升足式运动能力。DayDreamer (Wu et al., 2023) 采用了基于模型的强化学习（MBRL）框架，利用学成的“世界模型”来合成无限次交互；DreamWaQ (Nahrendra et al., 2023) 则通过变分自编码器（VAE）(?) 学成表示，以提升足式运动性能。这些方法的共同点在于使用回归目标来学习模型或表示，这要求神经网络精确拟合目标。然而，由于领域随机化带来的不确定性，网络倾向于拟合随机噪声，最终导致表示崩溃。

尽管我们的方法可以归入此类，但与上述工作的一个显著区别在于，我们的方法既不遵循计算成本高昂的 MBRL 框架，也不使用回归目标，后者可能导致作为辅助损失的表示崩溃。相反，我们遵循 IMC 原则，并使用原型对比学习 (Caron et al., 2020; Yarats et al., 2021; Deng et al., 2022) 作为辅助损失，这仅要求编码器基于历史观测结果区分当前情况与其他情况的不同之处。这使得样本得到更充分的利用，而基于样本的正则化带来了更好的鲁棒性 (LeCun, 2022)。

3 方法学

我们的混合内部模型（HIM）能够高效地训练一种策略，该策略不仅促进仿真到现实的兼容性，还能显著提升机器人的敏捷性。它受到经典内部模型控制原理的启发，并在基于学习的框架中实现。接下来，我们首先概述其整体结构，随后深入探讨细节。

表 1: 我们方法与先前方法的对比。教师-学生（Teacher-Student）指 (Miki et al., 2022a)，MONO 表示 (Agarwal et al., 2023)，AMP 表示对抗运动先验（Adversarial Motion Priors）(Wu et al., 2022; Escontrela et al., 2022)，RMA 表示快速运动适应（Rapid Motor Adaptation）(Kumar et al., 2021)。当前环境参数表示当前帧中的高程图、摩擦系数、恢复系数等。

Methods	Representations	External Sensors	Mimic Targets	Reference Dataset	# Samples (millions)
Teacher-Student	Current Env. Parameters	LiDAR	Behavior	-	Unknown
MONO	Current Env. Parameters	Depth Camera	Behavior	-	Unknown
AMP	Current Env. Parameters	-	Behavior	✓	600
RMA	Current Env. Parameters	-	Latent	-	1,280
Ours	Simulated Robot Response	-	-	-	200

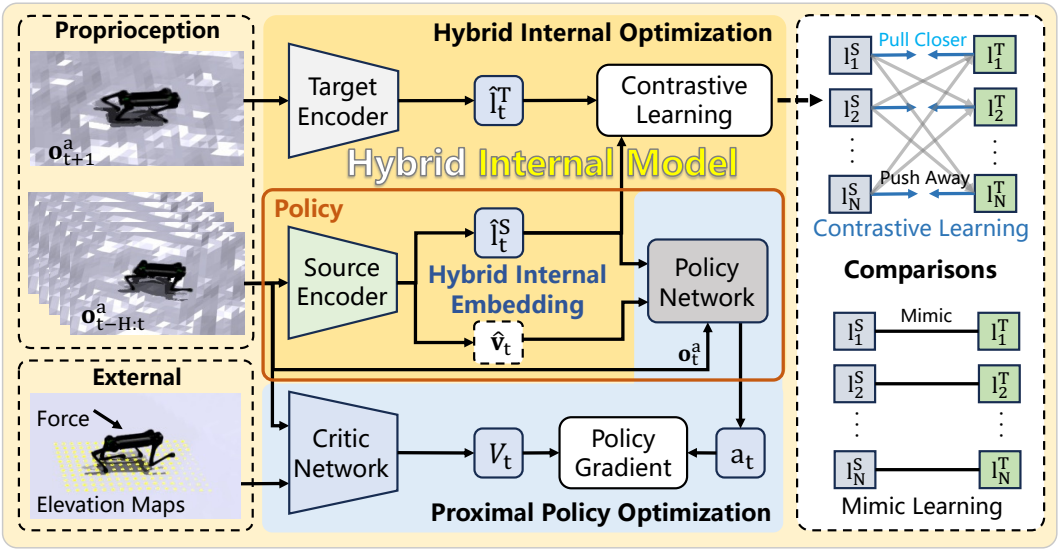


图 2: 我们框架的概述。策略网络接收部分观测和混合内部嵌入，后者通过对比学习优化至机器人的后继状态。该框架通过 HIO 与 PPO 交替优化。

3.1 框架概述

为了控制一个足式机器人，算法需要根据其本体感知信息，确定执行器的运动以实现期望的速度。我们遵循 (Rudin et al., 2022) 所提出的范式，将足式运动任务建模为一个序列决策问题。整个框架如图 2 所示。最优化过程包含两个阶段：混合内部最优化（HIO），用于训练混合内部模型；近端策略优化（PPO），用于优化策略网络。在每次迭代中，我们首先更新 HIM 的参数，然后冻结这些参数，并优化演员和评论员模块。

状态空间 策略网络以部分观测 o_t^a 作为输入，其中包括期望速度、来自其关节编码器和 IMU 的本体感知信息，以及上一个动作 a_{t-1} 。期望速度 $c_t = [v_x^c, v_y^c, \omega_{\text{yaw}}^c]$ 分别表示纵向和横向的线速度，以及水平方向的角速度。关节编码器提供其关节位置 θ_t 和关节速度 $\dot{\theta}_t$ 。IMU 提供其基座角速度 ω_t 和机器人坐标系中的重力方向 g_t 。我们的价值网络在训练阶段可访问特权信息，因此能够对状态值进行更准确的估计。其输入 o_t^c 在 o_t^a 的基础上增加了两个额外组件：当前外部作用力 f_t 和周围地面高度 h_t 。

动作空间。 每个执行器的运动被表述为目标关节位置 θ_{target} 与额定关节位置 θ_0 之间的偏差。为了降低网络输出的不稳定性，我们在策略输出 a_t 上增加一个缩放因子 $k \leq 1$ ，因此

关节的最终目标位置为 $\theta_{\text{target}} = \theta_0 + k\mathrm{a}_t$. 。动作空间的维度 $\mathcal{A}$ 等于执行器的数量。例如，四足机器人如 Unitree A1 或 ANYmal 具有 12 个执行器，每条腿上有 3 个。

奖励函数。 我们遵循 Rudin et al. (2022) 和 Agarwal et al. (2023) 中的奖励函数，并使用默认权重。详细信息见附录 A.1。

3.2 混合内部模型

经典的内部模型控制 (IMC) (Rivera et al., 1986) 表明，我们可以在不直接建模干扰的情况下实现鲁棒控制。如图 3-(a) 所示，它利用内部模型来模拟系统响应，并进一步估计系统干扰，从而提高闭环稳定性。内部模型越准确，所能实现的鲁棒控制效果越好。

在足式运动中，外部环境动态（如高程图、地面摩擦力和地面恢复系数）会对系统造成干扰。然而，准确估计这些参数尤为困难。受 IMC 的启发，我们提出使用模型来估计机器人的响应，作为一种可行的替代方案。如前所述，机器人显式地被赋予了期望速度以实现运动；同时，它也被隐式地要求保持稳定性。为此，我们引入了一种混合内部模型，能够同时估计显式的速度和另一个隐式的响应。

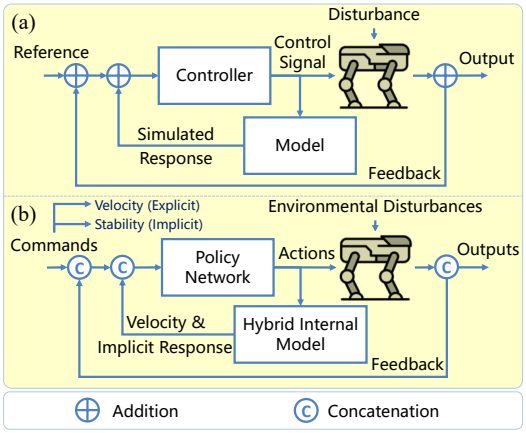


图 3: (a) IMC 和 (b) 我们实现的结果。

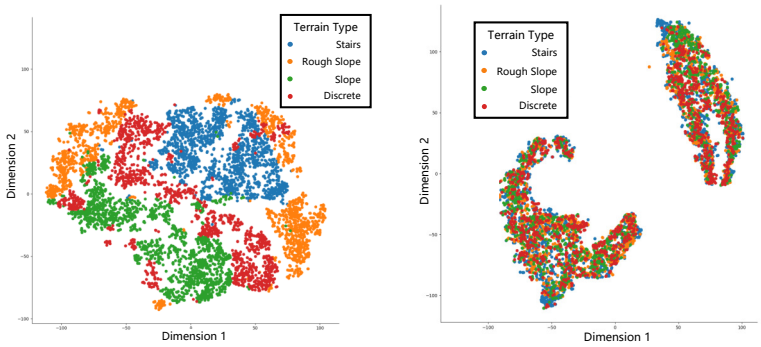
这些估计值与机器人观测结果共同输入到策略网络中，形成一个完整的闭环控制系统。该框架如图 3-(b) 所示。

在实际应用中，HIM 使用序列历史观测 $\mathrm{o}^a_{t-H:t}$ 来提取包含机器人速度 $\hat{\mathrm{v}}_t$ 和隐式响应 $\widehat{\mathrm{l}}_t$ 的混合内部嵌入。默认情况下，H 设为 5。提取器是一个具有隐藏维度分别为 512、256 和 128 的三层多层感知机（MLP）。策略网络将嵌入和 o^a_t 作为输入，并输出动作。

3.3 混合内部最优化

对于内部嵌入 $(\hat{\mathrm{v}}_t, \widehat{\mathrm{l}}_t)$ 最关键的问题是如何对其进行优化，以模拟机器人的响应，而这一响应自然地嵌入在机器人的后继状态 o^a_{t+1} 中。根据 IMC 的原则，我们可以直接根据 $\mathrm{o}^a_{t-H:t}$ 估计 o^a_{t+1}。然而，由于机器人状态维度较高，且仿真与现实之间存在差异，这带来了挑战。另一方面，考虑到我们在仿真环境中训练该框架，可以直接学习回归显式速度 $\hat{\mathrm{v}}_t$ ，并利用其真实值。对于隐式响应 $\widehat{\mathrm{l}}_t$ ，我们提出将其建模到潜在空间 $\mathrm{Z} \subset \mathrm{R}^{16}$ 中，并通过对比学习优化，使其接近后继状态。

在实际操作中，每个迭代步骤中，我们在每个环境中收集轨迹作为批量。若一对 o^a_{t+1} 与 $\mathrm{o}^a_{t-H:t}$ 属于同一轨迹，则它们为正样本对；否则为负样本对。这些样本对通过类似于 SwAV (Caron et al., 2020) 的交换分配任务进行优化。给定从滚动轨迹中采样的本体感知观测序列，我们可以根据转移关系推导出后续观测 o^a_{t+1} 作为目标向量，并将连结的历史观测 $\mathrm{o}^a_{t-H:t}$ 视为源向量。我们确保跨时间步的增强操作保持一致。源向量和目标向量分别输入到源编码器和目标编码器，以获得潜在特征 $\mathrm{l}_t^{\text{source}}$ 和 $\mathrm{l}_t^{\text{target}}$ ，并通过 $\mathcal{L}_2$ -范数规范化将其映射到高维空间中的单位球面上。为了从 $\mathrm{l}_t^{\text{source}}$ 和 $\mathrm{l}_t^{\text{target}}$ 预测簇分配概率 $\mathrm{p}_t^{\text{source}}$ 和 $\mathrm{p}_t^{\text{target}}$ ，我们首先对原型应用 $\mathcal{L}_2$ -范数规范化，得到规范化的矩阵 $\mathrm{E} = \{\bar{\mathrm{e}}_1, ..., \bar{\mathrm{e}}_K\}$ ，然后对源向量或目标向量与



(a) Ours (b) Regression (Nahrendra et al., 2023)

图 4: (a) 我们混合内部模型的潜在空间可视化，(b) Nahrendra et al. (2023)。

所有原型的点积进行 Softmax 运算：

$$\mathrm{p}_t^{\text{source}} = \frac{\exp(\frac{1}{\tau}\mathrm{l}_t^{\text{source}\top}\mathrm{e}_k)}{\sum_{k'}\exp(\frac{1}{\tau}\mathrm{l}_t^{\text{source}\top}\mathrm{e}_{k'})}, \quad \mathrm{p}_t^{\text{target}} = \frac{\exp(\frac{1}{\tau}\mathrm{l}_t^{\text{target}\top}\mathrm{e}_k)}{\sum_{k'}\exp(\frac{1}{\tau}\mathrm{l}_t^{\text{target}\top}\mathrm{e}_{k'})}. \tag{1}$$

此处，$\mathrm{p}_t^{\text{source}}$ 和 $\mathrm{p}_t^{\text{target}}$ 是历史观测值 $\mathrm{o}^a_{t-H:t}$ 映射到索引为 k 的单个簇的预测概率，而 τ 是一个温度参数。

为了获得上述预测概率的目标 $(\mathrm{q}_1^{\text{source}}, ..., \mathrm{q}_K^{\text{source}})$ 和 $(\mathrm{q}_1^{\text{target}}, ..., \mathrm{q}_K^{\text{target}})$，同时避免平凡解，对两个编码器均应用 Sinkhorn-Knopp 算法 (Cuturi, 2013)。现在我们有了簇分配预测和目标，表示学习的目标就是简单地最大化预测准确率：

$$\mathcal{J}^{\text{SwAV}} = -\frac{1}{2H}\sum_{t=1}^{H}(\mathrm{q}_t^{\text{source}}\log\mathrm{p}_t^{\text{target}} + \mathrm{q}_t^{\text{target}}\log\mathrm{p}_t^{\text{source}}). \tag{2}$$

分析 我们的方法可以最大化历史观测与下一次观测之间潜在特征的相似度，隐式建模外部状态，无需回归要求。这也通过利用批量级信息（即不同种类地形中的不同环境属性）来提升运动策略的性能。我们在我们的方法和回归 (Nahrendra et al., 2023) 的潜在输出上进行了 t-SNE Van der Maaten & Hinton (2008)。可视化结果表明，我们的混合内部模型对环境具有更可分离的编码，这意味着我们的方法携带了更宝贵的环境信息，从而具有更强的识别机器人所处地形种类的能力。

3.4 训练细节

仿真设置。 我们使用 Isaac Gym (Rudin et al., 2022)，配置 4096 个并行环境，每个 rollout 的长度为 100 个时间步。在 NVIDIA RTX 4090 上，训练过程需要 1000 次 rollout，耗时 1 小时的实时时钟时间。但其性能可一直提升至 2000 次 rollout。

动态随机化。 为了提高策略的鲁棒性并促进仿真到现实世界的迁移，我们在每个回合中随机化机器人的主体和连杆质量、机器人的质心（CoM）、施加在机器人主体上的负载、地面摩擦系数和恢复系数、电机强度、关节级 PD 增益、系统延迟、外部作用力以及初始关节位置。各参数的随机化值域详见附录 A.2。

训练课程。 我们采用与 Rudin et al. (2022) 和 Wu et al. (2022) 类似的地形课程。我们创建一个高度场地图，其中包含 200 种地形，按 20×10 网格排列，每一行的地形类型相同，且难度逐步增加，每个网格单元为 $10 \times 10\,\mathrm{m}^2$ 。我们的训练地形详细描述见附录 A.3。我们初始

时将所有机器人置于最简单难度的地形上，若机器人达到线性追踪奖励的 80%，则地形等级提升；若在单个回合中无法 travers 半数地形，则地形等级降低。我们使用一种简单的命令课程，帮助机器人从简单到复杂逐步学习。在楼梯或离散障碍物等复杂地形上，我们对纵向和横向线性速度命令采样范围为 $[-1.0, 1.0]$ m/s，水平角速度采样范围为 $[-2.0, 2.0]$ rad/s。在斜坡和崎岖斜坡上，我们将纵向线性速度范围扩大至 $[-3.0, 3.0]$ m/s，水平角速度范围扩大至 $[-3.0, 3.0]$ rad/s。所有命令均在对应范围内独立均匀采样，每 25 个时间步对每个机器人进行一次采样。

4 实验

在本节中，我们在仿真和真实场景下评估了所提方法的性能，并进行了消融实验。我们的方法的演示视频可在 Project Page 处找到。实验设置、基准方法和超参数的额外描述见附录。

4.1 评估设置

比较方法。 我们将本方法与以下方法进行比较：
- 基准：不使用 HIM 进行训练，但保留源编码器，并用 PPO 对其进行优化。
- 不带速度输入的我们的方法：将策略网络的速度输入设为 0。
- 不含速度损失：直接移除速度估计。
- 不含内部潜在输入的我们的方法：将策略网络的内部潜在输入设为 0。
- 无内部潜在损失的我们的方法：直接移除内部潜在估计。
- 回归：使用回归方法优化混合内部模型。
- Oracle：使用完整的观测历史来训练策略。
- 快速运动适应 (Kumar et al., 2021).
- 行为的多重性（走不同的路） (Margolis & Agrawal, 2023).
- 车载 MPC 控制器，仅在真实世界实验中进行对比。

现实世界中的设置。 我们将策略部署在 Unitree A1、Go1 和 Aliengo 上。策略以 50 Hz 运行，同时使用 PD 控制器以 500 Hz 的频率跟踪目标。参数分别为 A1 和 Go1 的 $k_p = 30.0$、$k_d = 0.75$，Aliengo 的 $k_p = 40.0$、$k_d = 2.0$。我们在真实世界中通过 3 个基准和 8 个任务对方法进行了鲁棒性测试。详细信息见附录 B.1。

仿真的设置 在仿真中，我们根据跟踪误差比较不同方法。线速度和角速度的跟踪误差分别使用范数 $\|v_{x,y} - v_{x,y}^{\text{target}}\|_2$ 和 $\|\omega_{\text{yaw}} - \omega_{\text{yaw}}^{\text{target}}\|_2$ 进行量化。我们在多种地形条件和运动范围下测试了跟踪性能。详细描述见附录 B.2。

4.2 主要结果

实际成果 在我们的真实世界基准测试中，我们将所提出的方法与 RMA (Kumar et al., 2021)、MoB (Margolis & Agrawal, 2023) 和内置 MPC 进行了比较。表 2 中的结果表明，我们的方法在所有任务上均优于其他方法，并且保持了更自然的步态。这证明了我们的方法能够很好地继承仿真中的策略，并可轻松部署到真实世界中。我们还观察到，即使在长距离楼梯等高难度任务，以及训练过程中从未出现过的复杂地形和可变形斜坡等情况中，我们的方法也能表现出色，显示出在开放世界中卓越的泛化能力。

仿真结果 在我们的仿真基准测试中，我们使用 Unitree Aliengo 将所提方法与 Baseline、Regression、RMA (Kumar et al., 2021) 和 MoB (Margolis & Agrawal, 2023) 进行了比较。表 3 中的结果显示，我们的方法在几乎所有任务上均优于其他方法。相较于其他方法，我们

表 2: 主要结果为在 20 次试验中真实世界基准上的平均性能 ↑，其中 ± 表示一个 95% 置信区间。表现最佳的结果已高亮显示。

Benchmarks	Environments	Metrics	Ours	RMA	MoB	Built-in MPC
Stairs	Short-range (A1)	Success rate (%)	100	60	0	0
	Long-range (Aliengo)	Number of stairs	176.5±7.81	75.35±19.98	0.0±0.0	0.0±0.0
Unseen Terrains	Compositional Terrain (Aliengo)	Success rate (%)	85	45	0	0
	Deformable Slope (A1)	Success rate (%)	55	10	0	0
Anti-disturbance	Dragging Obstacle (A1)	Maximum weight (Kg)	10	10	7	3
	Vertical Hit (A1)	Maximum weight (Kg)	8	7.5	7	5
	Payload (A1)	Maximum weight (Kg)	8	7	4	7
	Missing steps (Aliengo)	Success rate (%)	100	0	0	0

的方法具有更大的性能提升，且显著优于 Regression 方法。此外，在简单地形上，我们的方法在 66.67% 的速率值域内表现更优。

4.3 消融研究

仿真中的消融研究。 我们主要在 Aliengo 机器人上进行仿真环境下的消融实验。评估指标包括规范化的线速度跟踪得分、规范化的角速度跟踪得分以及最大可到达地形等级。任务与指令采样详见第 3.4节。地形等级的定义见附录 A.3。地形类型包括粗糙平面、金字塔坡面、粗糙金字塔坡面、波浪地形、台阶以及带有离散障碍物的平面，其对应比例为 [0.1, 0.2, 0.6, 0.1]。规范化的线速度跟踪得分（NLTS）和规范化的角速度跟踪得分（NATS）定义如下：

$$\text{NLTS} = \exp(-\frac{\|v_{x,y} - v_{x,y}^{\text{target}}\|_2^2}{0.25}),\ \text{NATS} = \exp(-\frac{\|\omega_{\text{yaw}} - \omega_{\text{yaw}}^{\text{target}}\|_2^2}{0.25}).$$

结果如图 4.3所示，其中曲线为 10 个随机种子的平均值。阴影区域表示不同种子间的标准差。尽管我们的方法无需地形信息，其表现结果与 Oracle 策略最为接近。我们还得出以下结论：

1. 在我们的混合内部模型中，内部嵌入和速度估计均有助于提升策略性能，缺少其中任一因素都可能导致性能下降。
2. 我们的混合内部最优化方法优于回归方法。这证明了我们的方法能够利用批量级别的信息，更准确地理解不同地形的特性。
3. RMA 无法模拟 Oracle 的所有出色表现。我们的方法在仿真与现实之间保持了一致的观测结果，从而实现了更优的性能。

真实世界中的消融研究。 我们还在真实世界基准上进行了消融研究。表 4 中的结果表明，我们的混合内部模型有助于性能提升，其中内部模型起到了关键作用。

表 3: 仿真中 4096×5 次试验的平均跟踪误差 ↓。最佳结果已高亮显示。

Terrain Types	Velocity Types	Ranges	Ours	Regression	RMA	Baseline	MoB (Trot)
Slopes	Linear	[-1, 1] m/s	0.073	0.071	0.158	0.271	0.103
		[-2, 2] m/s	0.075	0.077	0.270	0.305	0.126
	Angular	[-1, 1] rad/s	0.084	0.086	0.091	0.164	0.081
		[-2, 2] rad/s	0.124	0.130	0.134	0.202	0.114
	Combined	[-1, 1] m/s	0.078	0.075	0.155	0.207	0.069
		[-1, 1] rad/s	0.047	0.050	0.074	0.143	0.052
		[-2, 2] m/s	0.094	0.107	0.203	0.224	0.103
		[-2, 2] rad/s	0.067	0.071	0.102	0.157	0.069
Rough Slopes	Linear	[-1, 1] m/s	0.086	0.091	0.201	0.287	0.105
		[-2, 2] m/s	0.085	0.088	0.294	0.331	0.124
	Angular	[-1, 1] rad/s	0.097	0.108	0.142	0.160	0.119
		[-2, 2] rad/s	0.143	0.150	0.147	0.187	0.135
	Combined	[-1, 1] m/s	0.088	0.095	0.167	0.220	0.147
		[-1, 1] rad/s	0.054	0.070	0.086	0.169	0.092
		[-2, 2] m/s	0.103	0.137	0.221	0.284	0.195
		[-2, 2] rad/s	0.076	0.096	0.117	0.201	0.114
Stairs	Linear	[-1, 1] m/s	0.147	0.194	0.306	0.377	1.108
	Angular	[-1, 1] rad/s	0.087	0.101	0.241	0.370	0.930
	Combined	[-1, 1] m/s	0.135	0.217	0.337	0.405	1.270
		[-1, 1] rad/s	0.096	0.154	0.201	0.289	0.992
Discretre Obstacles	Linear	[-1, 1] m/s	0.125	0.182	0.311	0.279	0.973
	Angular	[-1, 1] rad/s	0.083	0.097	0.175	0.253	0.841
	Combined	[-1, 1] m/s	0.125	0.206	0.305	0.374	1.254
		[-1, 1] rad/s	0.075	0.133	0.177	0.246	0.976

5 结论

我们的工作提出了一种有前景的框架，并揭示了基于学习的运动控制与经典内部模型控制原理之间的联系。此外，实验结果表明，关节编码器和惯性测量单元（IMU）提供了足够的信息。我们还证明，与回归相比，对比学习在噪声鲁棒性和高样本效率方面能提供更优的表示。据我们所知，本方法是首个在运动任务中完全利用批量级信息的系统，借助 Isaac Gym 的大规模并行仿真实现。然而，缺乏外部感知（如视觉信息）使得腿式机器人仅具备基础技能集。未来，我们将结合外部感知来改进该方法，以应对更具挑战性的环境和更高层次的任务。

致谢 本工作由上海人工智能实验室支持。

参考文献

Ananye Agarwal, Ashish Kumar, Jitendra Malik, and Deepak Pathak. Legged locomotion in challenging terrains using egocentric vision. In Conference on Robot Learning (CoRL), 2023.

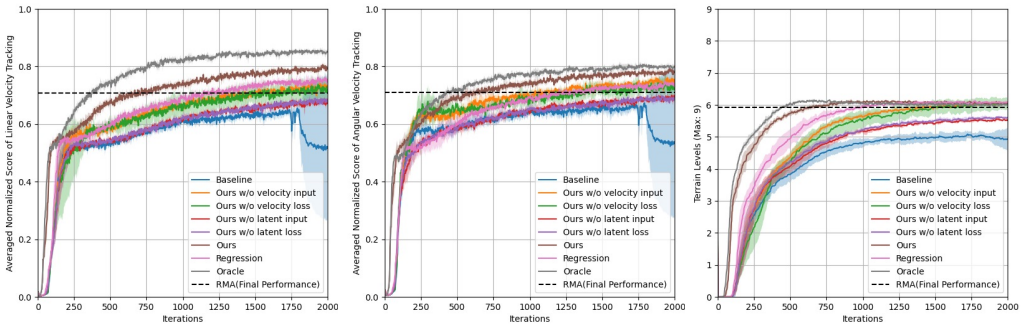


图 5: 消融实验中学习曲线的结果包括：(a) 规范化的线速度跟踪得分，(b) 规范化的角速度跟踪得分，以及 (c) Isaac Gym 中可达到的最大地形等级。

表 4: 消融研究在 20 次试验中的真实世界基准上的平均性能 ↑，其中 ± 表示一个 95% 置信区间。表现最佳的结果已高亮显示。

Benchmarks	Environments	Metrics	Ours	Ours w/o vel. inp.	Ours w/o vel. loss	Ours w/o lat. inp.	Ours w/o lat. loss	Regression	Baseline
Stairs	Short-range (A1)	Success rate (%)	100	85	80	50	55	85	10
	Long-range (Aliengo)	Number of stairs	176.5±7.81	51.45±25.67	54.6±24.68	13.3±13.42	10.6±9.68	155.7±13.48	0.0±0.0
Unseen Terrains	Compositional Terrain (Aliengo)	Success rate (%)	85	70	75	50	50	70	15
	Deformable Slope (A1)	Success rate (%)	55	30	25	0	0	30	0
Anti-disturbance	Dragging Obstacle (A1)	Maximum weight (Kg)	10	10	10	5	5	10	4
	Vertical Hit (A1)	Maximum weight (Kg)	8	7	6.5	4	4	8	5.5
	Payload (A1)	Maximum weight (Kg)	8	7	7	3.5	3.5	7.5	3
	Missing steps (Aliengo)	Success rate (%)	100	90	90	5	0	65	0

Ayush Agrawal, Shuxiao Chen, Akshara Rai, and Koushil Sreenath. Vision-aided dynamic quadrupedal locomotion on discrete terrain using motion libraries. In International Conference on Robotics and Automation (ICRA), 2022.

Gerardo Bledt, Matthew J Powell, Benjamin Katz, Jared Di Carlo, Patrick M Wensing, and Sangbae Kim. Mit cheetah 3: Design and control of a robust, dynamic quadruped robot. In IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2018.

Will Bosworth, Sangbae Kim, and Neville Hogan. The mit super mini cheetah: A small, low-cost quadrupedal robot for dynamic locomotion. In 2015 IEEE International Symposium on Safety, Security, and Rescue Robotics (SSRR), 2015.

Ken Caluwaerts, Atil Iscen, J Chase Kew, Wenhao Yu, Tingnan Zhang, Daniel Freeman, Kuang-Huei Lee, Lisa Lee, Stefano Saliceti, Vincent Zhuang, et al. Barkour: Bench-

marking animal-level agility with quadruped robots. arXiv preprint arXiv:2305.14654, 2023.

Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised learning of visual features by contrasting cluster assignments. Advances in neural information processing systems, 2020.

Dian Chen, Brady Zhou, Vladlen Koltun, and Philipp Krähenbühl. Learning by cheating. In Conference on Robot Learning (CoRL), 2019.

Xuxin Cheng, Ashish Kumar, and Deepak Pathak. Legs as manipulator: Pushing quadrupedal agility beyond locomotion. In IEEE International Conference on Robotics and Automation (ICRA), 2023.

Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. Advances in neural information processing systems, 2013.

Fei Deng, Ingook Jang, and Sungjin Ahn. Dreamerpro: Reconstruction-free model-based reinforcement learning with prototypical representations. In International Conference on Machine Learning, 2022.

Alejandro Escontrela, Xue Bin Peng, Wenhao Yu, Tingnan Zhang, Atil Iscen, Ken Goldberg, and Pieter Abbeel. Adversarial motion priors make good substitutes for complex reward functions. In IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2022.

Zipeng Fu, Ashish Kumar, Jitendra Malik, and Deepak Pathak. Minimizing energy consumption leads to the emergence of gaits in legged robots. In Conference on Robot Learning (CoRL), 2021.

Zipeng Fu, Xuxin Cheng, and Deepak Pathak. Deep whole-body control: Learning a unified policy for manipulation and locomotion. In Conference on Robot Learning (CoRL), 2022.

Ross Hartley, Josh Mangelson, Lu Gan, Maani Ghaffari Jadidi, Jeffrey M Walls, Ryan M Eustice, and Jessy W Grizzle. Legged robot state-estimation through combined forward kinematic and preintegrated contact factors. In 2018 IEEE International Conference on Robotics and Automation (ICRA), pp. 4422–4429. IEEE, 2018.

Marco Hutter, Christian Gehring, Dominic Jud, Andreas Lauber, C Dario Bellicoso, Vassilios Tsounis, Jemin Hwangbo, Karen Bodie, Peter Fankhauser, Michael Bloesch, et al. Anymal-a highly mobile and dynamic quadrupedal robot. In IEEE/RSJ international conference on intelligent robots and systems (IROS), 2016.

Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun, and Marco Hutter. Learning agile and dynamic motor skills for legged robots. Science Robotics, 2019.

Chieko Imai, Minghao Zhang, Yuchen Zhang, Marcin Kierebinski, Ruihan Yang, Yuzhe Qin, and Xiaolong Wang. Vision-guided quadrupedal locomotion in the wild with multi-modal delay randomization. In IEEE/RSJ international conference on intelligent robots and systems (IROS), 2022.

Yandong Ji, Gabriel B Margolis, and Pulkit Agrawal. Dribblebot: Dynamic legged manipulation in the wild. In IEEE International Conference on Robotics and Automation (ICRA), 2023.

Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. Rma: Rapid motor adaptation for legged robots. In Robotics: Science and Systems, 2021.

Yann LeCun. A path towards autonomous machine intelligence. Open Review, 2022.

Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. Science robotics, 2020.

Viktor Makoviychuk, Lukasz Wawrzyniak, Yunrong Guo, Michelle Lu, Kier Storey, Miles Macklin, David Hoeller, Nikita Rudin, Arthur Allshire, Ankur Handa, et al. Isaac gym: High performance gpu-based physics simulation for robot learning. Advances in neural information processing systems, 2021.

Gabriel B Margolis and Pulkit Agrawal. Walk these ways: Tuning robot control for generalization with multiplicity of behavior. In Conference on Robot Learning (CoRL), 2023.

Gabriel B Margolis, Ge Yang, Kartik Paigwar, Tao Chen, and Pulkit Agrawal. Rapid locomotion via reinforcement learning. In Robotics: Science and Systems, 2022.

Takahiro Miki, Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. Science Robotics, 2022a.

Takahiro Miki, Lorenz Wellhausen, Ruben Grandia, Fabian Jenelten, Timon Homberger, and Marco Hutter. Elevation mapping for locomotion and navigation using gpu. In IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2022b.

I Made Aswin Nahrendra, Byeongho Yu, and Hyun Myung. Dreamwaq: Learning robust quadrupedal locomotion with implicit terrain imagination via deep reinforcement learning. In IEEE International Conference on Robotics and Automation (ICRA), 2023.

Jacopo Panerati, Hehui Zheng, SiQi Zhou, James Xu, Amanda Prorok, and Angela P Schoellig. Learning to fly—a gym environment with pybullet physics for reinforcement learning of multi-agent quadcopter control. In IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2021.

Xue Bin Peng, Erwin Coumans, Tingnan Zhang, Tsang-Wei Lee, Jie Tan, and Sergey Levine. Learning agile robotic locomotion skills by imitating animals. In Robotics: Science and Systems, 2020.

Daniel E Rivera, Manfred Morari, and Sigurd Skogestad. Internal model control: Pid controller design. Industrial & engineering chemistry process design and development, 1986.

Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. In Conference on Robot Learning (CoRL), 2022.

Koushil Sreenath, Hae-Won Park, Ioannis Poulakakis, and Jessy W Grizzle. A compliant hybrid zero dynamics controller for stable, efficient and fast bipedal walking on mabel. The International Journal of Robotics Research, 2011.

Jie Tan, Tingnan Zhang, Erwin Coumans, Atil Iscen, Yunfei Bai, Danijar Hafner, Steven Bohez, and Vincent Vanhoucke. Sim-to-real: Learning agile locomotion for quadruped robots. In Robotics: Science and Systems, 2018.

Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2012.

Laurens Van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. Journal of machine learning research, 2008.

Jinze Wu, Guiyang Xin, Chenkun Qi, and Yufei Xue. Learning robust and agile legged locomotion using adversarial motion priors. IEEE Robotics and Automation Letters, 2022.

Philipp Wu, Alejandro Escontrela, Danijar Hafner, Pieter Abbeel, and Ken Goldberg. Daydreamer: World models for physical robot learning. In Conference on Robot Learning (CoRL), 2023.

Yujiang Xiang, Jasbir S Arora, and Karim Abdel-Malek. Physics-based modeling and simulation of human walking: a review of optimization-based and other approaches. Structural and multidisciplinary optimization, 2010.

Zhaoming Xie, Xingye Da, Michiel Van de Panne, Buck Babich, and Animesh Garg. Dynamics randomization revisited: A case study for quadrupedal locomotion. In IEEE International Conference on Robotics and Automation (ICRA), 2021.

Chuanyu Yang, Kai Yuan, Qiuguo Zhu, Wanming Yu, and Zhibin Li. Multi-expert learning of adaptive legged locomotion. Science Robotics, 2020.

Ruihan Yang, Minghao Zhang, Nicklas Hansen, Huazhe Xu, and Xiaolong Wang. Learning vision-guided quadrupedal locomotion end-to-end with cross-modal transformers. In International Conference on Learning Representations, 2022.

Ruihan Yang, Zhuoqun Chen, Jianhan Ma, Chongyi Zheng, Yiyu Chen, Quan Nguyen, and Xiaolong Wang. Generalized animal imitator: Agile locomotion with versatile motion prior. arXiv preprint arXiv:2310.01408, 2023a.

Ruihan Yang, Ge Yang, and Xiaolong Wang. Neural volumetric memory for visual locomotion control. In Conference on Computer Vision and Pattern Recognition, 2023b.

Denis Yarats, Rob Fergus, Alessandro Lazaric, and Lerrel Pinto. Reinforcement learning with prototypical representations. In International Conference on Machine Learning, 2021.

KangKang Yin, Kevin Loken, and Michiel Van de Panne. Simbicon: Simple biped locomotion control. ACM Transactions on Graphics (TOG), 2007.

Wenhao Yu, Deepali Jain, Alejandro Escontrela, Atil Iscen, Peng Xu, Erwin Coumans, Sehoon Ha, Jie Tan, and Tingnan Zhang. Visual-locomotion: Learning to walk on complex terrains with vision. In Conference on Robot Learning (CoRL), 2021.

Ziwen Zhuang, Zipeng Fu, Jianren Wang, Christopher Atkeson, Soeren Schwertfeger, Chelsea Finn, and Hang Zhao. Robot parkour learning. In Conference on Robot Learning (CoRL), 2023.

A 超参数

A.1 奖励函数

我们在训练过程中使用的奖励函数如表 5 所示，这些奖励函数来自 Kumar et al. (2021); Agarwal et al. (2023); Margolis & Agrawal (2023); Fu et al. (2021)。

表 5: 奖励

Reward	Equation (r_i)	Weight (w_i)
Lin. velocity tracking	$\exp\left\{-\frac{\lVert \mathrm{v}_{xy}^{\mathrm{cmd}} - \mathrm{v}_{xy} \rVert_2^2}{\sigma}\right\}$	1.0
Ang. velocity tracking	$\exp\left\{-\frac{\left(\omega_{\mathrm{yaw}}^{\mathrm{cmd}} - \omega_{\mathrm{yaw}}\right)^2}{\sigma}\right\}$	0.5
Linear velocity (z)	v_z^2	-2.0
Angular velocity (xy)	$\lVert \boldsymbol{\omega}_{xy} \rVert_2^2$	-0.05
Orientation	$\lVert \mathrm{g} \rVert_2^2$	-0.2
Joint accelerations	$\lVert \ddot{\boldsymbol{\theta}} \rVert^2$	-2.5×10^{-7}
Joint power	$\lvert \boldsymbol{\tau} \lVert \dot{\boldsymbol{\theta}} \rvert^T$	-2×10^{-5}
Body height	$\left(h^{\mathrm{target}} - h\right)^2$	-1.0
Foot clearance	$\sum_{i=0}^{3} \left(p_z^{\mathrm{target}} - p_z^i\right)^2 \cdot v_{xy}^i$	-0.01
Action rate	$\lVert \mathrm{a}_t - \mathrm{a}_{t-1} \rVert_2^2$	-0.01
Smoothness	$\lVert \mathrm{a}_t - 2\mathrm{a}_{t-1} + \mathrm{a}_{t-2} \rVert_2^2$	-0.01

在表 5 中, σ 为跟踪塑造系数, 我们使用 $\sigma = 0.25$, h^{target} 为对应于地面的期望基高, p_z^{target} 和 p_z^i 分别为机器人坐标系下期望足部位置与实际足部位置在 z 轴上的分量，v_{xy}^i 为机器人坐标系下足部在 xy 平面上的速度。

A.2 领域随机化

对于我们方法及其他方法的训练，所使用的领域随机化如表 6 所示，数据来源于 Wu et al. (2022); Nahrendra et al. (2023)。

表 6: 领域随机化及其相应的值域

Parameters	Range[Min, Max]	Unit
Body Mass	$[0.8, 1.2]\times$ nominal value	Kg
Link Mass	$[0.8, 1.2]\times$ nominal value	Kg
CoM	$[-0.1, 0.1] \times [-0.1, 0.1] \times [-0.1, 0.1]$	m
Payload Mass	$[-1, 3]$	Kg
Ground Friction	$[0.2, 2.75]$	-
Ground Restitution	$[0.0, 1.0]$	-
Motor Strength	$[0.8, 1.2]\times$ motor torque	Nm
Joint K_p	$[0.8, 1.2] \times 20$	-
Joint K_d	$[0.8, 1.2] \times 0.5$	-
Initial Joint Positions	$[0.5, 1.5]\times$ nominal value	rad
System Delay	$[0, 3\Delta_t]$	s
External Force	$[-30, 30] \times [-30, 30] \times [-30, 30]$	N

A.3 训练地形

我们的地形包括斜坡、陡坡、台阶和离散障碍物。

斜坡和粗糙斜坡的倾角从 0° 到 40° ，在粗糙斜坡上添加的均匀噪声范围为 ± 1 cm 到 ± 8 cm。台阶的宽度随机变化，范围为 20 cm 到 40 cm，高度变化范围为 5 cm 到 23 cm。离散障碍物的高度范围为 ± 5 cm 到 ± 15 cm。我们使用 0 到 9 的整数为地形分配难度等级。具体而言，对于用 $\text{level}^{\text{terrain}}$ 表示的地形等级，对应的地形如下：

- 坡度：倾斜角为 $40 \times \frac{\text{level}^{\text{terrain}}}{9}$ ◦；
- 粗糙斜坡：振幅为 $1 + 7 \times \frac{\text{level}^{\text{terrain}}}{9}$ cm，倾角为 $40 \times \frac{\text{level}^{\text{terrain}}}{9}$ ◦；
- 楼梯：踏步高度为 $5 + 18 \times \frac{\text{level}^{\text{terrain}}}{9}$ cm；
- 离散障碍物：高度为 $5 + 10 \times \frac{\text{level}^{\text{terrain}}}{9}$ cm。上述地形的比例分别为 0.1、0.2、0.6 和 0.1。

A.4 超参数

表 7: 训练的超参数

General	
Batch Size	4096×200
Mini-batch Size	4096×50
Number of epochs	5
PPO	
Clip range	0.2
Entropy coefficient	0.01
Discount factor	0.99
GAE discount factor	0.95
Desired KL-divergence	0.01
Learning rate	1×10^{-3}
Adam epsilon	1×10^{-8}
Gradient clipping	10
HIM	
Number of prototypes	16
Contrastive loss scale	1.0
Velocity estimation loss scale	1.0
Learning rate	1×10^{-3}
Adam epsilon	1×10^{-8}
Gradient clipping	10

B 实验细节

B.1 真实世界基准设置

我们的基准测试包含三个部分：**楼梯**、**未见过的地形**和 **抗干扰性**：

楼梯：

• 短距离楼梯：此场景包含两组楼梯，每组 5 级台阶。楼梯的高度和宽度分别为 16 cm 和 27 cm。使用 Unitree A1 机器人在此场景中测试我们的策略，评估指标为成功通过两组楼梯的比率。该场景对应的快照显示在图 6(a)的左列中。

• 远距离楼梯：该场景包含数百级台阶，每级台阶高 17 厘米，宽 25 厘米。Unitree Aliengo 机器人配备了待测试的策略，评估指标为机器人在不中断的情况下能够攀登的台阶数量。该场景的相应照片如图 6(a)右栏所示。

未被探索的领域：

• 组合地形：该场景交替出现碎石和楼梯，如图 6(b) 上部图片所示。Unitree Aliengo 机器人配备了需要测试的策略，评估指标为通过三次组合交替的成功率。

• 可变形斜坡：此场景由两个柔性床层构成一个可变形斜坡，如图 6(b) 下方图片所示。使用 Unitree A1 机器人测试我们的策略，衡量指标为成功穿越该斜坡的比率。

抗干扰：

• 拖拽障碍物：该任务模拟了机器人腿部被障碍物拖拽的场景。一个木箱被固定在机器人后腿上，限制其运动。此任务的衡量指标是机器人能够承受的最大权重。使用 Unitree A1 机器人，示意图见图 6(c)左上角。

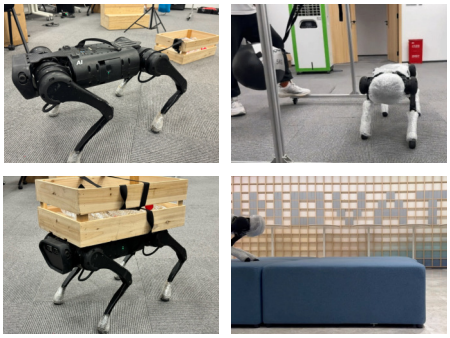
• 侧向撞击：此任务用于评估机器人抵抗推力的能力。机器人会受到一个来自 107 厘米高度下落摆动载荷的侧向力。本任务使用 Unitree A1 机器人，指标为机器人在受到撞击后所能承受的最大载荷重量。示意图如图 6(c)右上角所示。

• 载荷：该任务评估机器人的承载容量。使用 Unitree A1 机器人，测量机器人在行走过程中能够携带的最大重量。示意图见图 6(c)左下角。

• 缺失步骤：此任务模拟机器人在丢失步态并从高台跌落时的反应。如图 6(c) 右下角所示，平台高度为 42 厘米。本任务使用 Unitree Aliengo 机器人，衡量指标为下落后的平衡保持成功率。



(a) Stairs (b) Unseen terrains



(c) Anti-disturbance

图 6: 第 4.1. 节中用于定量分析的我们的真实场景基准的快照。

B.2 仿真基准设置

我们考虑在每种地形类型下具有 3 种不同范围指令的跟踪任务。在斜坡和粗糙斜坡上的跟踪误差测试范围为 $[-1.0, 1.0]\,\mathrm{m/s} \times [-1.0, 1.0]\,\mathrm{m/s} \times [-1.0, 1.0]\,\mathrm{rad/s}$ 和 $[-2.0, 2.0]\,\mathrm{m/s} \times [-1.0, 1.0]\,\mathrm{m/s} \times [-2.0, 2.0]\,\mathrm{rads/s}$ 。所有其他测试均在范围 $[-1.0, 1.0]\,\mathrm{m/s} \times [-1.0, 1.0]\,\mathrm{m/s} \times [-1.0, 1.0]\,\mathrm{rad/s}$ 内进行。这些范围分别对应于前进方向的线性速度、横向速度以及关于垂直轴的角速度。

在测试线性速度跟踪误差时，角速度目标设为 0。在测试角速度跟踪误差时，线性速度目标设为 0。' 组合速度' 测试则不将任一速度分量设为 0。我们在这几个值域内均匀采样测试指令。环境条件设置为 $\mathrm{level}^{\mathrm{terrain}} = 1, 2, 3, 4$，每种情况各占 25%，如附录 A.3所述。

B.3 原型数量消融实验

我们对原型数量进行了消融实验。默认情况下，我们将原型数量设置为 16，这对应于地形类型的方阵。

不同原型数量的训练曲线如图 7 所示。可以观察到，随着原型数量的增加，我们方法的性能稳步提升，直到达到 64 个原型时达到峰值。此后，性能开始下降。

这一发现表明，环境动态的表示无需像纯回归那样依赖稠密表示，但过于稀疏的表示也同样不足。此外，原型数量较多可在初始阶段加速训练，但会损害最终性能；相反，原型数量较少可能导致初始训练较慢，但最终可达到更优的性能。

因此，确定合适的原型数量对于在快速训练速度和最佳最终性能之间取得平衡至关重要。这一问题有待未来研究进一步探讨。

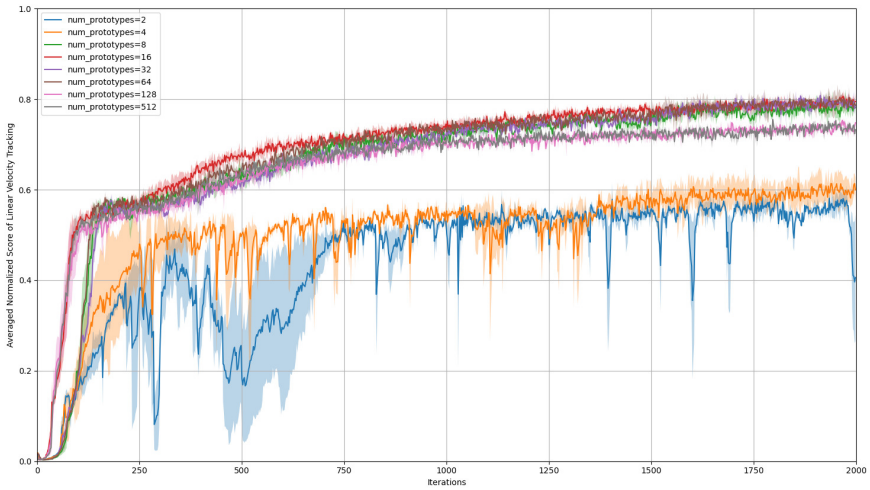


图 7: 原型数量上的规范化线性追踪得分

B.4 户外实验

我们进一步在更多真实场景中评估了我们的策略。视频可于以下 URL 查看。我们在户外实验中出现的场景示意图如图 8 所示。

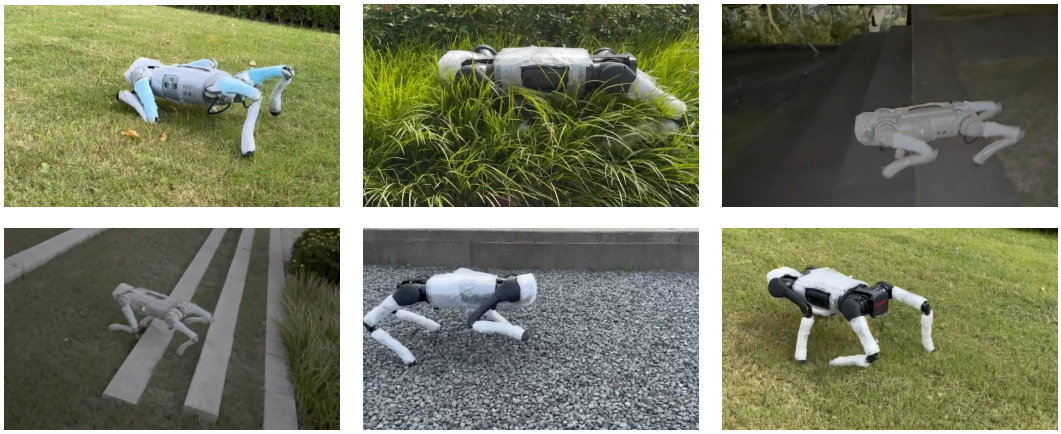


图 8: 用于评估我们的四足机器人敏捷性的各种户外场景快照。