https://hjfy.top/arxiv/2201.08117

在野外为四足机器人学习稳健的感知运动

Takahiro Miki[1,*], Joonho Lee[1], Jemin Hwangbo[2], Lorenz Wellhausen[1], Vladlen Koltun[3], and Marco Hutter[1]

[1]Robotic Systems Lab, ETH Zurich, Zurich, Switzerland

[2]Robotics and Artificial Intelligence Lab, KAIST, Daejeon, Korea

[3]Intelligent Systems Lab, Intel, Jackson, WY, USA.

[*]Corresponding author: tamiki@ethz.ch

Compiled August 11, 2025

能在偏远危险环境中自主作业的腿式机器人，将极大地拓宽对未充分探索区域的探索机会。外感受感知对于快速且节能的运动至关重要：在接触地形前感知它，使机器人能提前规划并调整步态，以保持速度和稳定性。然而，如何鲁棒地利用外感受感知进行运动，一直是机器人学中的一大挑战。雪、植被和水在视觉上常被误认为不可踏足的障碍，或因高反射率而完全缺失。此外，深度感知可能因复杂光照、灰尘、雾气、反光或透明表面、传感器遮挡等因素而退化。因此，迄今为止最鲁棒且通用的腿式运动解决方案仅依赖于本体感知，这严重限制了运动速度，因为机器人需先实际感受地形，再相应调整步态。本文提出了一种鲁棒且通用的方法，将外感受与本体感知整合于腿式运动中。我们采用了一种基于注意力机制的循环编码器，融合了本体与外感受输入。该编码器通过端到端训练，无需依赖启发式方法，便能无缝结合不同的感知模式，最终形成一个具有高鲁棒性和速度的腿式运动控制器。该控制器在多种挑战性的自然与城市环境中进行了跨季节测试，并在阿尔卑斯山完成了一次与人类徒步者推荐时间相当的时长一小时的徒步。

1. 引言

腿式机器人能够在人类难以到达或过于危险的环境中执行任务，例如危险区域和其他行星表面。腿可以跨越陡峭的斜坡、台阶和沟壑等具有挑战性的地形，这些地形可能会阻碍类似大小的轮式或履带式车辆。腿式机器人领域已经取得了显著进展 [1–5]，并且一些商业平台正在现实世界中部署 [6–10]。

然而，迄今为止，腿式机器人在穿越具有挑战性的现实世界地形方面仍无法与动物相媲美。许多腿式动物，如人类和狗，能够通过预见即将到来的地形并基于视觉信息规划步伐，在这样的环境中敏捷地行走或奔跑 [11]。动物自然地结合本体感觉和外感觉，以适应高度不规则的地形形状和表面特性，如滑溜或柔软，即使在视觉感知受限的情况下也是如此。赋予腿式机器人这种能力是机器人学中的一大挑战。

最大的困难之一在于对不完整和噪声感知的可靠解释，以进行控制。在现实环境中，由机载传感器提供的外部感知信息往往不完整且不可靠。大多数现有腿式机器人依赖的基于立体相机的深度传感器 [6, 9, 12]，需要纹理来进行立体匹配，因此在低纹理表面或图像部分过曝或欠曝时表现不佳。飞行时间（ToF）相机常常无法感知黑暗表面，并在阳光下产生噪声 [13]。一般而言，依赖光线推断距离的传感器容易在高度反射表面上产生伪影，因为这些传感器假设光线沿直线传播。此外，深度传感器本质上无法区分柔软不稳定的表面（如植被）与刚性表面。高程图通常用于表示从深度传感器测量中提取的地形几何信息 [14–17]。它依赖于机器人的估计姿态，因此会受到姿态估计误差的影响。地图中其他常见的不确定性来源包括动态物体导致的遮挡或测量时间不一致。大多数依赖机载地形感知的现有方法仍然容易受到这些故障的影响。

传统方法假设地形信息及地图中编码的任何不确定性都相对准确，重点完全放在生成运动上。离线方法使用预先扫描的地形图，计算一个手工设计的代价函数，并优化一条轨迹，然后在机器人上回放 [18, 19]。这些方法假设对完整地形和机器人状态有完美了解，并规划复杂的运动，导致较长的规划时间。在线方法通常采用类似的方式，但仅利用机载资源构建地图，并在执行过程中不断重新规划轨迹 [20–24]。最近，通过使用启发式方法减少规划时间 [25–27]，或利用卷积神经网络（CNN）更高效地计算落脚点代价 [27]，实现了更快的运动。最近，双足机器人 Atlas 展示了在复杂障碍物上的跑酷能力 [28]。它利用预先规划的运动参考，并通过机载 LiDAR 传感器数据在线优化其运动。总体而言，上述所有方法的重点都是在给定准确地形信息的情况下选择落脚点并生成轨迹。一些工作 [14, 17] 在图中表示了测量的统计不确定性，但其应用仅限于启发式定义的落脚规则，以避开风险区域 [24]。此类方法只能处理明确建模的不确定性，对于在野外遇到的各种感知故障并不具备鲁棒性。



Fig. 1. 在野外实现稳健的移动。所展示的移动控制器在多种复杂环境中经过多季节的广泛测试。该控制器克服了现实世界中的一系列挑战，常常是多种困难同时出现。这些挑战包括自然环境中湿滑的表面、陡峭的斜坡、复杂的地形以及植被覆盖。在搜救场景中，控制器应对了陡峭的楼梯、未知的负载以及影响感知的浓雾。在地下洞穴系统中，遇到了反光表面、松软的地面、低光照及水坑。冬季则堆积了柔软且易滑的积雪。控制器在这些环境中穿行，实现了零故障。

数据驱动的方法最近被引入，以便在不影响实时性能的情况下融入更复杂的动态。基于学习的四足或双足运动，通过使用强化学习（RL）[29–32]，在仿真角色中得以实现，并且在最近的工作中使用了真实的机器人模型 [33]。然而，这些工作仅在仿真中进行。最近，基于 RL 的运动控制器已成功转移到物理机器人上 [3, 4, 34–40]。Hwangbo 等人 [3, 41] 通过使用学成的执行器动力学，促进了仿真到现实（sim-to-real）的转移，在平地上实现了四足运动与恢复。Lee 等人 [4] 扩展了这一方法，通过在特权训练设置中模拟具有挑战性的地形，并采用自适应课程，实现了崎岖地形的运动。Peng 等人 [35] 利用模仿学习将动物运动转移到有腿机器人上。然而，这些方法并未使用任何视觉信息。

为了将外部感知信息融入运动学习中，Gangapurwala 等人 [42] 结合了基于学习的落脚点规划器和基于模型的全身体运动控制器，以在实验室情景中将策略转移到现实世界。他们的应用主要局限于具有平坦表面的刚性地形，并且在部署值域上仍然受到限制。其性能紧密依赖于地图的质量，而在野外环境中，地图往往变得不可靠。

在基于模型和基于学习的方法中，对地图质量无瑕疵的假设阻碍了这些方法在非受控户外环境中的应用。处理地形感知中的不确定性仍然是一个未解决的问题。现有的控制器通过避免在户外环境中使用视觉信息 [2, 4, 38] 或通过添加启发式定义的反射规则 [43, 44] 来防止灾难性故障。

在此，我们推出一种面向四足机器人的地形感知控制器，它突破了以往方法的局限，使机器人能够在严酷的自然地形中以前所未有的速度稳健行进（见视频 1）。该控制器的核心在于，它采用了一种原则性方案，将外部感知信息整合入运动控制之中。

核心组件是一个循环编码器，它将本体感知与外部感知融合为一个综合信念状态。该编码器在仿真环境中训练，旨在从可能不完整、有偏且含噪声的外部感知观测中捕捉地形的地面实况信息。信念状态编码器以端到端方式训练，无需依赖启发式方法即可整合本体感知与外部感知数据。它学会利用外部感知提供的预见性来规划落脚点并在外部感知可靠时加速运动，同时能在需要时无缝切换至基于本体感知的鲁棒运动模式。因此，学成的控制器结合了两者的优势：外部感知带来的速度与效率，以及本体感知的鲁棒性。

控制器通过特权学习 [45] 进行训练。我们首先通过Reinforcement Learning (RL)训练一个教师策略，该策略能够完全访问以环境真实状态形式呈现的特权信息。这种特权训练使教师策略能够在完美了解地形的情况下发现最优行为。随后，我们训练一个学生策略，该策略仅能访问物理机器人在现场可获取的信息。学生策略围绕我们的信念状态编码器构建，并通过模仿学习进行训练。学生策略学会在仅能获取环境部分且带噪声的观测时，预测教师的最优动作。

一旦学生策略训练完成，我们便将其直接部署于机器人上，无需任何微调。控制器接收来自机载传感器的观测数据及期望速度指令，进而输出各关节的目标位置作为动作指令。机器人通过利用以自身为中心的高程地图来感知环境。该高程地图充当了传感器与运动控制器之间的抽象层，使得我们的方法不受深度传感器选择的限制，能够无缝适配不同传感器，如立体相机或激光雷达（LiDAR）。由于策略在训练时已能应对高程地图中的显著噪声、偏差及缺失，即便在映射失败或传感器物理损坏的情况下，机器人仍能持续行走。

所提出的方法在运动速度和障碍物通过能力方面相较于现有技术 [4] 取得了显著提升，同时保持了卓越的鲁棒性。我们的核心贡献在于提出了一种融合多模态感知的方法，并通过大量硬件实验证明，由此产生的控制策略能够有效应对各种外部感知故障。处理外部感知故障一直是机器人技术中的一个难题。我们的方法为在复杂环境中稳健部署自主机器提供了一个通用框架。

2. 结果

在野外实现快速且稳健的移动

我们在多种地形中部署了控制器，如图 1 和影片 1 所示。这包括高山、森林、地下和城市环境。控制器在所有部署中始终表现出鲁棒性，且实现了零跌倒。得益于外部感知能力，机器人能够预判地形并调整其运动，以实现快速而平稳的行走。这在需要高足部间隙的结构（如楼梯和大型障碍物）上尤为显著。机器人能够利用外部感知输入，征服了那些在先前的、未采用外部感知的研究中无法应对的地形 [4]。

ANYmal 成功穿越了具有陡峭坡度、湿滑表面、草地和雪地等挑战性的自然环境（图 1 A-J）。在这些条件下，机器人表现出极强的鲁棒性，即便在遮挡和高反射率等表面特性阻碍外部感知时也是如此。我们的控制器同样在含有松散砾石、沙土、灰尘、积水和有限光照的地下环境中稳健运行（图 1 K-N）。

城市环境也带来了重要挑战（图 1 O-R）。在跨越楼梯方面，波士顿动力公司的最先进四足机器人 Spot 需要启用专用模式，并且机器人必须正确对准楼梯方向 [p. 33 44]。相比之下，我们的控制器无需任何特殊模式即可应对楼梯，能够以任意方向和姿态自然穿越楼梯，例如侧向、斜向以及在楼梯上转身。参见影片 S1，了解我们的控制器在任意方向上实现平滑且稳健的楼梯穿越演示。

控制器在面对不同挑战的组合时也表现出鲁棒性，如图 1R 中楼梯上的雪所示。雪使得楼梯变得湿滑，并导致外部感知数据不完整和错误。深度传感器要么因雪的高反射性而失效，要么将表面轮廓估计在雪的顶部，而机器人的腿却沉入雪下。雪中的脚部打滑还可能导致运动学姿态估计出现较大漂移 [47]，使得地图更加不一致。尽管如此，控制器始终保持一致的鲁棒性，在此情况下也实现了零失败。

阿尔卑斯山徒步之旅

为了进一步评估我们控制器的鲁棒性，我们在瑞士的埃策尔山上进行了一次徒步实验，测试 ANYmal 是否能够完成一小时的徒步环线。徒步路线全长 2.2 公里，海拔上升 120 米。完成这条路线需要穿越陡峭的斜坡、高台阶、岩石表面、湿滑地面和树根（图 2）。如视频 2 所示，ANYmal 在没有任何故障的情况下完成了整个徒步，仅在修复脱落的鞋子和更换电池时短暂停下。机器人能够在 31 分钟内到达山顶，比官方指示牌上预期的人类徒

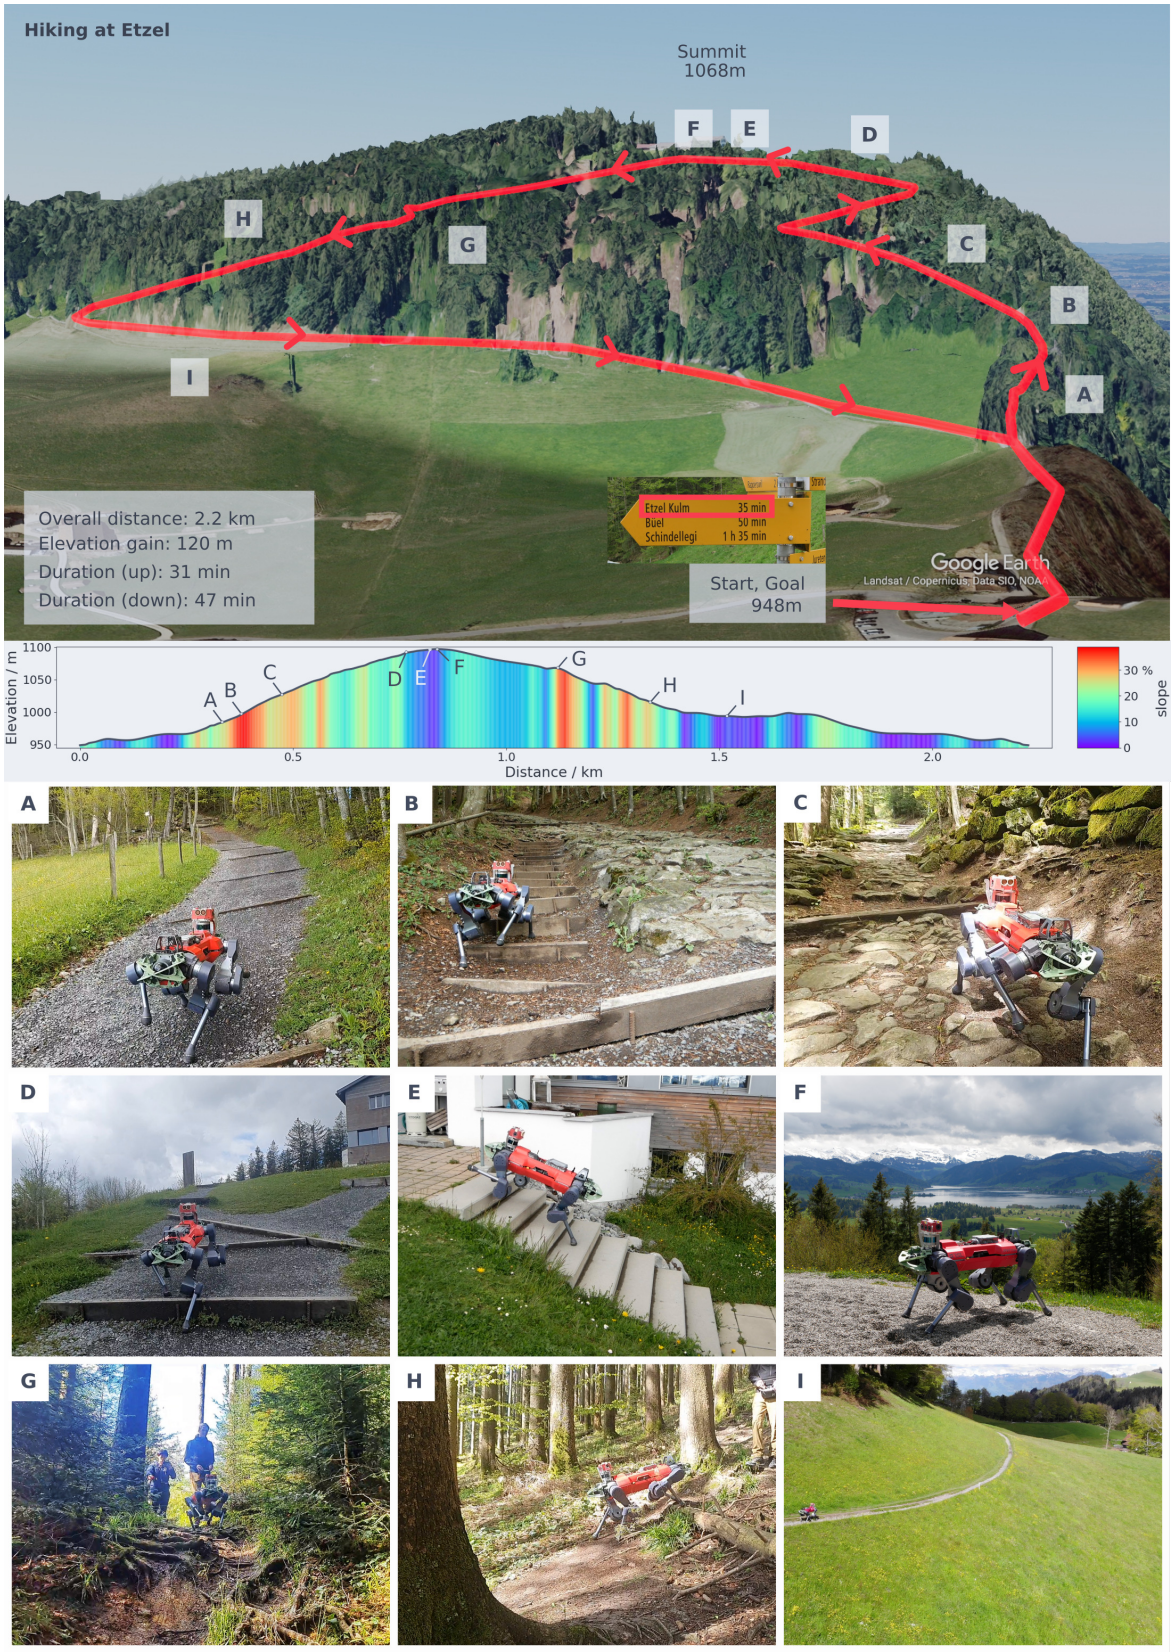


Fig. 2. 在瑞士的埃策尔山上，ANYmal 凭借我们的 Locomotion Controller 完成了一次徒步。这条 2.2 公里的路线——包含 120 米的海拔提升和高达 38% 的坡度——涵盖了多种具有挑战性的地形。ANYmal 比官方标识所示的人类用时更快地登顶，并以几乎与徒步指南 [46] 给出的时间相同的速度完成了全程。

步时间（35 分钟，如图 2 所示）更快，并在 78 分钟内完成了整个路线——几乎与徒步规划器建议的时长（76 分钟）相同，该规划器将此次徒步评为“困难” [46]。难度等级从“简单”、“中等”和“困难”中选择，通过结合所需的体能水平、运动类型和技术复杂性计算得出 [48]。

在徒步过程中，控制器面临了各种挑战。上坡路径的倾斜度高达 38%，且路面多石且湿滑（图 2 (B-C)）。在下坡穿越森林时，树根形成了复杂的障碍，地面非常滑（图 2 (G-H)）。

机器人上方的植被有时会在估计的高程图中引入严重的伪影。尽管面临诸多挑战，机器人还是在没有人类帮助且未发生一次跌倒的情况下完成了徒步。

外感受性挑战

本节探讨了在外部感知面临挑战的条件下，机器人如何感知地形。机器人通过从点云输入构建的高程图中获取高度样本来感知环境，如图 3A 所示。我们在部分实验中使用了 LiDAR（图 3D-G），在其他实验中则采用了主动立体相机（图 3B,C），以测试控制器对不同感知模态的鲁棒性。

我们在许多情况下发现，外部感知提供的输入可能不完整或具有误导性。如图 3 B-G 所示，由于感知故障、2.5D 高度图表示的局限性或机载传感视角的限制，估计的高程图可能不可靠。

由于多数深度传感器依赖光线来推算距离，无论是通过飞行时间测量还是立体视差法，它们在面对反射或半透明表面时普遍表现欠佳。图 3B 展示了一次此类传感失效的情况，其中反射性的金属地板导致了显著的深度异常值，这些异常值在高度图中呈现为一条沟壑。图 3C 则展示了在雪地环境下的传感失效实例。由于雪具有高反射性且缺乏纹理特征，立体相机无法准确推断距离，最终生成了空白地图。

2.5D 高程图表示无法准确表示如树枝或低矮天花板等悬垂物体 [17]。这些物体被整合到高度场中，并被错误地表示为高大的障碍物（图 3D）。此外，由于地图无法区分刚性或软性材料，在软质植被或深雪中，地图提供了误导性信息（图 3E）。

由于滑移或可变形表面违反了运动学姿态估计器通常采用的稳定立足点假设，导致里程计漂移 [47]。由于地图构建依赖于此类姿态估计来配准连续输入的点云，因此在此类情况下地图变得不准确（图 3F）。此外，由于传感器仅位于机器人本体上，结构背后的区域被遮挡，未在地图中呈现，这在爬坡行走时尤为突出（图 3G）。

总体而言，我们的控制器能够优雅地应对所有这些具有挑战性的条件，未出现任何故障。信念状态估计量经过训练，能够评估外部感知信息的可靠性，并尽可能加以利用。当外部感知信息不完整、有噪声或具有误导性时，控制器总能优雅地退化为本体感知运动，这已被证明具有鲁棒性 [4]。因此，该控制器旨在实现两全其美：在外部感知信息有用时实现快速预测运动，而在其不可靠时无缝保持本体感知控制的鲁棒性。

评估外感受的作用

我们进行了控制实验，以定量评估外感受的贡献。我们将我们的控制器与不使用外感受的本体感受基准 [4] 进行了比较。

首先，我们对比了机器人克服固定高度台阶的成功率，如图 4A 所示。在机器人前方放置了不同高度（从 12 厘米到 36.5 厘米）的木制台阶，机器人以固定速度指令对每个台阶进行 10 次试验。若机器人在 5 秒内成功跨越台阶，则该次试验被视为成功。

在 20 厘米台阶高度时，本体感知基准的成功率显著下降，原因是前腿频繁在台阶处受阻（图 4B）。即便前腿成功跨越台阶，后腿也常未能完全踏上。相比之下，我们的控制器则能稳定穿越高达 30.5 厘米的台阶。由于控制器能预判台阶的存在，它无需先进行物理接触便抬高腿部，并通过身体前倾使后腿顺利摆过台阶（图 4A）。在此高度以下，主要失败原因是机器人选择侧向避让而非直接跌落。当面对超过 32 厘米的台阶时，控制器会犹豫不前，因为它已学成此类高度的台阶接近或超出机器人的物理极限，可能导致高昂代价。

我们还在一门障碍课程中测试了这两个控制器，如图 4C,D 所示。在此实验中，机器人被赋予了一条固定的路径以跨越障碍物，并使用纯追踪控制器 [49] 进行跟踪。该路径穿越了多种类型的障碍物——一个倾斜平台、一个抬高的平台、楼梯以及一堆方块。平台高 20 厘米，楼梯每级高 17 厘米、深 29 厘米，方块的高度和深度均为 20 厘米。我们的控制器无需任何辅助便顺利跟随了给定路径，如图 4C 所示。外感知提供了即将到来障碍物的预先信息，使得控制器能够在机器人接触障碍物之前调整其运动，从而实现了快速且平滑地通过障碍课程。相比之下，基准控制器在没有人工协助的情况下未能跟踪路径。在执行过程中，它在所有三个障碍物上都卡住了，我们不得不抬起并推动机器人以继续实验（图 4D）。

此外，我们测量了两种控制器在平坦地面和存在障碍物情况下的最大运动速度。图 4E 展示了实验设置。我们向控制器发出恒定的前进、侧移或转向指令，并记录在平坦地面和跨越 20 厘米台阶时的速度。需要注意的是，基准控制器仅接收方向指令，并学习在指定方向上尽可能快地行走 [4]。我们的控制器在平坦地面上的前进和侧移速度达到了 1.2 m/s，而基准控制器仅能达到 0.6 m/s。在跨越障碍物时，这一差异更加显著。我们的控制器能够无障碍地通过障碍物，而基准控制器则受阻。在转向速度方面，基准策略与我们的策略之间展现出最大差异。我们的控制器能以 3 rad/s 的速度转向，而基准策略仅能达到 0.6 rad/s，相差五倍。

这些结果表明，我们的控制器相较于本体感知基准有明显优势。通过外感知，控制器能够更成功地穿越复杂环境，并且速度比纯本体感知时更快。补充部分 S2 中提供了进一步的定量性能评估。

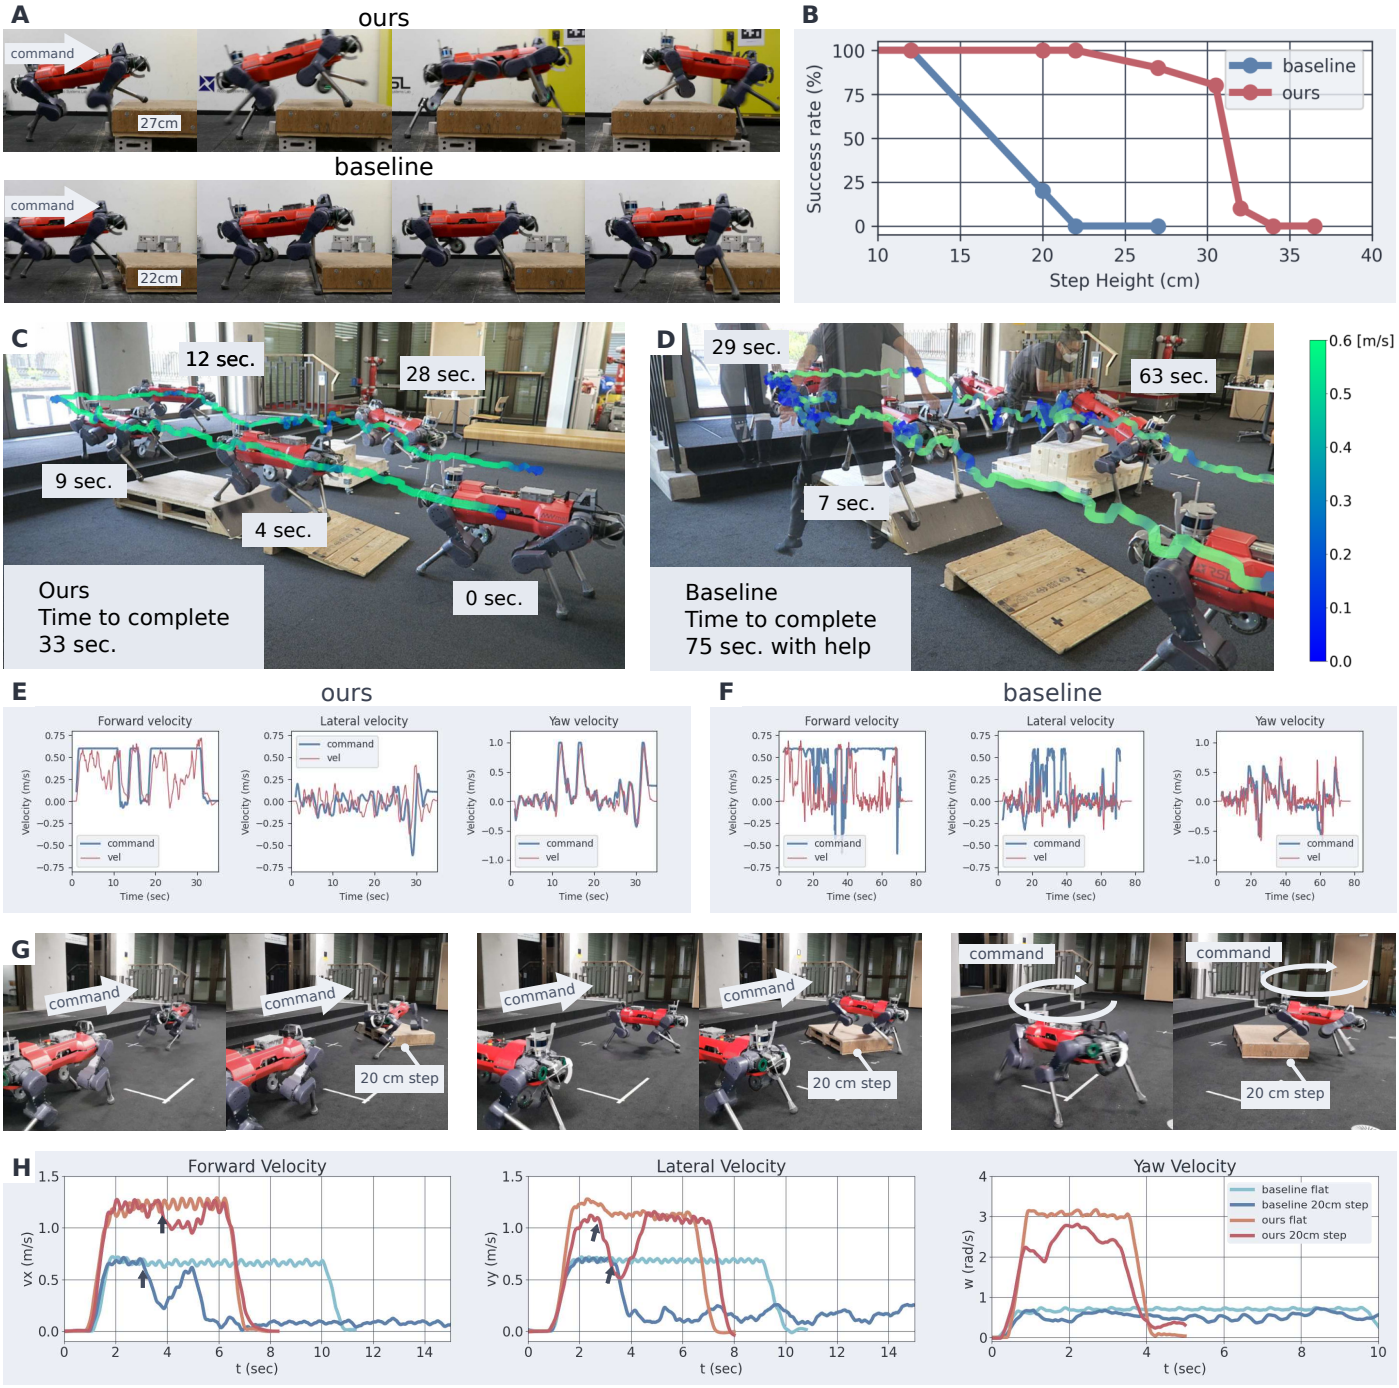
通过信念状态可视化评估鲁棒性

为探究我们的控制器如何整合本体感知与外感知，我们开展了一系列对照实验。实验中，我们选用了两种能提供模糊或误导性外感知信息的障碍物：一种看似坚固实则无法承重的不透明泡沫障碍物，以及一种实心但透明的障碍物。我们将每种障碍物置于机器人前方，并指令机器人以恒定速度向前行走。

传感器将泡沫块感知为固体，机器人因此准备踩踏其上，但



Fig. 3. 我们的运动控制器通过从高程地图（A）中获取的高度样本（红点）感知环境。该控制器对实地常见的多种感知挑战具有鲁棒性：因传感故障导致的地图信息缺失（B、C、G），以及因非刚性地形（D、E）和姿态估计漂移（F）引起的误导性地图信息。


A
ours
command
27cm
baseline
command
22cm
B
Success rate (%)
Step Height (cm)
baseline
ours
C
12 sec.
28 sec.
9 sec.
4 sec.
0 sec.
Ours
Time to complete
33 sec.
D
29 sec.
63 sec.
7 sec.
Baseline
Time to complete
75 sec. with help
0.6 [m/s]
E
ours
Forward velocity
Lateral velocity
Yaw velocity
Velocity (m/s)
Time (sec)
command
vel
F
baseline
G
command
20 cm step
H
Forward Velocity
Lateral Velocity
Yaw Velocity
vx (m/s)
vy (m/s)
w (rad/s)
t (sec)
baseline flat
baseline 20cm step
ours flat
ours 20cm step

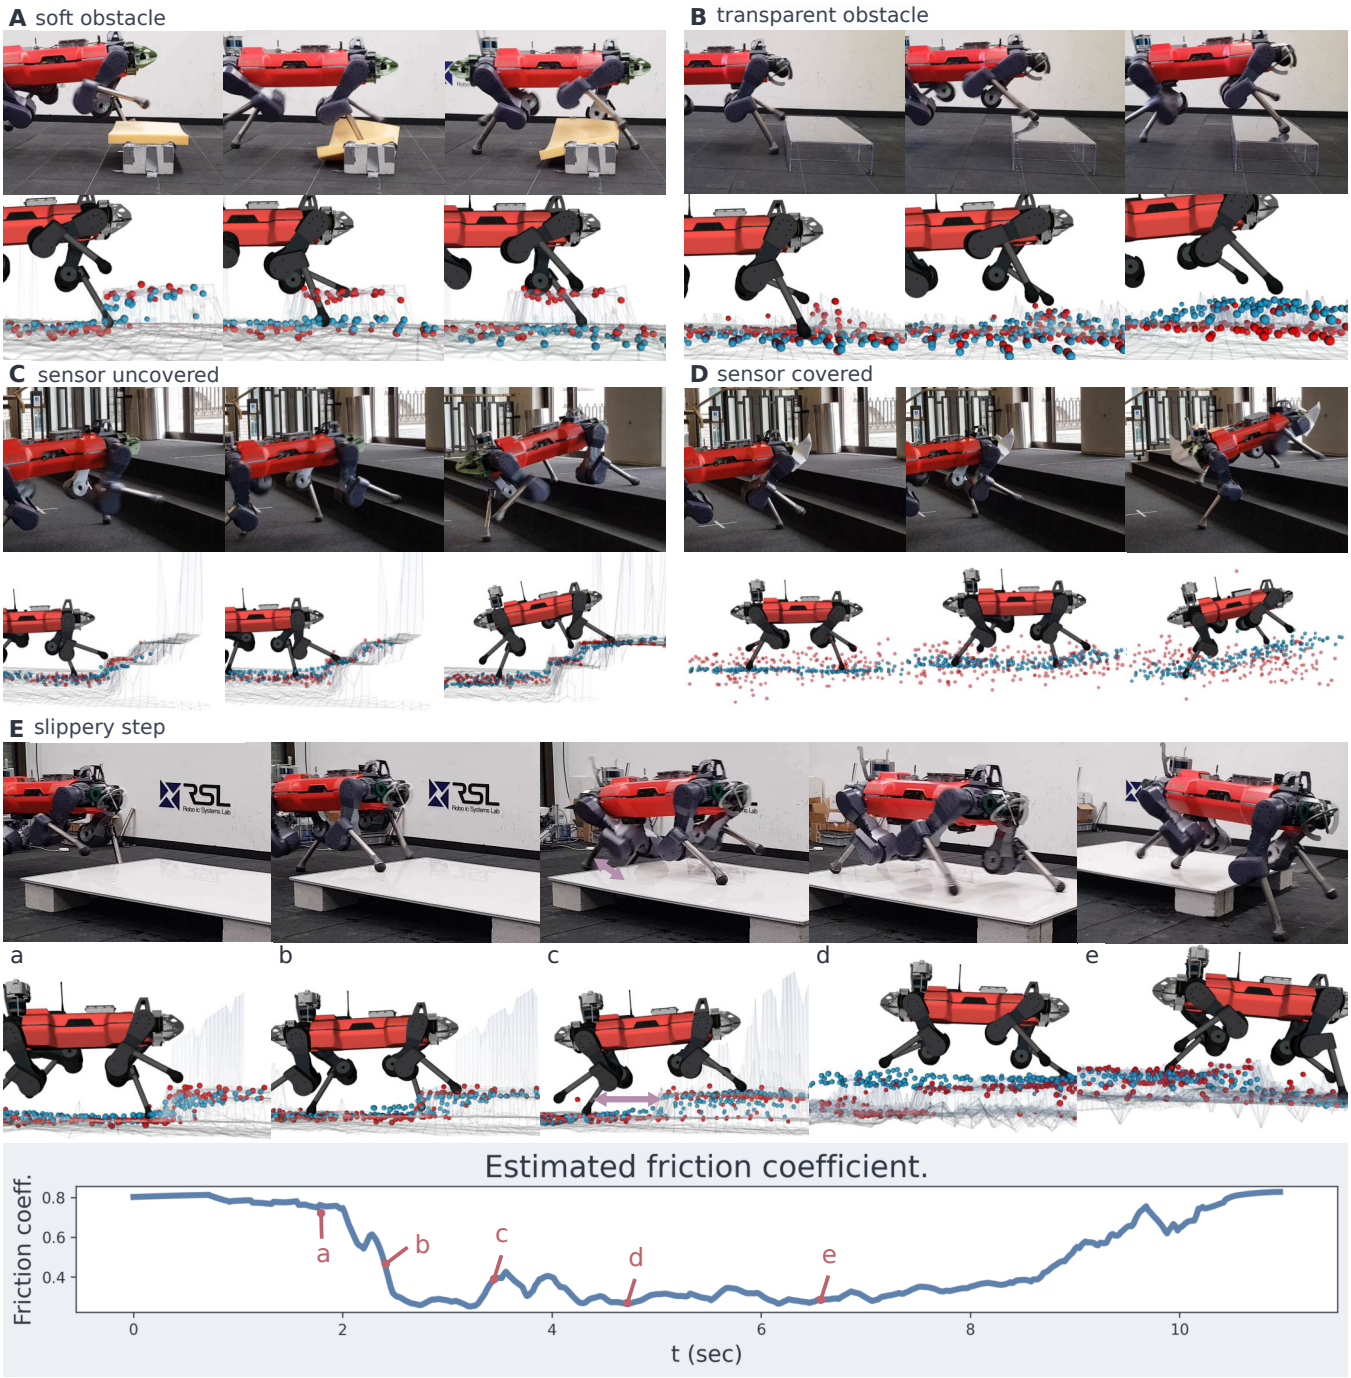


Fig. 4. 感知失败期间使用学成信念解码器进行内部状态信念检查。红点表示作为策略输入的高度样本。蓝点显示控制器对地形轮廓的内部估计。(A) 踩上无法支撑立足点的软障碍物后，策略正确下调了对地形轮廓的估计。(B) 透明障碍物在接触后被正确纳入地形轮廓。(C) 在传感器正常工作时，机器人迅速而优雅地攀爬楼梯，无任何异常接触。(D) 当传感器被遮蔽导致机器人“失明”时，策略虽无法预知地形，但仍保持稳健并成功穿越楼梯。(E) 踏上湿滑平台时，策略识别出低摩擦并补偿了由此引发的姿态估计漂移。图中展示了解码得到的摩擦系数。

由于泡沫变形未能获得稳定的立足点。图 5A 展示了机器人在遇到误导性障碍时，其内部信念状态（蓝色）如何被修正：控制器最初信任外部感知输入（红色），但在接触后迅速修正了对地形高度的估计。一旦形成正确的信念，即便脚部离开地面，该信念仍被保留，这表明控制器因其循环结构而保留了过往信息。

透明障碍物是由透明亚克力板构成的块体，机载传感器未能准确识别（图 5B）。因此，机器人如同行走在平地上，直至触碰到台阶，此时它重新评估了地形轮廓，并相应调整了步态。

在接下来的实验中，我们通过物理覆盖传感器来模拟完全的外感受失效，使其完全无法提供信息（图 5C,D）。机器人被指令上下两级楼梯。当传感器未被遮挡时，控制器优雅地穿越楼梯，未与楼梯竖板发生任何意外接触，调整其落脚点与身体姿态以轻柔地走下楼梯。而当传感器被覆盖后，地图信息缺失，控制器接收到随机噪声作为输入。在此情况下，机器人触碰到了第一级楼梯的竖板，这一情况无法预先感知，随后它修正了对地形轮廓的估计，相应调整了步态，并成功攀爬上了楼梯。在下行过程中，失去“视觉”的机器人前脚着地较为生硬，但仍保持平衡，并用后腿轻柔地踏下。

最后，我们测试了机器人在高湿滑表面上的移动性能（图 5E）。当机器人踏上湿滑平台后，它检测到低摩擦力并调整步伐加快以保持平衡。此时，脚部的短暂滑动违背了运动姿态估计量的前提假设，进而导致估计的高度地图失稳，使外部感知信息在此阶段失效。控制器无缝切换至依赖本体感知，直至估计的高度地图恢复稳定，外部感知信息重新变得有效。

3. 讨论

我们提出了一种快速且鲁棒的四足运动控制器，专为复杂地形设计。该控制器无缝整合了外部感知与本体感知输入。通过外部感知，机器人能够预见地形并相应调整步态，在接触前实现快速而优雅的环境穿越。当外部感知存在误导、不完整或完全缺失时，控制器能平稳过渡至本体感知模式。无论在何种条件下，包括机器人处于“盲态”时，控制器均保持高度鲁棒性。外部与本体感知的整合是通过端到端学习实现的，无需任何手动编码规则或启发式方法。由此诞生的，是首个结合了基于视觉运动的速度与优雅，以及本体感知高鲁棒性的崎岖地形腿式运动控制器。

速度与高鲁棒性的这种组合已通过控制实验和在野外的广泛部署得到验证，包括在阿尔卑斯山一条被评为“困难”级的长达一小时的徒步路线 [46]。

整个路线由机器人在没有人类协助的情况下（除了重新安装一只脱落的鞋子和更换电池）完成，所用时间为人类徒步者完成此路线的推荐时间。

我们的工作拓展了腿式机器人的操作领域，并为自主导航开辟了新前沿。导航规划器在自主操作期间不再需要识别地面类型或切换模式。我们的控制器被用作团队 Cerberus 在 DARPA 地下挑战赛任务中的默认控制器，该团队在决赛中荣获一等奖 [50, 51]。在此挑战中，我们的控制器驱动 ANYmals 在具有崎岖地形、障碍物以及因尘埃、雾气、水和烟雾导致感知能力下降的地下环境中长时间自主操作 [53]。我们的控制器发挥了关键作用，使四台 ANYmals 在隧道、城市和洞穴三种类型的赛道中探索超过 1700 米，且无一跌倒 [52]。

可能的扩展

未来工作可明确利用信念状态中的不确定性信息。当前，策略仅隐式地运用不确定性来估算地形。例如，面对狭窄悬崖或踏脚石时，由于遮挡，高程图无法提供足够信息，因此策略假设地表连续，可能导致机器人踏空坠落。显式估算不确定性或使策略在外部感知输入不可靠时更为谨慎，如用脚探测地面以确认其稳固性。此外，我们当前实现通过高程图这一中间状态获取感知信息，而非直接处理原始传感器数据，这使模型独立于特定外部传感器（我们在不同部署中使用 LiDAR 和立体相机，无需重新训练或微调）。然而，高程图表示法忽略了原始感官输入中可能存在的细节，这些细节可能包含有关材质和纹理的额外信息。再者，我们的高程图构建依赖于一个未与系统其余部分联合训练的经典位姿估计模块。将原始感官输入的处理恰当地融入网络，可能进一步提升控制器的速度与鲁棒性。同时，可学习一个遮挡模型，使策略理解悬崖后方存在遮挡，从而避免踏空。另一局限在于无法完成与常规行走差异显著的移动任务，如从狭窄洞穴中抽出卡住的腿或攀爬至高台。

4. 材料与方法

概述

我们在仿真环境中训练了一个神经网络策略，随后实现了 zero-shot 的仿真到现实迁移。我们的方法包含三个阶段，如图 6 所示。

首先，使用RL训练一个教师策略，使其能够在随机生成的地形上跟随随机目标速度，并应对随机干扰。该策略能够访问特权信息，如无噪声地形测量、地面摩擦以及引入的干扰。

在第二阶段，学生策略被训练以复现教师策略的动作，但无需使用特权信息。学生策略通过一个循环编码器构建信念状态来捕捉未观测到的信息，并基于此信念状态输出动作。在训练过程中，我们利用两种损失：行为克隆损失和重构损失。行为克隆损失旨在模仿教师策略，而重构损失则激励编码器生成富含信息的内部表示。

最终，我们将学成的学生策略迁移到实体机器人上，并利用其搭载的传感器在现实世界中部署。机器人通过整合来自机载传感器的深度数据构建高程图，并从该高程图中采样高度读数，形成策略的外感知输入。这一外感知输入与本体感知数据结合后，馈入神经网络，由神经网络生成执行器指令。

问题表述

我们将控制问题表述为离散时间动态，其中环境完全由时间步 t 的状态 s_t 定义。策略执行动作 a_t 并通过观察模型 $\mathcal{O}(o_t|s_t,a_t)$ 生成的 o_t 来观察环境。随后，环境以转移概率 $P(s_{t+1}|s_t,a_t)$ 转移到下一个状态 s_{t+1}，并返回奖励 r_{t+1}。

当所有状态都是可观测的，即 $o_t = s_t$，这可以被视为一个 Markov Decision Process (MDP)。然而，当存在不可观测的信息

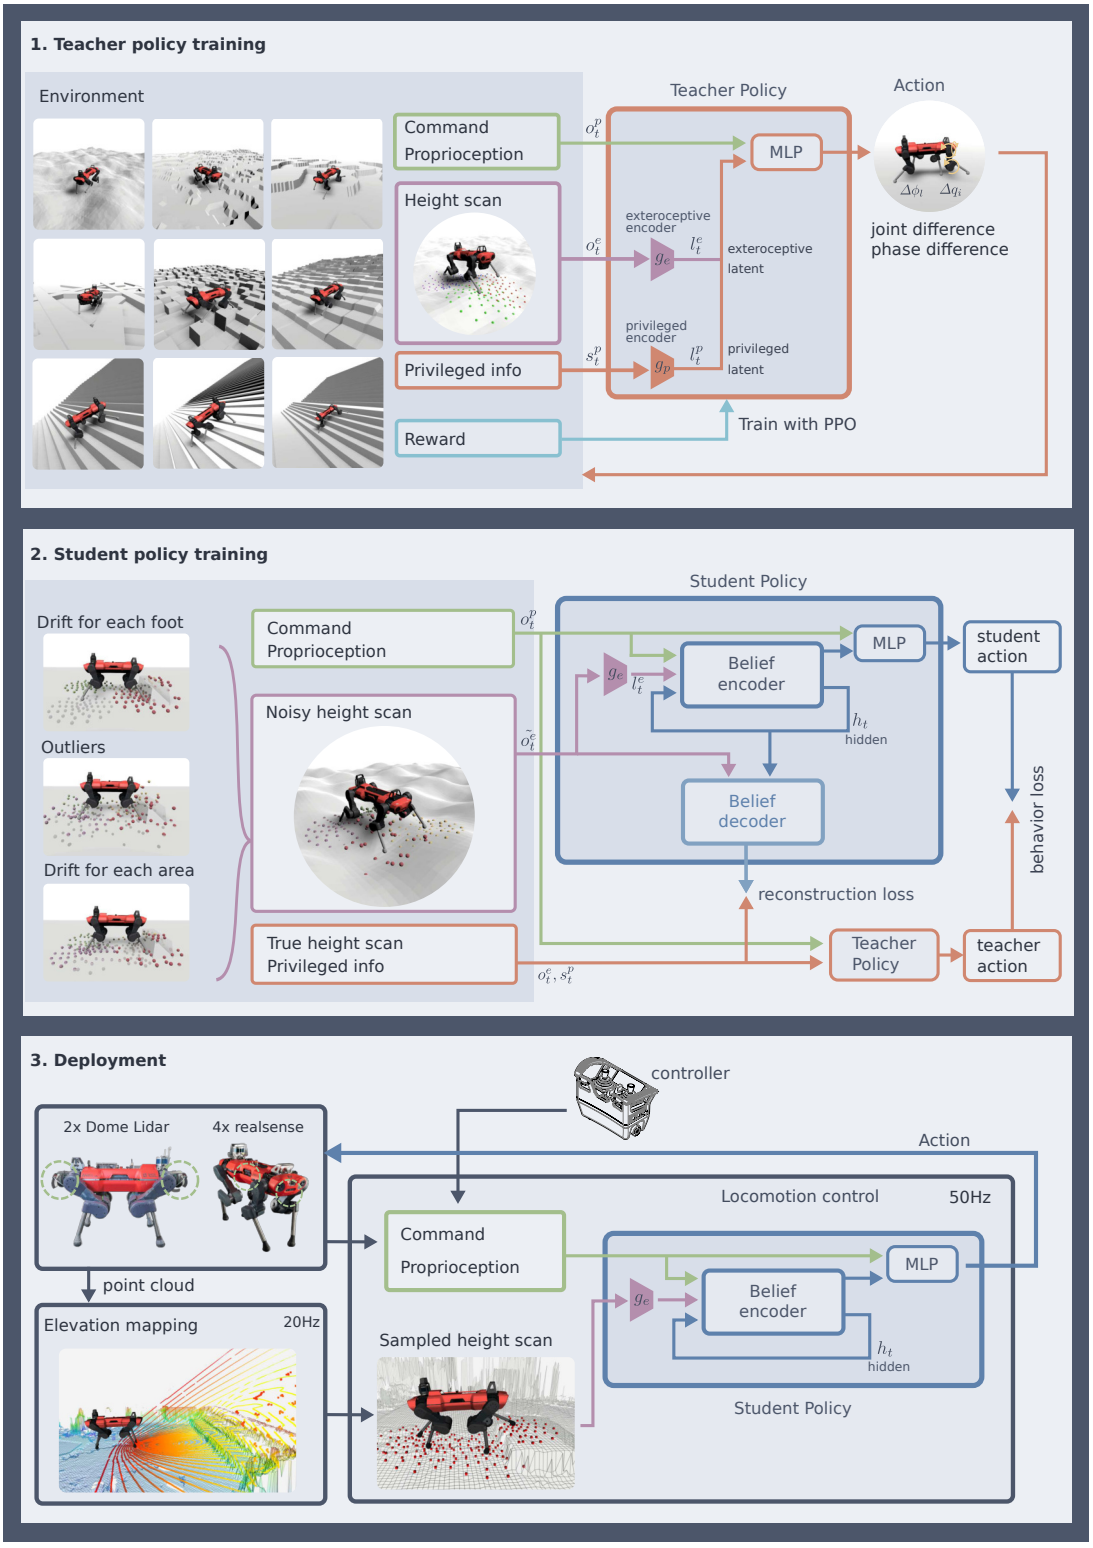


Fig. 5. 训练方法与部署概览。我们首先利用强化学习（RL）基于特权仿真数据训练一个教师策略。随后，将该教师策略蒸馏至学生策略中，后者被训练以模仿教师的动作，并从噪声观测中重建真实环境状态。最终，我们采用机器人中心高度图提供的样本，在真实硬件上 zero-shot 部署学生策略。

时，例如外部力或我们案例中的完整地形信息，动态被建模为一个 Partially Observable Markov Decision Process (POMDP)。

RL 目标是找到一种策略 π^*，以最大化未来轨迹上的期望折扣奖励，使得

$$\pi^* = \underset{a}{\operatorname{argmax}}\, \mathbb{E}[\sum_{t=0}^{\infty} \gamma^t r_t].$$

许多RL算法已被开发用于解决完全可观测的 MDP 问题，并可直接用于训练。然而，POMDP 的情况更具挑战性，因为状态并非完全可观测。通常通过从观测历史 $\{o_0, \cdots, o_t\}$ 中构建信念状态 b_t 来尝试捕捉完整状态。在深度强化学习中，这通常通过堆叠一系列先前观测 [54] 或使用能够压缩过去信息的架构（如Recurrent Neural Networks (RNNs) [55, 56] 或Temporal Convolutional Networks (TCNs) [4, 57]）来实现。

从头开始训练一个处理序列数据的复杂神经网络策略可能耗时较长 [4]。因此我们采用特权学习 [45]，其中首先使用特权信息训练一个教师策略，然后通过监督学习将教师策略蒸馏到学生策略中。

训练环境

我们使用 RaiSim [58] 作为模拟器来构建训练环境。在该环境中，我们并行模拟多个 ANYmal-C 机器人在随机生成的崎岖地形上运动，并集成了执行器模型 [3] 以缩小现实差距。

地形

我们将参数化地形定义如图 6.1 所示。该地形被建模为高度图；更多细节见补充章节 S4。

除了由多种坡度和台阶构成的地形外，我们还在训练环境中模拟了四种不同类型的楼梯：标准型、开放式、带平台型及随机型。我们采用箱体搭建楼梯，这是因为基于高度图建模的楼梯踏步并非完全垂直；我们观察到，在仿真中策略会利用这些非垂直的边缘，导致仿真到现实的迁移效果不佳。

领域随机化

在每一回合中，我们随机化机器人躯干与腿部的质量、初始关节位置与速度，以及初始身体朝向与速度。此外，还会对机器人躯干施加外力和扭矩，并偶尔将足部摩擦系数设为较低值以引入滑动现象。

终止

当机器人达到不良状态时，我们终止当前训练回合并开启新的一轮。终止标准包括：机身与地面发生碰撞、机身倾斜过大，以及执行器关节扭矩超出限制。这些标准有助于塑造运动模式，确保行为满足约束条件。

教师策略训练

在训练的第一阶段，我们的目标是找到一个最优的参考控制策略，该策略能够访问完美的特权信息，并使得 ANYmal 能够在随机生成的地形上遵循期望的命令速度。期望命令被随机生成为向量 $\boldsymbol{v}_{des} \in \mathbb{R}^3 = (v_x, v_y, w)$，其中 v_x, v_y 表示纵向和横向速度，w 表示偏航速度，所有这些都在机器人的本体坐标系中。

我们使用Proximal Policy Optimization (PPO) [59] 来训练教师策略。教师被建模为一个高斯策略 $a_t \sim \mathcal{N}(\pi_\theta(o_t = s_t), \sigma I)$，其中 π_θ 通过一个由 θ 参数化的多层感知机（MLP）实现，σ 表示每个动作的方差。

观察与行动

教师观察定义为 $o_t^{teacher} = (o_t^p, o_t^e, s_t^p)$，其中 o_t^p 表示本体感知观察，o_t^e 表示外部感知观察，s_t^p 表示特权状态。o_t^p 包含身体速度、方向、关节位置和速度历史、动作历史以及每条腿的相位。o_t^e 是围绕每只脚的五个不同半径的高度样本向量。特权状态 s_t^p 包括接触状态、接触力、接触法线、摩擦系数、大腿和小腿的接触状态、施加在身体上的外力和扭矩，以及摆动相持续时间。

我们的动作空间受到中枢模式生成器（CPGs）[4] 的启发。每条腿 $l = \{1, 2, 3, 4\}$ 保持一个相位变量 ϕ_l，并根据相位定义一条名义轨迹。该名义轨迹是足尖的步进运动，我们使用逆运动学计算每个关节执行器 $i = \{1, \cdots, 12\}$ 的名义关节目标 $q_i(\phi_l)$。策略输出的动作是相位差 $\Delta\phi_l$ 和剩余关节位置目标 Δq_i。观测和动作空间的更多细节见补充材料 S5 节。

策略架构

我们将教师策略 π_θ 建模为一个 MLP。它由三个 MLP 组件组成：外感受编码器、特权编码器和主网络，如图 6 所示。外感受编码器 g_e 接收 o_t^e 并输出一个较小的潜在表示 l_t^e：

$$l_t^e = g_e(o_t^e)$$

特权编码器 g_p 接收特权状态 s_t^p 并输出潜在表示 l_t^{priv}：

$$l_t^{priv} = g_p(s_t^p)$$

这些编码器将每个输入压缩为更紧凑的表示，并促进学生策略对教师策略组件的部分重用。各层的更多细节见补充材料 S6 部分。

奖励

我们为遵循指令速度设定正向奖励，并为违反某些既定约束设定负向奖励。指令遵循的奖励定义如下：

$$r_{command} = \begin{cases} 1.0, & \text{if } \boldsymbol{v}_{des} \cdot \boldsymbol{v} > |\boldsymbol{v}_{des}| \\ \exp(-(\boldsymbol{v}_{des} \cdot \boldsymbol{v} - |\boldsymbol{v}_{des}|)^2), & \text{otherwise} \end{cases} \quad (1)$$

其中 $\boldsymbol{v}_{des} \in \mathbb{R}^2$ 是期望的水平速度，$\boldsymbol{v} \in \mathbb{R}^2$ 是相对于机体坐标系的当前水平机体速度。相同的奖励也应用于偏航指令。我们惩罚与期望速度正交的速度分量以及围绕滚转、俯仰和偏航的机体速度。此外，我们使用塑造奖励来优化机体姿态、关节扭矩、关节速度、关节加速度、足部打滑以及小腿和膝盖碰撞。

采用身体朝向奖励来避免身体出现异常姿态。关节相关奖励项用于防止动作过于激进。足部滑动和碰撞奖励项则旨在规避这些问题。我们通过观察策略在仿真中的表现来调整这些奖励项。除了移动性能外，我们还检查了运动的流畅性。所有奖励项的具体说明详见补充材料 S7 部分。

课程

我们采用两种课程来随着策略性能的提升逐步增加难度。一种课程通过自适应方法调整地形难度 [4]，另一种则利用对数几率函数改变诸如奖励或施加干扰等元素 [3]。

对于地形课程，粒子滤波器更新地形参数，确保它们在策略训练的任何阶段都保持具有挑战性但可实现 [4]。

第二课程将领域随机化的幅度及部分奖励项（关节速度、关节加速度、姿态、滑动、大腿与小腿接触）乘以一个单调递增且渐近趋近于 1 的因子：

$$c_{k+1} = (c_k)^d,$$

其中 c_k 是第 k 次迭代时的课程因子，$0 < d < 1$ 是收敛率。

学生策略训练

在我们训练出一个能够借助特权信息穿越各种地形的教师策略后，我们将其蒸馏成一个学生策略，该策略仅能访问真实机器人上可用的信息。我们使用与教师策略相同的训练环境，但在学生高度样本观测中添加了额外的噪声：$o_t^{student} = (o_t^p, n(o_t^e))$，其中 $n(o_t^e)$ 是应用于高度样本输入的噪声模型。该噪声模型模拟了在实地部署过程中经常遇到的外感知的不同故障情况，具体细节如下。

当外部感知中存在大量噪声时，其变得不可观测，因此动态过程被视为部分可观测马尔可夫决策过程（POMDP）。此外，由于缺乏直接测量的传感器，特权状态也无法被观测到。因此，策略需考虑序列相关系数以估计不可观测状态。我们提出采用循环信念状态编码器，结合外部感知与本体感知的序列信息，将不可观测状态估计为信念状态。

学生策略由一个循环信念状态编码器和一个多层感知机（MLP）组成，如图 6.2 所示。我们用 h_t 表示循环网络的隐状态。信念状态编码器接收 $o_t^{student}$ 和 h_t 作为输入，并输出一个潜在向量 b_t，我们称之为信念状态。目标是将信念状态 b_t 与教师策略的特征向量 (l_t^e, l_t^{priv}) 相匹配，后者编码了所有与运动相关的信息。随后，我们将 o_t^p 和 b_t 传递给 MLP，以计算输出动作。

MLP 结构保持与教师策略一致，以便我们能够复用教师策略中学成的权重来初始化学生网络，从而加速训练过程。

训练以监督方式进行，通过最小化两种损失：行为克隆损失和重构损失。行为克隆损失定义为在相同状态和命令下，学生动作与教师动作之间的平方距离。重构损失是无噪声高度样本与特权信息 (o_t^e, s_t^p) 及其从信念状态重构之间的平方距离。我们通过展开学生策略生成样本来提高鲁棒性 [60, 61]。

高度样本随机化

在学生训练过程中，我们使用参数化噪声模型 $n(\tilde{o_t^e}|o_t^e, z)$，$z \in \mathbb{R}^{8\times4}$ 向高度样本中注入随机噪声。在采样高度时，我们应用了两种不同类型的测量噪声，如图 7A 所示：

1. 横向移动扫描点。
2. 扰动高度值。

每个噪声值均从高斯分布中采样，噪声参数 z 定义了方差。两种类型的噪声在三个不同的范围内应用，每个范围都有其自身的噪声方差：每个扫描点、每只脚和每个回合。每个扫描点和每只脚的噪声值在每个时间步重新采样，而回合噪声对于所有扫描点保持不变。

此外，我们定义了三个映射条件及其相关的噪声参数 z，以模拟地图质量的变化和误差来源，如图 7B 所示。

1. 常规运行中，假设地图质量良好时的标称噪声。
2. 通过高每英尺噪声模拟地图偏移，以反映姿态估计漂移或可变形地形的影响。
3. 为每个扫描点设置较大的噪声幅度，以模拟因遮挡或测绘失败导致的地形信息完全缺失。

这三种映射条件在每轮训练开始时以 60%、30% 和 10% 的比例进行选择。

最后，我们将每个训练地形划分为单元，并根据样本采集自哪个单元，为高度样本添加一个额外的偏移量。这模拟了具有不同地形特征区域之间的转移，例如植被和深雪。参数向量 z 也是学习课程的一部分，其大小随着训练持续时间线性增加。

高度样本的表示在补充章节 S8 中有更详细的说明。

信念状态编码器

循环信念状态编码器对不可直接观察的状态进行编码。为了整合本体感受和外感受数据，我们引入了一个门控编码器，如图 7C 所示，其灵感来源于门控RNN模型 [62, 63] 和多模态信息融合 [64–66]。

编码器学习一个自适应门控因子，用于控制通过多少外部感知信息。首先，本体感知 o_t^p、来自噪声观测的外部感知特征 $l_t^e = g_e(\tilde{o_t^e})$ 和隐状态 s_t 被 RNN 模块编码为中间信念状态 b'_t。然后，从 b'_t 计算注意力向量 α，它控制进入最终信念状态 b_t 的外部感知信息量。

$$\begin{aligned} b'_t, h_{t+1} &= \mathrm{RNN}(o_t^p, l_t^e, h_t) \\ \alpha &= \sigma(g_a(b'_t)) \\ b_t &= g_b(b'_t) + l_t^e \odot \alpha \end{aligned}$$

此处，g_a 和 g_b 是全连接神经网络，$\sigma(\cdot)$ 是 Sigmoid 函数。

在解码器中，同一门被用来重构特权信息及高度样本（图 7D）。这一过程用于计算重构损失，旨在促使信念状态捕捉关于环境的真实信息。

我们使用 Gated Recurrent Unit (GRU) [62] 作为我们的 RNN 架构。门结构有效性的评估在补充部分 S9 中展示。

部署

我们在 ANYmal C 机器人上部署了控制器，并采用了两种不同的传感器配置：一种是使用两个 Robosense Bpearl [67] 穹顶激光雷达传感器，另一种是使用四个 Intel RealSense D435 深度相机 [68]。我们的策略在 PyTorch [69] 中进行了训练，并以 zero-shot 方式直接部署到机器人上，未进行任何微调。我们通

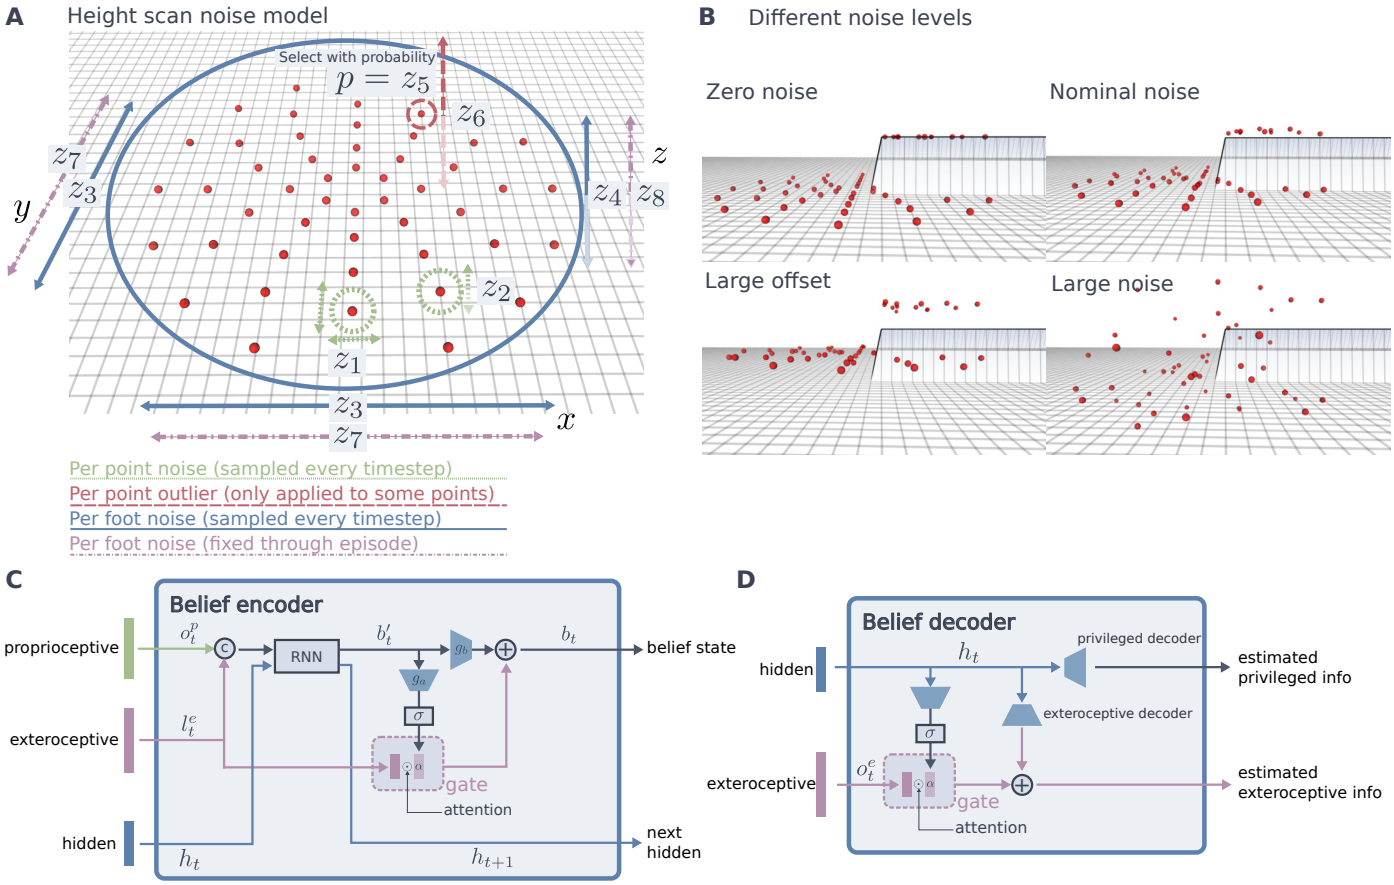


Fig. 6. 稳健地形感知组件的详细信息。(A) 在学生训练期间，向高度样本添加随机噪声。噪声从高斯分布 $\mathcal{N}(0, z^l \in \mathbb{R}^8)$ 中采样，其中每个 z_i^l 控制每条腿 l 的不同噪声分量 i。(B) 我们使用多种噪声配置 z 来模拟不同的操作条件。在教师训练期间应用“零噪声”，而“标称噪声”代表学生训练期间的正常映射条件。“大偏移”噪声模拟由于姿态估计漂移或可变形地形表面导致的大地图偏移。“大噪声”模拟由于遮挡或传感器故障导致的地形信息完全缺失。(C) 学生策略信念编码器包含一个循环核心和一个注意力门，用于整合本体感受和外感受模态。该门显式控制通过哪些外感受数据方面。(D) 信念解码器有一个用于重建外感受数据的门。它仅在训练期间和用于信念状态的内省时使用。

过估计机器人的姿态并相应地注册来自传感器的点云数据，以 20 Hz 的频率构建了一个以机器人为中心的 2.5D 高程地图。策略以 50 Hz 的频率运行，并从最新的高程地图中采样高度，若在查询位置无地图信息可用，则填充一个随机采样的值。

我们开发了一种用于快速地形测绘的高程映射流水线，以在graphics processing unit (GPU)上并行化点云处理。我们采用与 Fankhauser 等人 [17] 类似的方法，以卡尔曼滤波的方式更新地图，并额外执行漂移补偿和光线投射，以获得更一致的地图。这一快速映射的实现对于保持高速处理速率并跟上我们控制器实现的快速运动速度至关重要。

5. 致谢

资助本项目部分由英特尔智能系统网络、瑞士国家科学基金会（SNF）通过国家机器人能力研究中心及项目编号 188596、欧洲研究理事会（ERC）根据欧盟“地平线 2020”研究与创新计划资助协议编号 852044、780883 和 101016970 提供支持。此项工作作为 ANYmal 研究的一部分进行，该社区致力于推动腿式机器人技术的发展。**作者贡献** T.M. 提出了结合多模态输入的核心构想。J.L. 和 J.H 设计并测试了初始设置。T.M. 开发了软件并训练了控制器。T.M. 和 L.W. 在机器人上搭建了感知流水线。T.M. 主导了大部分室内实验。T.M.、J.L. 和 L.W. 共同进行了户外实验。所有作者均参与了理念的完善、实验设计、数据分析及论文撰写。**利益竞争**作者声明不存在利益竞争。**数据与材料可用性**评估论文结论所需的所有数据均包含在论文或补充材料中。

补充材料

Section S1. Nomenclature
Section S2. Evaluating the importance of exteroception: simulation result
Section S3. Training details
Section S4. Terrain generation
Section S5. Observation and action
Section S6. Network architecture
Section S7. Reward function
Section S8. Height sample noise
Section S9. Belief encoder evaluation
Figure S1. Comparison of the presented controller to a proprioceptive baseline over random terrains
Figure S2. Ablation analysis of the presented belief encoder
Table S1. Hyperparameters for PPO
Table S2. Hyperparameters for student training
Table S3. Observations
Table S4. Action difference between teacher and student under two exteroceptive noise conditions.
Movie S1. Walking over stairs in different directions.
Movie S2. Baseline comparison.
Movie S3. Robustness evaluation.
Movie S4. Slippery surface and soft obstacle.

REFERENCES

1. M. Raibert, K. Blankespoor, G. Nelson, R. Playter, Bigdog, the rough-terrain quadruped robot, *IFAC Proceedings Volumes* 10822–10825 (2008).
2. B. Katz, J. Di Carlo, S. Kim, Mini cheetah: A platform for pushing the limits of dynamic quadruped control, *2019 International Conference on Robotics and Automation (ICRA)*, 6295–6301 (IEEE, 2019).
3. J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, M. Hutter, Learning agile and dynamic motor skills for legged robots, *Science Robotics* **4** (2019).
4. J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, M. Hutter, Learning quadrupedal locomotion over challenging terrain, *Science Robotics* **5** (2020).
5. H.-W. Park, P. M. Wensing, S. Kim, Jumping over obstacles with MIT Cheetah 2, *Robotics and Autonomous Systems* p. 103703 (2021).
6. Boston Dynamics, Spot, https://www.bostondynamics.com/spot (2021). [Online; accessed March-2021].
7. C. Gehring, P. Fankhauser, L. Isler, R. Diethelm, S. Bachmann, M. Potz, L. Gerstenberg, M. Hutter, ANYmal in the field: Solving industrial inspection of an offshore HVDC platform with a quadrupedal robot, *Field and Service Robotics*, 247–260 (Springer, 2021).
8. Agility Robotics, Robots, https://www.agilityrobotics.com/robots (2021). [Online; accessed June-2021].
9. Unitree Robotics, A1, https://www.unitree.com/products/a1/ (2021). [Online; accessed March-2021].
10. Ghost Robotics, Vision 60, https://www.ghostrobotics.io/ (2021). [Online; accessed June-2021].
11. J. S. Matthis, J. L. Yates, M. M. Hayhoe, Gaze and the control of foot placement when walking in natural terrain, *Current Biology* 1224–1233 (2018).
12. ANYbotics, ANYmal, https://www.anybotics.com/anymal-autonomous-legged-robot/ (2021). [Online; accessed June-2021].
13. P. Fankhauser, M. Bloesch, D. Rodriguez, R. Kaestner, M. Hutter, R. Siegwart, Kinect v2 for mobile robot navigation: Evaluation and modeling, *2015 International Conference on Advanced Robotics (ICAR)*, 388–394 (IEEE, 2015).
14. C. Ye, J. Borenstein, A new terrain mapping method for mobile robots obstacle negotiation, *Unmanned ground vehicle technology V*, 52–62 (International Society for Optics and Photonics, 2003).
15. D. Belter, P. Skrzypczyński, Rough terrain mapping and classification for foothold selection in a walking robot, *2010 IEEE Safety Security and Rescue Robotics*, 1–6 (2010).
16. P. Fankhauser, M. Bloesch, C. Gehring, M. Hutter, R. Siegwart. Robot-centric elevation mapping with uncertainty estimates. *Mobile Service Robotics* (World Scientific, 2014), 433–440.
17. P. Fankhauser, M. Bloesch, M. Hutter, Probabilistic terrain map-

ping for mobile robots with uncertain localization, *IEEE Robotics and Automation Letters* 3019–3026 (2018).

18. M. Zucker, J. A. Bagnell, C. G. Atkeson, J. Kuffner, An optimization approach to rough terrain locomotion, *2010 IEEE International Conference on Robotics and Automation*, 3589–3595 (IEEE, 2010).
19. P. D. Neuhaus, J. E. Pratt, M. J. Johnson, Comprehensive summary of the institute for human and machine cognition' s experience with LittleDog, *The International Journal of Robotics Research* 216–235 (2011).
20. J. Z. Kolter, Y. Kim, A. Y. Ng, Stereo vision and terrain modeling for quadruped robots, *2009 IEEE International Conference on Robotics and Automation*, 1557–1564 (IEEE, 2009).
21. I. Havoutis, J. Ortiz, S. Bazeille, V. Barasuol, C. Semini, D. G. Caldwell, Onboard perception-based trotting and crawling with the hydraulic quadruped robot (HyQ), *2013 IEEE/RSJ International Conference on Intelligent Robots and Systems*, 6052–6057 (IEEE, 2013).
22. C. Mastalli, M. Focchi, I. Havoutis, A. Radulescu, S. Calinon, J. Buchli, D. G. Caldwell, C. Semini, Trajectory and foothold optimization using low-dimensional models for rough terrain locomotion, *2017 IEEE International Conference on Robotics and Automation (ICRA)*, 1096–1103 (IEEE, 2017).
23. D. Belter, P. Łabęcki, P. Skrzypczyński, Adaptive motion planning for autonomous rough terrain traversal with a walking robot, *Journal of Field Robotics* 337–370 (2016).
24. P. Fankhauser, M. Bjelonic, C. D. Bellicoso, T. Miki, M. Hutter, Robust rough-terrain locomotion with a quadrupedal robot, *2018 IEEE International Conference on Robotics and Automation (ICRA)*, 5761–5768 (IEEE, 2018).
25. F. Jenelten, T. Miki, A. E. Vijayan, M. Bjelonic, M. Hutter, Perceptive locomotion in rough terrain–online foothold optimization, *IEEE Robotics and Automation Letters* 5370–5376 (2020).
26. D. Kim, D. Carballo, J. Di Carlo, B. Katz, G. Bledt, B. Lim, S. Kim, Vision aided dynamic exploration of unstructured terrain with a small-scale quadruped robot, *2020 IEEE International Conference on Robotics and Automation (ICRA)*, 2464–2470 (IEEE, 2020).
27. O. A. Villarreal-Magaña, V. Barasuol, M. Camurri, M. Focchi, L. Franceschi, M. Pontil, D. G. Caldwell, C. Semini, Fast and continuous foothold adaptation for dynamic locomotion through cnns, *IEEE Robotics and Automation Letters* 2140–2147 (2019).
28. Boston Dynamics, Atlas | partners in parkour, https://youtu.be/tF4DML7FIWk (2021). [Online; accessed September-2021].
29. X. B. Peng, G. Berseth, M. Van de Panne, Terrain-adaptive locomotion skills using deep reinforcement learning, *ACM Transactions on Graphics (TOG)* 1–12 (2016).
30. X. B. Peng, G. Berseth, K. Yin, M. Van De Panne, Deeploco: Dynamic locomotion skills using hierarchical deep reinforcement learning, *ACM Transactions on Graphics (TOG)* 1–13 (2017).
31. X. B. Peng, P. Abbeel, S. Levine, M. van de Panne, Deepmimic: Example-guided deep reinforcement learning of physics-based character skills, *ACM Trans. Graph.* 143:1–143:14 (2018).
32. Z. Xie, H. Y. Ling, N. H. Kim, M. van de Panne, Allsteps: Curriculum-driven learning of stepping stone skills, *Computer Graphics Forum*, 213–224 (Wiley Online Library, 2020).
33. V. Tsounis, M. Alge, J. Lee, F. Farshidian, M. Hutter, Deepgait: Planning and control of quadrupedal gaits using deep reinforcement learning, *IEEE Robotics and Automation Letters* 3699–3706 (2020).
34. J. Tan, T. Zhang, E. Coumans, A. Iscen, Y. Bai, D. Hafner, S. Bohez, V. Vanhoucke, Sim-to-real: Learning agile locomotion for quadruped robots, *Robotics: Science and Systems* (2018).
35. X. B. Peng, E. Coumans, T. Zhang, T.-W. E. Lee, J. Tan, S. Levine, Learning agile robotic locomotion skills by imitating animals, *Robotics: Science and Systems* (2020).
36. Y. Yang, K. Caluwaerts, A. Iscen, T. Zhang, J. Tan, V. Sindhwani, Data efficient reinforcement learning for legged robots, *Conference on Robot Learning*, 1–10 (PMLR, 2020).
37. Z. Xie, P. Clary, J. Dao, P. Morais, J. Hurst, M. van de Panne, Learning locomotion skills for cassie: Iterative design and sim-to-real, *Proceedings of the Conference on Robot Learning*, L. P. Kaelbling, D. Kragic, K. Sugiura, eds., 317–329 (PMLR, 2020).
38. J. Siekmann, K. Green, J. Warila, A. Fern, J. Hurst, Blind bipedal stair traversal via sim-to-real reinforcement learning, *Robotics: Science and Systems* (2021).
39. A. Kumar, Z. Fu, D. Pathak, J. Malik, Rma: Rapid motor adaptation for legged robots, *Proceedings of Robotics: Science and Systems (RSS)* (2021).
40. C. Yang, K. Yuan, Q. Zhu, W. Yu, Z. Li, Multi-expert learning of adaptive legged locomotion, *Science Robotics* p. eabb2174 (2020).
41. J. Lee, J. Hwangbo, M. Hutter, Robust recovery controller for a quadrupedal robot using deep reinforcement learning, *arXiv preprint arXiv:1901.07517* (2019).
42. S. Gangapurwala, M. Geisert, R. Orsolino, M. Fallon, I. Havoutis, RLOC: Terrain-aware legged locomotion using reinforcement learning and optimal control, *arXiv preprint arXiv:2012.03094* (2020).
43. M. Focchi, R. Orsolino, M. Camurri, V. Barasuol, C. Mastalli, D. G. Caldwell, C. Semini. Heuristic planning for rough terrain locomotion in presence of external disturbances and variable perception quality. *Advances in Robotics Research: From Lab to Market* (Springer, 2020), 165–209.
44. Boston Dynamics, Spot user guide release 2.0 version A, https://www.generationrobots.com/media/spot-boston-dynamics/spot-user-guide-r2.0-va.pdf (2021). [Online; accessed June-2021].
45. D. Chen, B. Zhou, V. Koltun, P. Krähenbühl, Learning by cheating, *Conference on Robot Learning*, 66–75 (PMLR, 2020).
46. Komoot, Etzel kulm loop hike, https://bit.ly/35bjfyE (2021). [Online; accessed June-2021].
47. M. Bloesch, M. Hutter, M. A. Hoepflinger, S. Leutenegger, C. Gehring, C. D. Remy, R. Siegwart, State estimation for legged robots-consistent fusion of leg kinematics and imu, *Robotics* 17–24 (2013).
48. Komoot, Komoot help guides, https://d21buns5ku92am.cloudfront.net/67683/documents/40488-Komoot%20Guides%

20English-4d1241.pdf (2021). [Online; accessed December-2021].

49. R. C. Coulter, Implementation of the pure pursuit path tracking algorithm, *Tech. rep.*, Carnegie-Mellon UNIV Pittsburgh PA Robotics INST (1992).
50. M. Tranzatto, F. Mascarich, L. Bernreiter, C. Godinho, M. Camurri, S. M. K. Khattak, T. Dang, V. Reijgwart, J. Loeje, D. Wisth, others, Cerberus: Autonomous legged and aerial robotic exploration in the tunnel and urban circuits of the darpa subterranean challenge, *Journal of Field Robotics* (2021).
51. Cerberus, Team cerberus, https://www.subt-cerberus.org/ (2021). [Online; accessed June-2021].
52. DARPA, Darpa subterranean challenge competition results finals, https://www.subtchallenge.com/results.html (2021). [Online; accessed November-2021].
53. DARPA, Darpa subterranean challenge competition rules final event, https://www.subtchallenge.com (2021). [Online; accessed June-2021].
54. V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller, Playing atari with deep reinforcement learning, *Advances in Neural Information Processing Systems, Deep Learning Workshop* (2013).
55. P. Zhu, X. Li, P. Poupart, G. Miao, On improving deep reinforcement learning for pomdps, *arXiv preprint arXiv:1704.07978* (2017).
56. O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev, others, Grandmaster level in starcraft ii using multi-agent reinforcement learning, *Nature* 350–354 (2019).
57. S. Bai, J. Z. Kolter, V. Koltun, An empirical evaluation of generic convolutional and recurrent networks for sequence modeling, *arXiv:1803.01271* (2018).
58. J. Hwangbo, J. Lee, M. Hutter, Per-contact iteration method for solving contact dynamics, *IEEE Robotics and Automation Letters* 895–902 (2018).
59. J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, Proximal policy optimization algorithms, *arXiv preprint arXiv:1707.06347* (2017).
60. S. Ross, G. Gordon, D. Bagnell, A reduction of imitation learning and structured prediction to no-regret online learning, *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, 627–635 (JMLR Workshop and Conference Proceedings, 2011).
61. W. M. Czarnecki, R. Pascanu, S. Osindero, S. Jayakumar, G. Swirszcz, M. Jaderberg, Distilling policy distillation, *Proceedings of Machine Learning Research*, K. Chaudhuri, M. Sugiyama, eds., 1331–1340 (PMLR, 2019).
62. K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio, Learning phrase representations using rnn encoder-decoder for statistical machine translation, *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, p. 1724–1734 (2014).
63. S. Hochreiter, J. Schmidhuber, Long short-term memory, *Neural Computation* 1735–1780 (1997).
64. T. Anzai, K. Takahashi, Deep gated multi-modal learning: In-hand object pose changes estimation using tactile and image data, *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 9361–9368 (IEEE, 2020).
65. J. Kim, J. Koh, Y. Kim, J. Choi, Y. Hwang, J. W. Choi, Robust deep multi-modal learning based on gated information fusion network, *Asian Conference on Computer Vision*, 90–106 (Springer, 2018).
66. J. Arevalo, T. Solorio, M. Montes-y Gómez, F. A. González, Gated multimodal units for information fusion, *ICLR workshop* (2017).
67. Rs-bpearl (2021, april), https://www.robosense.ai/en/rslidar/RS-Bpearl.
68. Intel realsense (2021, april), https://www.intelrealsense.com/.
69. A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, S. Chintala. Pytorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems 32*, H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, R. Garnett, eds. (Curran Associates, Inc., 2019), 8024–8035.
70. M. Takahiro, L. Joonho, M. Yuntao, E. Pascal, Rslgym, *GitHub repository* (2021).
71. D. P. Kingma, J. Ba, Adam: A method for stochastic optimization, *ICLR* (2015).
72. A. Lagae, S. Lefebvre, R. Cook, T. DeRose, G. Drettakis, D. S. Ebert, J. P. Lewis, K. Perlin, M. Zwicker, A survey of procedural noise functions, *Computer Graphics Forum*, 2579–2600 (Wiley Online Library, 2010).
73. A. L. Maas, A. Y. Hannun, A. Y. Ng, Rectifier nonlinearities improve neural network acoustic models, *Proc. icml*, p. 3 (Citeseer, 2013).

S1. 命名法

s	state
o	observation
b	belief state
h	hidden state
l	latent feature
v	linear velocity
ω	angular velocity
τ	joint torque
q	joint position
ϕ	CPG phase
$\Delta\phi_0$	CPG phase base frequency
c_k	curriculum factor
c_{sk}	student curriculum factor
$\mathcal{L}_{bc}$	behavior cloning loss
$\mathcal{L}_{re}$	reconstruction loss
$(\cdot)^p$	proprioceptive quantity
$(\cdot)^e$	exteroceptive quantity
$(\cdot)^{priv}$	privileged quantity
$(\cdot)^{target}$	target quantity
$(\cdot)_t$	quantity at time t
$\tilde{(\cdot)}$	noisy quantity
$\dot{(\cdot)}$	first derivative
$\ddot{(\cdot)}$	second derivative
$g(\cdot)$	Multilayer Perceptron (MLP) encoder
$\mathcal{N}()$	Normal distribution
$\odot$	Hadamard product
$\mathbf{p}(\cdot)$	foot trajectory function
$IK(\cdot)$	inverse kinematics function

S2. 评估外感受的重要性：仿真中的附加实验

我们在仿真中比较了各种阶梯地形和楼梯上的成功率，以进一步定量评估性能表现。

机器人被设定以 0.7 米/秒的恒定前向速度指令运行 10 秒钟。我们收集了 300 次试验来计算成功率，其中若机器人能无故障地行进 4 米，则视为一次成功的试验。如图 8A、8B 所示，我们的控制器显著优于基准，能够在更广泛的地形范围内自如移动。

S3. 训练详情

策略的控制频率设置为 50 Hz，每个环境收集 250 个轨迹时间步进行一次训练迭代。我们并行化了仿真环境，以同时执行 1000 个环境的滚动。我们使用自定义的PPO [59] 实现来训练教师策略 [70]。在将观测值输入策略网络之前，使用运行均值和标准差对其进行规范化处理。课程因子在每个训练回合 $c_{k+1} = c_k^d$ 中按指数更新，收敛速率为 $d = 0.98$。我们使用 Adam [71] 优化器，并采用指数学习率衰减。PPO的超参数在表 S1 中给出。

Table S1. PPO 的超参数。

learning rate	5.0 E-4
learning rate decay gamma	0.9999
discount factor	0.996
learning epoch	2
GAE-lambda	0.95
clip ratio	0.2
entropy coefficient	0.005
batch size	8300

Table S2. 学生训练的超参数。

learning rate	5.0 E-4
truncate step for TBPTT	10
learning epoch	2

在学生训练中，我们使用 300 个环境进行 rollout，并在每次训练迭代中收集 400 个时间步的轨迹。我们开始学生训练时不加入高度样本噪声，并通过一个随训练轮次线性增加的学生课程因子逐步提高噪声水平。在前 10 轮次中，我们使用平坦地形，随后启用地形生成的自适应课程。经过 20 轮次后，我们线性增加学生课程因子 c_{sk}，直至达到 100 轮次。之后，我们保持 $c_{sk} = 1.0$。我们使用截断时间反向传播（TBPTT）训练编码器的RNN单元。行为克隆损失与重构损失的比例为 0.5，因此损失设置为 $\mathcal{L}_{bc} + 0.5 \cdot \mathcal{L}_{re}$。学生训练的超参数见表 S2。

S4. 地形生成

地形类型包括粗糙、粗糙离散、大台阶、箱体、网格台阶、阶梯台阶和楼梯，如图 6.1 所示。楼梯有四种类型：标准楼梯、开放式楼梯、带平台楼梯和随机楼梯。每种地形类型由不同的地形属性参数化，这些属性在训练过程中随机化。

粗糙地形通过 Perlin 噪声 [72] 进行参数化，而粗糙离散和大步阶地形则通过对其进行量化生成。虽然粗糙离散地形不限制量化层数，但大步阶仅允许两种高度级别 ($h \in [0, 0.4]$ m)。对于网格步阶，其参数包括平均步阶高度 ($h \in [0.05, 0.4]$ m) 和步阶宽度 ($d \in [0.2, 0.7]$ m)。图 8A 展示了不同网格步阶的示例。注意图中显示的参数值域仅用于评估，与训练时使用的值域不同。楼梯地形的参数包含台阶深度 ($d \in [0.25, 1.0]$ m) 和高度 ($h \in [0.01, 0.22]$ m)。对于随机楼梯，其高度和深度值按照比例 $\epsilon \sim \mathcal{N}(1.0, 0.2)$ 分别设定，使得 $\hat{x} = x \cdot \epsilon$，其中 x 为给定的深度或高度参数。图 8B 展示了不同楼梯的示例。箱体地形由多个最大高度为 0.25 m 的箱体组成，这些箱体随机分布并带有随机

偏航角。

S5. 观察与动作

观测向量在表 S3 中定义。本体感觉输入包括命令、关节和身体信息，以及腿部相位信息。central pattern generator (CPG)的相位信息由 $\Delta\phi_l$、$\cos\phi_l$、$\sin\phi_l$ 和每条腿的基频 l 组成。对于外部感知，我们使用每只脚周围的高度样本，而不是局部高程图。圆形采样模式由每只脚周围的 {6, 8, 10, 12, 16} 个点组成，半径分别为 {0.08, 0.16, 0.26, 0.36, 0.48} 米。

Table S3. 观察。本体感觉用于教师和学生的训练。外部感觉以高度样本的形式提供。特权信息仅用于教师训练。

观测类型	输入	暗淡。
本体感觉	命令	3
	身体朝向	3
	身体速度	6
	关节位置	12
	关节速度	12
	关节位置历史（3 个时间步）	36
	关节速度历史（2 个时间步）	24
	联合目标历史（2 个时间步）	24
	CPG 相位信息	13
外感受	高度样本	208
特权信息	接触状态	4
	接触力	12
	接触范数	12
	摩擦系数	4
	大腿与小腿接触	8
	外力和扭矩	6
	通话时长	4

动作定义为 $\langle \Delta\phi_l, \Delta q_i \rangle$，其中 $\Delta\phi_l$ 和 Δq_i 分别指每条腿的相位偏移 ($l \in \{legs\}$) 和剩余关节位置目标 ($i \in \{1, \cdots, 12\}$)。我们有一个标称的足部轨迹 $\mathbf{p}(\phi) : \mathbb{R} \longrightarrow \mathbb{R}^3$，它将每个 ϕ_l 映射到一个目标足部位置，当 ϕ 在 $[0, 2\pi)$ 内循环时，生成周期的步进运动。从动作中，使用解析逆运动学 $IK(\cdot)$ 和基础相位频率 $\Delta\phi_0$，定义了一条腿 l 的关节位置目标为 $q_{i\in l}^{target} = IK(\mathbf{p}(\phi_l + \Delta\phi_l + \Delta\phi_0)) + \Delta q_{i\in l}$。标称的足部轨迹定义如下。

如果相位处于摆起状态（$0 \le \phi_l \le \pi/2$），

$$\begin{aligned} \mathbf{p}_l(\phi_l) \quad &= \langle x_l^n, y_l^n, z_l^n + 0.2 \cdot (-2t_l^3 + 3t_l^2) \rangle, \\ &\text{where} \quad t_l = 2/\pi \cdot \phi_l. \end{aligned}$$

$\{x, y, z\}_l^n$ 是默认站立配置下的标称足部位置。三次 Hermite 样条在 $\phi_l = 0$ 处连接 $z = z_l^n$，并在 $\phi_l = \pi/2$ 处连接 $z = z_l^n + 0.2$。

在下摆阶段（$\pi/2 < \phi_l \le \pi$），足部高度被计算为

$$\begin{aligned} \mathbf{p}_l(\phi_l) \quad &= \langle x_l^n, y_l^n, z_l^n + 0.2 \cdot (2t_l^3 - 3t_l^2 + 1) \rangle, \\ &\text{where} \quad t_l = 2/\pi \cdot \phi_l - 1, \end{aligned}$$

这与前一个函数对称。

在支撑阶段（$\pi < \phi_l \le 2\pi$），$\mathbf{p}_l(\phi_l) = \langle x_l^n, y_l^n, z_l^n \rangle$。

S6. 网络结构

策略网络由多个多层感知器（MLP）组成。高度样本首先被编码为一个 $24 \times 4 = 96$ 维的潜在向量，而特权信息则通过基于 MLP 的编码器（g_e, g_p）被编码为一个 24 维的潜在向量。每个编码器分别拥有两个隐藏层，隐藏单元数量分别为 {80, 60} 和 {64, 32}。高度样本首先分别输入到每个足的编码器中，随后被连结成一个特征向量。接着，这些特征与本体感受观测值连结，并输入到另一个具有三个隐藏层 {256, 160, 128} 的 MLP 中。所有 MLP 的激活函数均为 LeakyReLU [73]。

我们使用带有外部感知门的GRU作为信念编码器（图 7C）。该GRU由 2 个堆叠的层组成，每层有 50 个隐藏单元。信念编码器和外部感知门 g_b、g_a 用于计算 $96 + 24 = 120$ 维的信念状态 b_t 和 96 维的注意力向量 α。每个编码器有两个隐藏层，分别具有 {64, 64} 和 {64, 64} 个隐藏单元。过滤后的外部感知信息 $l_t^e \odot \alpha$ 被添加到 $g_b(b_t')$ 中，并使用零填充以匹配维度。

S7. 奖励函数

奖励函数定义为 $r = 0.75(r_{lv} + r_{av} + r_{lvo}) + r_b + 0.003r_{fc} + 0.1r_{co} + 0.001r_j + 0.08r_{jc} + 0.003r_s + 1.0 \cdot 10^{-6}r_\tau + 0.003r_{slip}$ 。各项定义如下。

- 线性速度奖励 (r_{lv})：该术语鼓励策略遵循期望的水平速度（xy 平面内的速度）指令：

$$r_{lv} = \begin{cases} \exp(-|\boldsymbol{v}|^2), & \text{if } |\boldsymbol{v}_{des}| = 0 \\ 1.0, & \text{else if } \boldsymbol{v}_{des} \cdot \boldsymbol{v} > |\boldsymbol{v}_{des}| \\ \exp(-(\boldsymbol{v}_{des} \cdot \boldsymbol{v} - |\boldsymbol{v}_{des}|)^2), & \text{otherwise} \end{cases}$$

  其中 $\boldsymbol{v}_{des} \in \mathbb{R}^2$ 是期望的水平速度，$\boldsymbol{v} \in \mathbb{R}^2$ 是当前相对于机体坐标系的体速度。

- 角速度奖励 (r_{av})：该术语鼓励策略遵循期望的偏航速度指令：

$$r_{av} = \begin{cases} \exp(-\omega_z^2), & \text{if } \omega_{des} = 0 \\ 1.0, & \text{else if } \omega_{des} \cdot \omega_z > \omega_{des} \\ \exp(-(\omega_{des} \cdot \omega_z - \omega_{des})^2), & \text{otherwise} \end{cases}$$

其中 ω_{des} 是期望的偏航速度，ω_z 是相对于机体框架的当前偏航速度。

- 线性正交速度奖励 (r_{lvo})：该术语对与目标方向正交的速度进行惩罚：

$$r_{lvo} = \exp(-3.0|\boldsymbol{v}_o|^2),$$

其中 $\boldsymbol{v_o} = \boldsymbol{v} - (\boldsymbol{v}_{des} \cdot \boldsymbol{v})\boldsymbol{v}_{des}$。

- 身体运动奖励 (r_b)：该术语惩罚了不在命令方向上的身体速度：

$$r_{bm} = -1.25v_z^2 - 0.4|\omega_x| - 0.4|\omega_y|.$$

- 足部离地高度奖励 (r_{fc})：当一条腿处于摆动阶段，即 $\phi_i \in [0, \pi)$ 时，机器人应使对应脚部抬升高于周围环境。然而，为防止机器人表现出不必要的过高足部离地，我们给予一个惩罚奖励 r_{fcl} 以规范腿部轨迹。$H_{sample,l}$ 是围绕第 l 只脚采样高度的集合。随后，离地高度成本定义为

$$\begin{aligned} r_{fcl} &= \begin{cases} -1.0, & \text{if } \max(H_{sample,l}) < -0.2 \\ 0.0 & \text{otherwise} \end{cases} \\ r_{fc} &= \sum_{l=1}^{4} r_{fcl} \end{aligned}$$

请注意，高度样本是相对于足部高度采样的，因此-0.2 表示地形比足部低 0.2 米；换言之，足部比采样地形高度高出 0.2 米。

- Shank and Knee Collision Reward (r_{co})：我们希望惩罚地形与机器人非脚部部件之间的不良接触，以避免硬件损坏：

$$r_{co} = \begin{cases} -c_k, & \text{if shank or knee is in collision} \\ 0.0 & \text{otherwise} \end{cases}$$

其中 c_k 是单调递增并收敛于 1 的课程因子。

- 关节运动奖励 (r_j)：该术语惩罚关节速度和加速度以避免振动：

$$r_s = -c_k \sum_{i=1}^{12} (0.01\dot{q}_i{}^2 + \ddot{q}_i{}^2),$$

其中 $\dot{q}_i$ 和 $\ddot{q}_i$ 分别表示关节速度和加速度。

- 联合空间软约束奖励 (r_{jc})：该术语在关节空间中引入了一个软约束。为了避免膝关节反向翻转，我们对超过阈值的情况施加惩罚：

$$\begin{aligned} r_{jc,i} &= \begin{cases} -(q_i - q_{i,th})^2, & \text{if } q_i > q_{i,th} \\ 0.0 & \text{otherwise} \end{cases} \\ r_{jc} &= \sum_{i=1}^{12} r_{jc,i} \end{aligned}$$

其中 $q_{i,th}$ 是第 i 个关节的阈值。我们仅为膝关节设置阈值。

- 目标平滑度奖励 (r_s)：目标脚位置的一阶和二阶有限差分导数的大小受到惩罚，以使生成的脚部轨迹更加平滑：

$$r_s = -c_k \sum_{i=1}^{12} ((q_{i,t}^{des} - q_{i,t-1}^{des})^2 + (q_{i,t}^{des} - 2q_{i,t-1}^{des} + q_{i,t-2}^{des})^2),$$

其中 $q_{i,t}^{des}$ 是关节 i 在时间步 t 的关节目标位置。

- 扭矩奖励 (r_τ)：我们对关节扭矩进行惩罚以减少能量消耗 ($\tau \propto$ electric current)：

$$r_\tau = -c_k \sum_{i=1}^{12} \tau_i^2,$$

其中 τ_i 是执行器网络计算输出的第 i 个关节的扭矩。

- 滑移奖励 (r_{slip})：如果脚部与地面接触，则对脚部速度进行惩罚以减少滑移：

$$r_{slip} = -c_k \sum_{l \in \{\text{foot in contact}\}} v_{f,l}^2,$$

其中 $v_{f,l}$ 是与地面接触的第 l 只脚的速度。

S8. 高度样本噪声

在学生训练过程中，我们对每只脚周围抽取的高度样本进行随机化处理（见图 7A）。我们对每个样本的位置进行了扰动，并按照以下方式向测量高度值添加噪声。

$$\begin{aligned} x_p &= r_p \cos(\theta_p) + \epsilon_{px} + \epsilon_{fx} + w_x \\ y_p &= r_p \sin(\theta_p) + \epsilon_{py} + \epsilon_{fy} + w_y \\ h_p &= h(x_p, y_p) + \epsilon_{pz} + \epsilon_{fz} + w_z + \epsilon_{outlier} \end{aligned}$$

其中 $h(x_p, y_p)$ 表示位置 (x_p, y_p) 处的地形高度。r_p 是点 p 的径向距离，θ_p 是 p 在围绕足部的极坐标中的方位角。$\epsilon_{px}, \epsilon_{py}, \epsilon_{pz}$ 表示每个时间步为每个单独点采样的噪声。$\epsilon_{fx}, \epsilon_{fy}, \epsilon_{fz}$ 表示每个时间步为每只足采样的噪声。w_x, w_y, w_z 表示每个回合为每只足采样的噪声。$\epsilon_{outlier}$ 是间歇性添加的大噪声，用于模拟异常值。

每个噪声使用参数 z 从正态分布中采样。$\epsilon_{px}, \epsilon_{py} \sim \mathcal{N}(0, z_0)$, $\epsilon_{pz} \sim \mathcal{N}(0, z_1)$, $\epsilon_{fx}, \epsilon_{fy} \sim \mathcal{N}(0, z_2)$, $\epsilon_{fz} \sim \mathcal{N}(0, z_3)$, $\epsilon_{outlier} \sim \mathcal{N}(0, z_4)$ 的概率分别为 $p = z_5$, $w_x, w_y \sim \mathcal{N}(0, z_6)$, $w_z \sim \mathcal{N}(0, z_7)$ 。

我们为学生训练定义了三个条件：正常、偏移、噪声。每个参数 z 定义如下。

$$z_{nominal} = \langle 0.004, 0.005, 0.01, 0.04, 0.03, 0.05, 0.1 \rangle \quad \textbf{(2)}$$

$$z_{offset} = \langle 0.004, 0.005, 0.01, 0.1c_{sk}, 0.1c_{sk}, 0.02, 0.1 \rangle \quad \textbf{(3)}$$

$$z_{noisy} = \langle 0.004, 0.1c_{sk}, 0.1c_{sk}, 0.3c_{sk}, 0.3c_{sk}, 0.3c_{sk}, 0.1 \rangle \quad \textbf{(4)}$$

其中 c_{sk} 是学生课程因子，它随着训练回合线性增加。我们在轨迹的开始和中间随机选取其中一个条件，概率分别为 60%，30% 和 10%。

S9. 信念编码器中注意力门控的消融研究

我们通过比较带与不带外感受门限的信念编码器性能，评估了外感受门限的影响。为此，我们利用四种不同的信念编码器训练了学生策略：“GRU 带门限”、“GRU 无门限”、“MLP 带门限” 和 “MLP 无门限”。其中，“GRU 带门限” 采用了提出的外感受门限，而 “GRU 无门限” 则未使用；“MLP” 则采用前馈网络替代了循环单元。图 S2A 展示了使用这四种不同架构进行学生训练的学习曲线。结果表明，使用循环单元能提升性能，而 MLP 未能重构特权信息。此外，外感受门限持续改善了 GRU 和 MLP 架构的表现。值得注意的是，在训练初期，我们未引入外感受噪声和地形课程，而是逐步增加，这一效果表现为初期损失急剧上升及奖励下降。

为了评估学成模型，我们收集了 300 个时间步，每种地形类型包含 100 个不同的地形参数，并在两种噪声条件下进行：小和大。每个噪声参数 z 定义如下，

$$z_{small} = \langle 0.004, 0.005, 0.04, 0.04, 0.04, 0.01, 0.1 \rangle \quad \textbf{(5)}$$

$$z_{large} = \langle 0.004, 0.3, 0.2, 0.1, 0.1, 0.03, 0.1 \rangle \quad \textbf{(6)}$$

随后，我们计算了学生动作与教师动作之间的方阵距离，以及解码高度样本与真实高度样本之间的差异。如表 S4、S5 所示，在两种噪声情况下，带门控的编码器均优于无门控编码器。当外部感知信息可靠时，编码器通过跳跃连接利用这一外部感知输入。然而，当高度样本含有较大噪声时，外部感知无法提供可靠信息。此时，带门控与无门控结构表现相近（见表 S4、S5）。这表明，带门控结构在外部感知信息可靠时能有效利用该信息，而在其不可靠时也不会牺牲系统的鲁棒性。

为了进一步评估各策略的性能，我们对比了各策略在台阶穿越成功率上的表现。机器人在不同高度的台阶前初始化，并接收到朝向台阶的恒定速度指令（0.8 米/秒）。针对每一台阶高度，我们进行了 100 次试验，并将成功率展示于图 S2B 中。结果显示，在低噪声和高噪声环境下，“GRU 门控” 策略均表现最佳。特别是在低噪声情况下，“GRU 门控” 与 “无门控 GRU” 之间的差异更为显著，这证实了当外部感知信息可靠时，门控结构能更有效地利用这些信息。

Table S4. 不同噪声条件下教师与学生动作差异。数据以经验均值及标准差呈现。当噪声较小时，带有外感受门控的信念编码器在所有地形类型上展现出更小的动作差异。当外感受不可靠（噪声较大）时，两者表现相近；这表明门控阻断了跳跃连接，使得在此条件下我们的编码器与本体感受模型趋于一致。

	Small exteroceptive noise		Large exteroceptive noise	
terrain	ours	without gate	ours	without gate
rough	**0.690±0.40**	0.746±0.40	**0.879±0.46**	0.997±0.44
rough discrete	**0.787±0.45**	0.857±0.54	**0.878±0.53**	0.964±0.55
step stair	**0.652±0.39**	0.687±0.43	**0.975±0.49**	1.043±0.50
large step	**0.719±0.40**	0.855±0.43	**1.142±0.55**	1.225±0.54
grid steps	**1.444±0.56**	1.674±0.58	2.218±0.70	**2.212±0.70**
standard stair	**0.854±0.67**	0.961±0.72	**1.387±0.59**	1.438±0.56
open stair	**0.842±0.61**	0.938±0.65	**1.356±0.55**	1.428±0.53
ledged stair	**0.819±0.39**	0.929±0.42	**1.373±0.53**	1.416±0.54
boxes	**0.928±0.53**	1.123±0.56	**1.614±0.64**	1.683±0.68
random stair	**0.872±0.45**	0.956±0.46	**1.489±0.59**	1.526±0.58

Table S5. 不同噪声条件下高度样本的重构误差。数值以经验均值与标准差呈现。配备外感门控的信念编码器在所有地形类型上均表现出更小的重构误差，这证明了当外感知可靠时，门控跳跃连接的有效性。即便在噪声较大的情景下，门控编码器的表现也优于非门控编码器，尽管两者间的差距相较于低噪声情景有所缩小。

	Small exteroceptive noise		Large exteroceptive noise	
terrain	ours	without gate	ours	without gate
rough	**1.21E-03±2.8E-04**	1.36E-03±6.1E-04	**1.03E-03±2.3E-04**	1.17E-03±5.9E-04
rough discrete	**9.99E-04±3.3E-04**	1.03E-03±3.9E-04	**1.02E-03±3.5E-04**	1.05E-03±3.5E-04
step stair	**1.13E-03±4.4E-04**	1.31E-03±4.7E-04	**1.41E-03±4.3E-04**	1.48E-03±4.6E-04
large step	**1.37E-03±8.0E-04**	2.03E-03±1.0E-03	**1.95E-03±8.2E-04**	**1.95E-03±7.8E-04**
grid steps	**3.05E-03±4.1E-04**	4.77E-03±7.4E-04	**4.17E-03±5.0E-04**	4.39E-03±5.1E-04
standard stair	**2.59E-03±2.2E-03**	3.11E-03±2.2E-03	**2.68E-03±1.6E-03**	2.69E-03±1.5E-03
open stair	**2.61E-03±2.3E-03**	3.06E-03±2.0E-03	**2.63E-03±1.2E-03**	2.64E-03±1.1E-03
ledged stair	**2.53E-03±1.7E-03**	3.03E-03±1.5E-03	**2.62E-03±1.2E-03**	2.63E-03±1.1E-03
boxes	**2.13E-03±1.4E-03**	3.38E-03±1.5E-03	**3.00E-03±1.0E-03**	3.09E-03±1.2E-03
random stair	**2.31E-03±9.1E-04**	2.89E-03±8.2E-04	**2.72E-03±7.9E-04**	2.74E-03±8.0E-04

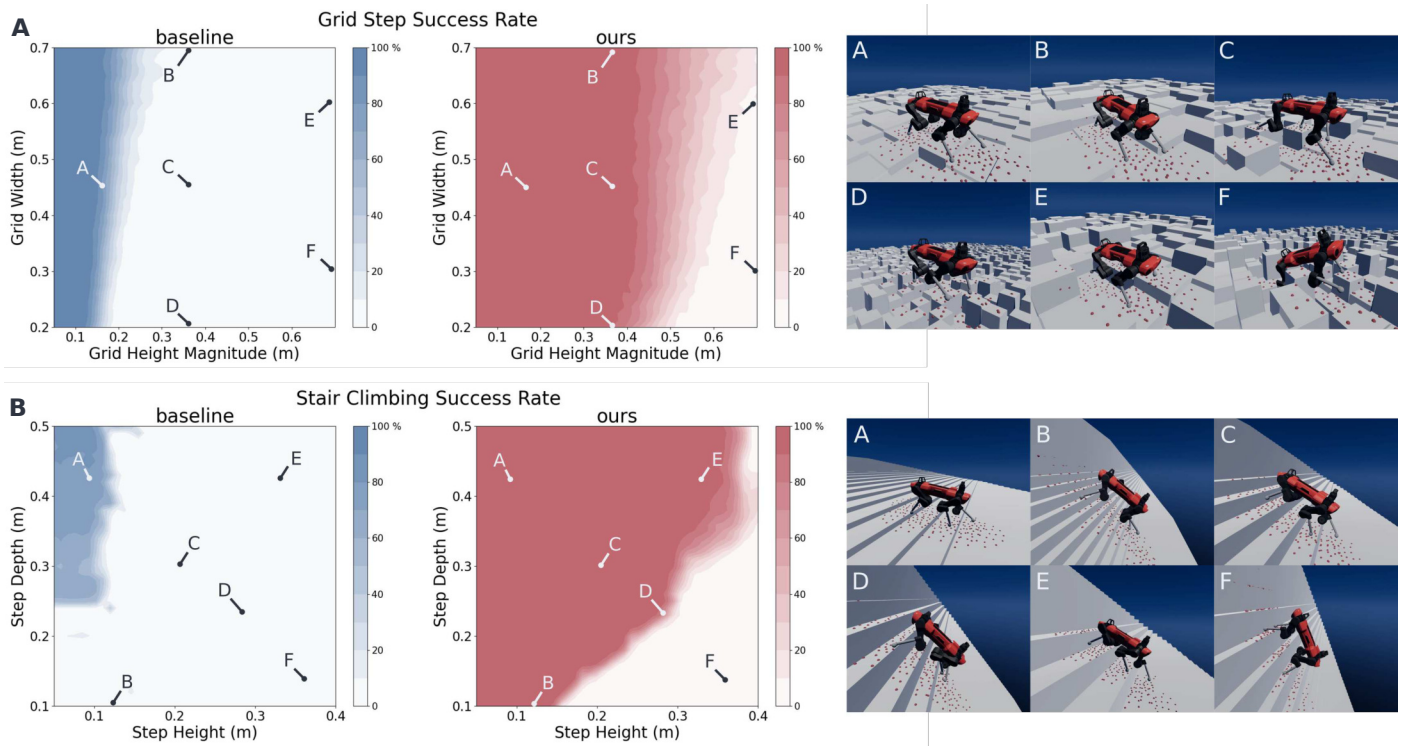


Fig. S1. 所提出的控制器与本体感觉基准 [4] 在随机地形上的比较。我们在 41×41 种不同的地形参数组合下收集了 300 次试验，并比较了成功率。我们的控制器能够在网格台阶（A）和楼梯（B）上穿越更广泛的地形值域。

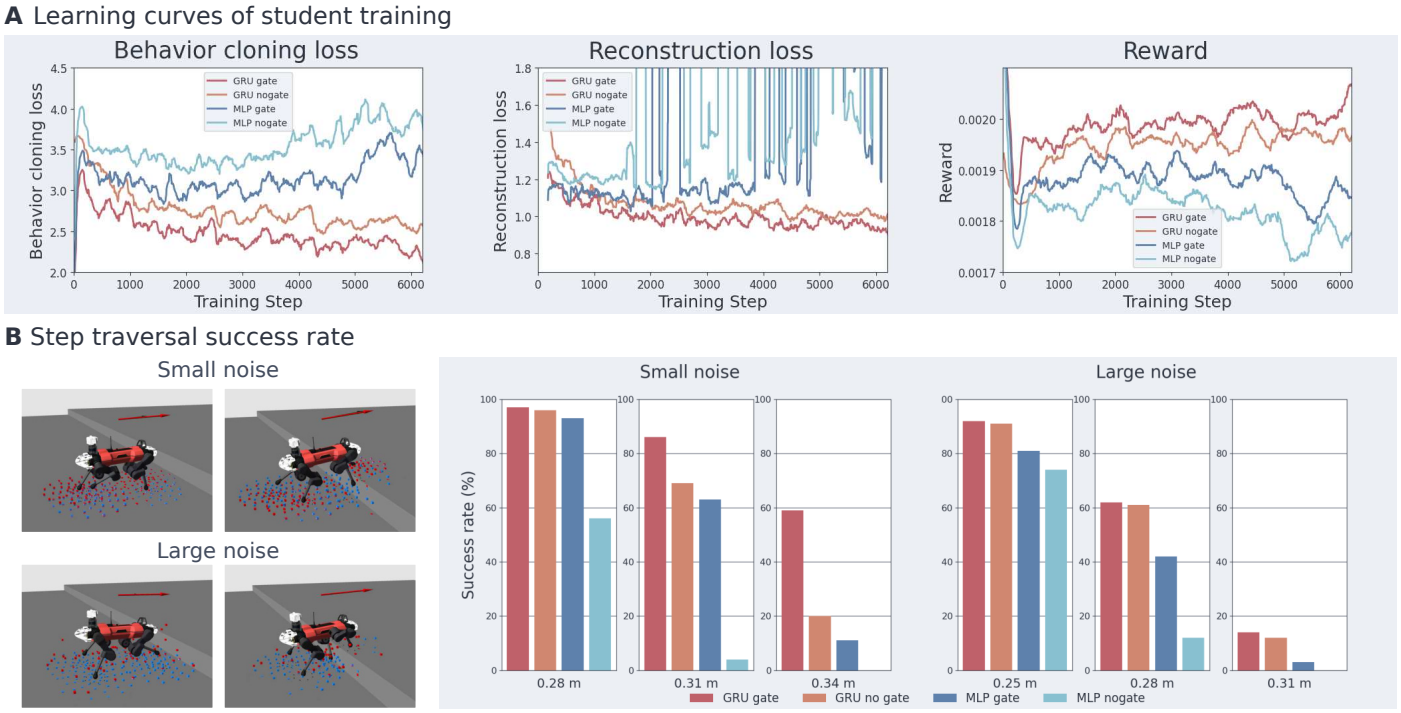


Fig. S2. 对所提出的信念编码器进行消融分析。我们比较了带 GRU 门控、无 GRU 门控、带 MLP 门控及无 MLP 门控四种情况。MLP 情景下，采用 MLP 而非 GRU 作为编码器；门控情景则引入了所提出的注意力门机制，而无门控情景则排除了该机制。(A) 学生策略训练的学习曲线显示，在所有情况下，GRU 均优于 MLP。对于 GRU 和 MLP 而言，使用注意力门控均比不使用表现更佳。初期损失上升与奖励下降归因于课程设置。(B) 在小噪声与大噪声环境下测试的台阶穿越成功率。机器人以随机关节配置和初始速度启动，并持续接收朝向台阶的恒定指令。若机器人前后腿均成功跨越台阶，则视为成功。共进行了 100 次试验。