https://hjfy.top/arxiv/2107.04034

RMA：用于腿式机器人的快速运动适应

Ashish Kumar
UC Berkeley

Zipeng Fu
Carnegie Mellon University

Deepak Pathak
Carnegie Mellon University

Jitendra Malik
UC Berkeley, Facebook

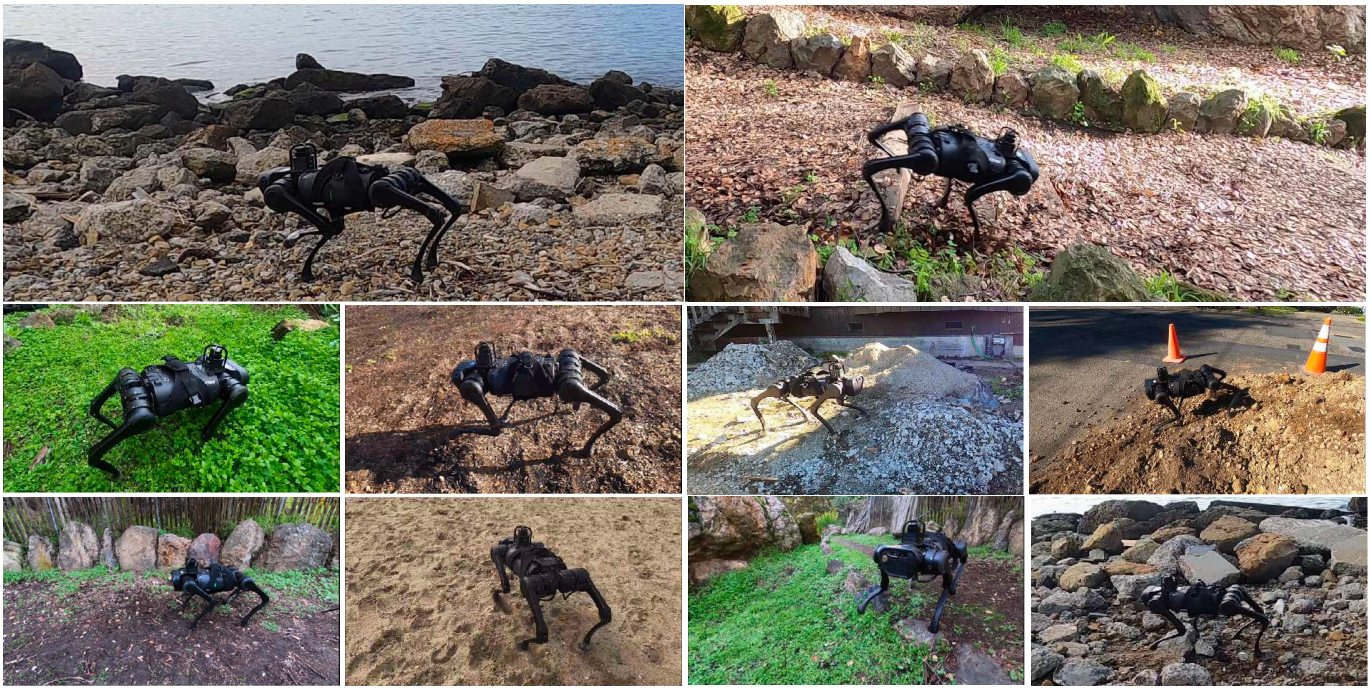


图 1: We demonstrate the performance of RMA on several challenging environments. The robot is successfully able to walk on sand, mud, hiking trails, tall grass and dirt pile without a single failure in all our trials. The robot was successful in 70% of the trials when walking down stairs along a hiking trail, and succeeded in 80% of the trials when walking across a cement pile and a pile of pebbles. The robot achieves this high success rate despite never having seen unstable or sinking ground, obstructive vegetation or stairs during training. All deployment results are with the same policy without any simulation calibration, or real-world fine-tuning. Videos at https://ashish-kmr.github.io/rma-legged-robots/

摘要—腿式机器人的成功实际部署需要它们在实时中适应未见过的场景，如地形变化、载荷变化、磨损和老化。本文提出了快速运动适应（RMA）算法来解决四足机器人实时在线适应的问题。RMA **包含两个组件：基础策略和适应模块。这些组件的结合使机器人能够在几分之一秒内适应新情况。**RMA **完全在仿真中进行训练，无需使用任何领域知识，如参考轨迹或预定义的脚部轨迹生成器，并且在** A1 **机器人上进行部署而无需微调。我们使用生物能量学启发的奖励在一个多样的地形生成器上训练** RMA**，并将其部署在各种困难地形上，包括岩石、滑腻、可变形表面，在有草地、长植被、混凝土、鹅卵石、楼梯、沙子等环境中的地形。**RMA **在多样化的现实世界以及仿真实验中表现出最先进的性能。视频结果见** https://ashish-kmr.github.io/rma-legged-robots/.

I. 引言

在过去四十年中，通过物理动力学建模和控制理论工具，腿式机器人领域取得了巨大进展 [36, 43, 46, 16, 56, 63, 50, 26, 28, 2, 24]。这些方法需要人类设计者具备相当的专业知识，近年来人们对于使用强化学习和模仿学习技术来复制这种成功表现出浓厚兴趣 [23, 18, 41, 55, 32]，这可能会降低这一负担，甚至可能提高性能。标准范式是在物理仿真环境中训练基于强化学习的控制器，然后使用各种仿真到现实的技术转移到真实世界 [52, 40, 23]。这种转移已被证明非常具有挑战性，因为仿真到现实的差距本身是由多个因素造

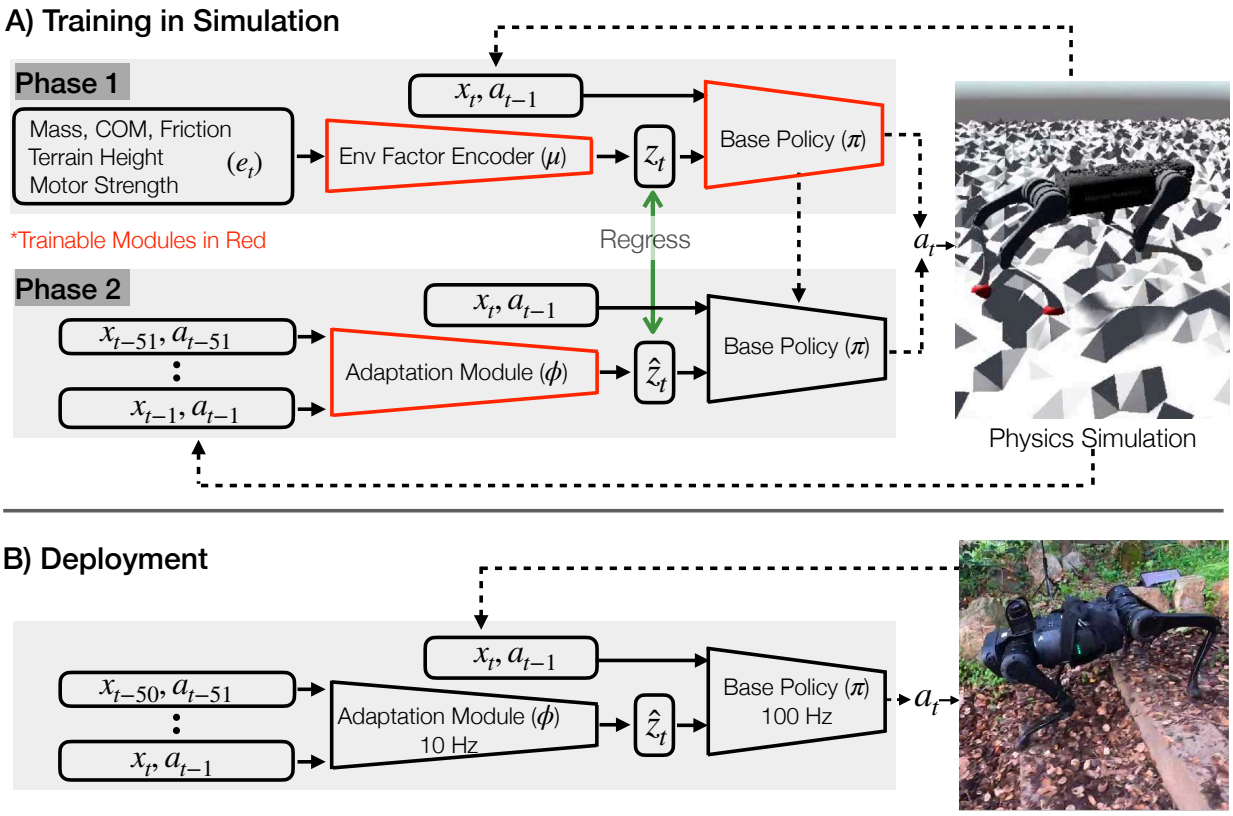


图 2: RMA 包含两个子系统 - 基础策略 π 和适应模块 ϕ 。**顶部：** RMA 分为两个阶段进行训练。在第一阶段，基础策略 π 将当前状态 x_t 、前一个动作 a_{t-1} 和特权环境因子 e_t 作为输入，这些因子通过环境因子编码器 μ 被编码成潜在的外在向量 z_t 。基础策略在仿真中使用无模型强化学习进行训练。在第二阶段，适应模块 ϕ 使用同策略数据通过监督学习来预测外在因素 $\hat{z}_t$ ，其依据是状态和动作的历史记录。**底部：** 在部署时，适应模块 ϕ 以 10Hz 的频率生成外在因素 $\hat{z}_t$ ，而基础策略以 100Hz 的频率生成期望的关节位置，并通过 A1 的 PD 控制器将其转换为力矩。由于适应模块运行频率较低，基础策略会使用适应模块最新预测的外在向量 $\hat{z}_t$ 来预测 a_t 。这种异步设计对于在计算能力有限的低成本机器人（如 A1）上实现无缝部署至关重要。视频请见：https://ashish-kmr.github.io/rma-legged-robots/

成的：(a) 物理机器人及其在模拟器中的模型存在显著差异；(b) 真实世界的地形与我们在模拟器中的模型有很大不同（图 1）；(c) 物理模拟器无法准确捕捉现实世界的物理特性——我们在这里处理的是接触力、可变形表面等——这比建模在自由空间中运动的刚体要困难得多。

在本文中，我们报告了我们在解决四足运动这一挑战方面的进展，使用的实验平台是 Unitree 相对便宜的 A1 机器人。图 1显示了一些视频中动作结果的样本示例。在概述我们的方法（图 2）之前，我们首先指出，人类在现实世界中的行走需要快速适应，因为我们会在不同的土壤上行走，上下坡，携带负载，肌肉休息或疲劳，以及应对扭伤的脚踝等。让我们将这一点作为腿式机器人的核心问题，并称之为**快速运动适应** (RMA)。我们将提出，RMA 必须在在线状态下发生，在几分之一秒的时间尺度上，这意味着我们没有时间在物理世界中进行多次实验，展开多个轨迹并优化以估计各种系统参数。这可能更糟糕。如果我们让四足机器人在一个没有任何先验经验的岩石表面上，机器人策略可能会经常失败，导致机器人严重损坏。为了适应行走策略，收集甚至 3-5 分钟的行走数据在实践中可能是不可行的。因此，我们的策略不仅包括基本的行走策略，还包括 RMA 必须在仿真中进行训练，并直接部署到现实世界中。但是怎么做呢?

图 2 显示了 RMA 包含两个子系统：基础策略 π 和适应模块 ϕ ，它们共同作用以实现在非常多样化的环境配置上的在线实时适应。基础策略通过强化学习在仿真中进行训练，使用关于环境配置 e_t 的特权信息，

例如摩擦力、负载等。对向量 e_t 的了解使基础策略能够适当适应给定的环境。环境配置向量 e_t 首先通过编码器网络 μ 被编码到潜在特征空间 z_t 中。这个潜在向量 z_t ，我们称之为 *外在因素*，然后与当前状态 x_t 和前一个动作 a_{t-1} 一起输入到基础策略中。然后基础策略预测机器人的期望关节位置 a_t 。策略 π 和环境因子编码器 μ 在仿真中通过强化学习进行联合训练。

不幸的是，由于在现实世界中我们无法获得 e_t ，因此此策略无法直接部署。我们需要在运行时估计外部参数，这就是适应模块 ϕ 的作用。关键的见解是，当我们命令机器人关节进行某种运动时，实际的运动与预期的运动存在差异，这种差异取决于外部参数。因此，我们可能希望利用智能体最近的状态历史来估计这个外部参数向量，类似于利用观测历史进行状态估计的卡尔曼滤波器的操作。具体来说，ϕ 的目标是从机器人的最近状态和动作历史中估计外部参数向量 z_t ，而无需假设对 e_t 的任何访问权限。也就是说，在运行时，但训练时生活更轻松。**由于状态历史和外部参数向量 z_t 都可以在仿真中计算，我们可以通过监督学习来训练这个模块**。在部署时，这两个模块协同工作以实现稳健和自适应的运动。在我们有限的板载计算能力的实验设置中，基础策略 π 以 100 Hz 运行，而适应模块 ϕ 更慢，以 10Hz 运行。两者异步并行运行，没有中央时钟来对齐它们。基础策略只是从适应模块上传最近的外部参数向量 z_t 的预测值来预测动作 a_t 。

我们的方法与之前在运动中基于学习的工作形成对比，这些工作通过从每次机器人被引入新情况时收集的小数据集中推断环境的关键参数来适应学成的策略。这些参数可以是摩擦等物理参数 [7] 或它们的潜在编码 [41]。不幸的是，如前所述，当机器人尚未掌握良好的行走策略时，收集这样的数据集可能导致机器人跌倒和损坏。我们的方法避免了这一点，因为 RMA 通过快速估计 z_t 允许行走策略快速适应[1] 并避免跌倒。

使用额外环境参数参数的基于强化学习的基线策略的训练也已在 [57, 41] 中进行。我们的创新之处在于使用了变化的地形生成器和由生物能量学启发的 “自然” 奖励函数，这使我们能够在不使用任何参考演示的情况下学习行走策略 [41]。但本文真正的新颖贡献是适应模块，在仿真中进行训练，这使得 RMA 成为可能。在部署时，这具有系统识别的特征，但它是在系统识别的在线版本，仅基于机器人在过去几秒钟内看到的单一轨迹。人们可能会合理地问为什么它会起作用，但我们可以提出一些推测：

- 系统识别传统上被认为是优化问题。但在许多情景中，研究人员发现给定优化问题的样本（输入，输出）对及其解，我们可以使用神经网络来近似将问题映射到其解的函数 [1, 17]。有效地，ϕ 正在学习做到这一点。
- 我们不需要完美的系统辨识来使该方法起作用。外在参数向量 z_t 是环境参数的低维非线性投影。这解决了某些可识别性问题，其中一些参数可能以相同的效果影响可观测值。其次，我们不需要这个外在向量在某种 “真实值” 的意义上是正确的。重要的是它能导致 “正确” 的动作，并且端到端训练会为此进行优化。
- 在训练中看到的情境范围应涵盖机器人在现实世界中将遇到的情况。我们使用一种分形地形生成器，结合质量、摩擦力等参数的随机化，创造出多种多样的物理环境，使行走机器人必须做出反应。

在现实世界中，与 RL 策略的鲁棒性能最相似的工作是 Lee et al. [32]，与我们的工作不同，它依赖于预定义轨迹生成器 [25] 和电机模型 [23] 的手工编码领域知识。我们在现实世界的多种地形上评估了 RMA（图 1）。所提出的自适应控制器能够在滑腻表面、不平坦地面、可变形表面（如泡沫、床垫等）以及自然环境中的粗糙地形（如草地、长植被、混凝土、鹅卵石、岩石表面、沙子等）上行走。

II. 相关工作

传统上，双足运动是通过使用基于控制的方法来实现的 [36, 43, 16, 56, 50, 26, 28, 2, 24, 4]。MIT Cheetah 3 [5] 通过使用正则化模型预测控制（MPC）和简化动力学实现了高速运动并跳过障碍物 [12]。ANYmal 机器人 [20] 通过优化参数化控制器并基于倒立摆模型进行规划来实现运动 [15]。然而，这些方法需要对真实世界动力学进行精确建模，深入了解机器人的先验知识，并手动调整步态和行为。结合 MPC 优化控制器可以缓解一些问题 [30, 8, 9]，但它们仍然需要大量的任务特定特征工程 [11, 15, 3]。

仿生运动的學習 將學習引入運動的最早嘗試可以追

[1] RMA 需要少于 1 秒，而 Peng et al. [41] 需要收集 $4-8$ 分钟（50 回合的 $5-10$ 秒）的数据。

溯到 DARPA 學習運動計劃 [63, 64, 44, 62, 27]。最近，深度化學習（RL）提供了一種替代方案，以少對人類專業知識的依賴，并在仿真中顯示出了良好的結果 [48, 33, 37, 14]。然而，這樣的策略很難轉移到現實世界 [31, 39, 6]。一種方法是直接在現實世界中進行訓練 [18, 55]。然而，這樣的策略僅限於非常簡單的設置，而要擴展到雜的設置需要不安全的探索和大量樣本。

从仿真到现实的强化学习 在现实世界中使用 RL 实现复杂的行走行为，几种方法试图弥合从仿真到现实的差距。领域随机化是一类方法，在这种方法中，策略通过广泛的环境参数和传感器噪声进行训练，以学习在这个范围内具有鲁棒性的行为 [51, 52, 40, 54, 38]。然而，领域随机化以最优性换取鲁棒性，导致策略过于保守 [34]。

另一种方法是通过使仿真更准确来减少 Sim-to-Real 差距 [23, 51, 19]。Tan et al. [51] 通过将分段线性函数拟合到实际电机的数据来改进电机模型 [51]。Hwangbo et al. [23]，则使用神经网络来参数化执行器模型 [23, 32]。然而，这些方法需要从机器人中进行初始数据采集以拟合电机模型，并且需要为每个新设置重复此过程。

系统识别与适应 而不是对物理参数漠不关心，策略可以通过在线系统识别来根据这些参数进行条件判断。在现实世界中部署时，物理参数可以通过在仿真中训练的模块进行推断 [57]，或者通过使用进化算法直接优化以获得高总回报 [58]。预测确切的系统参数通常不必要的且困难的，导致实际性能较差。相反，可以使用低维的潜在嵌入 [41, 61]。在测试时，可以通过使用策略梯度方法 [41]、贝叶斯优化 [59] 或随机搜索 [60]，在现实世界中对这个潜在进行优化。另一种方法是使用元学习来学习策略网络的初始化，以实现快速的在线适应 [13]。尽管它们已经在真实机器人上得到验证 [49, 10]，但它们仍然需要多次现实世界的滚动来适应。

III. 快速运动适应

我们现在描述在第 I 节第三段中引入并在图 2 中总结的 RMA 算法的各个组件。接下来的章节将依次讨论基础策略、自适应模块以及在真实机器人上的部署。我们将使用与第 I 节中引入的相同符号。

A. 基础策略

我们学习一个基础策略 π，它以当前状态 $x_t \in \mathbb{R}^{30}$、前一个动作 $a_{t-1} \in \mathbb{R}^{12}$ 和外在向量 $z_t \in \mathbb{R}^8$ 作为输入，预测下一个动作 a_t。预测的动作 a_t 是 12 机器人关节的期望关节位置，通过 PD 控制器将其转换为扭矩。外在向量 z_t 是由 μ 生成的环境向量 $e_t \in \mathbb{R}^{17}$ 的低维编码。

$$z_t = \mu(e_t) \tag{1}$$

$$a_t = \pi(x_t, a_{t-1}, z_t) \tag{2}$$

我们实现 μ 和 π 作为多层感知机（详情见第 IV-B 节）。我们使用模型无关的强化学习联合训练基础策略 π 和环境因子编码器 μ，端到端进行。在时间步 t，π 根据当前状态 x_t、前一个动作 a_{t-1} 和外部因素 $z_t = \mu(e_t)$，预测一个动作 a_t。强化学习最大化策略 π 的期望回报：

$$J(\pi) = \mathbb{E}_{\tau \sim p(\tau|\pi)} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right],$$

其中 $\tau = \{(x_0, a_0, r_0), (x_1, a_1, r_1)...\}$ 是智能体执行策略 π 时的轨迹，$p(\tau|\pi)$ 表示该轨迹在 π 下的似然。

通过自然约束实现稳定步态： 我们不是添加人工仿真噪声，而是在以下自然约束下训练我们的智能体。首先，奖励函数来源于最小化工作量和地面冲击的生物能量约束 [42]。我们发现这些奖励函数对于在仿真中学习现实步态至关重要。其次，我们在不平坦地形（图 2）上训练我们的策略，作为其他研究 [23] 用于足部间隙和对外部推力鲁棒性的额外奖励的替代方案。在这些自然约束下训练的行走策略可以无需任何修改地转移到现实世界中的简单设置（如混凝土或木制地板）。这与其他从仿真到现实的工作形成对比，这些工作要么将仿真与现实世界进行校准 [51, 23]，要么在现实世界中微调策略 [41]。然后，适应模块使其能够从简单设置扩展到非常具有挑战性的地形，如图 1 所示。

强化学习奖励：奖励函数鼓励智能体以最大速度 0.35 米/秒向前移动，并对急促和低效的运动进行惩罚。我们用 v 表示线速度，$\boldsymbol{\theta}$ 表示方向，$\boldsymbol{\omega}$ 表示角速度，所有值都在机器人的基坐标系中。我们另外定义关节角度为 q，关节速度为 $\dot{\mathrm{q}}$，关节力矩为 $\boldsymbol{\tau}$，脚部的地面反作

用力为 f ，脚部的速度为 $\mathrm{v_f}$ 以及二进制脚接触指示向量为 g 。时间 t 的奖励定义为以下各项的总和：

1) 正向：$\min(v_x^t, 0.35)$
2) 横向移动和旋转：$-\|v_y^t\|^2 - \|\omega_{\text{yaw}}^t\|^2$
3) 工作：$-|\boldsymbol{\tau}^T \cdot (\mathrm{q}^t - \mathrm{q}^{t-1})|$
4) 地面撞击：$-\|\mathrm{f}^t - \mathrm{f}^{t-1}\|^2$
5) 平滑性：$-\|\boldsymbol{\tau}^t - \boldsymbol{\tau}^{t-1}\|^2$
6) 动作幅度：$-\|\mathrm{a}^t\|^2$
7) 联合速度：$-\|\dot{\mathrm{q}}^t\|^2$
8) 方向：$-\|\boldsymbol{\theta}^t_{\text{roll, pitch}}\|^2$
9) Z 加速度：$-\|v_z^t\|^2$
10) 脚滑：$-\|\mathrm{diag}(\mathrm{g}^t) \cdot {\mathrm{v_f}}^t\|^2$

每个奖励项的缩放因子分别是 20 ，21 ，0.002 ，0.02 ，0.001 ，0.07 ，0.002 ，1.5 ，2.0 ，0.8 。

训练课程：如果我们天真地使用上述奖励函数来训练智能体，由于关节运动的罚项，它会学习保持静止。为防止这种情况，我们遵循 [23] 中描述的策略。我们从非常小的罚项系数开始训练，然后使用固定的课程逐渐增加这些系数的强度。随着训练的进行，我们还线性地增加其他扰动（如质量、摩擦力和电机强度）的难度。我们在地形方面没有任何课程，并从同一固定难度中随机采样地形剖面开始训练。

B. 适应模块

特权环境配置 e_t 以及其编码的外在向量 z_t 在现实世界部署过程中是不可访问的。因此，我们提出使用适应模块 ϕ 在线估计外在参数。而不是 e_t ，适应模块使用机器人最近的状态 $x_{t-k:t-1}$ 和动作 $a_{t-k:t-1}$ 来生成 $\hat{z}_t$ ，这是对真实外在向量 z_t 的估计。在我们的实验中，我们使用 $k = 50$ ，这对应于 0.5 的。

$$\hat{z}_t = \phi\big(x_{t-k:t-1}, a_{t-k:t-1}\big)$$

注意，我们不是预测 e_t ，这在典型的系统识别中是常见的情况，而是直接估计外参 z_t ，它仅编码了为了纠正给定的环境向量 e_t 行为应该如何变化。

为了训练适应模块，我们只需要状态-动作历史和 z_t 的目标值（由环境因子编码器 μ 提供）。这两者在仿真中都是可用的，因此，ϕ 可以通过监督学习进行训练以最小化：$\mathrm{MSE}(\hat{z}_t, z_t) = \|\hat{z}_t - z_t\|^2$，其中 $z_t = \mu(e_t)$ 。我们将 ϕ 建模为一个 1 -D CNN 来捕捉时间相关性（第 IV-B 节）。

一种收集状态-动作历史的方法是将训练好的基础策略 π 与真实值 z_t 进行展开。然而，这样的数据集只会包含机器人无缝行走的良好轨迹。在这些数据上训练的适应模块 ϕ 在部署过程中遇到专家轨迹的偏差时将不够稳健。

我们通过使用同策略数据（类似于 Ross et al. [45]）来训练 ϕ 。我们展开基础策略 π ，其中 $\hat{z}_t$ 是由随机初始化的策略 ϕ 预测的。然后，我们使用此状态动作历史与 真实值 z_t 配对来训练 ϕ 。我们反复重复此过程直到收敛。这种训练过程确保了 RMA 在训练期间能看到足够的探索轨迹，这是由于 a) 随机初始化的 ϕ ，以及 b) 对 $\hat{z}_t$ 的不完美预测。这增强了 RMA 在部署时的鲁棒性。

C. 异步部署

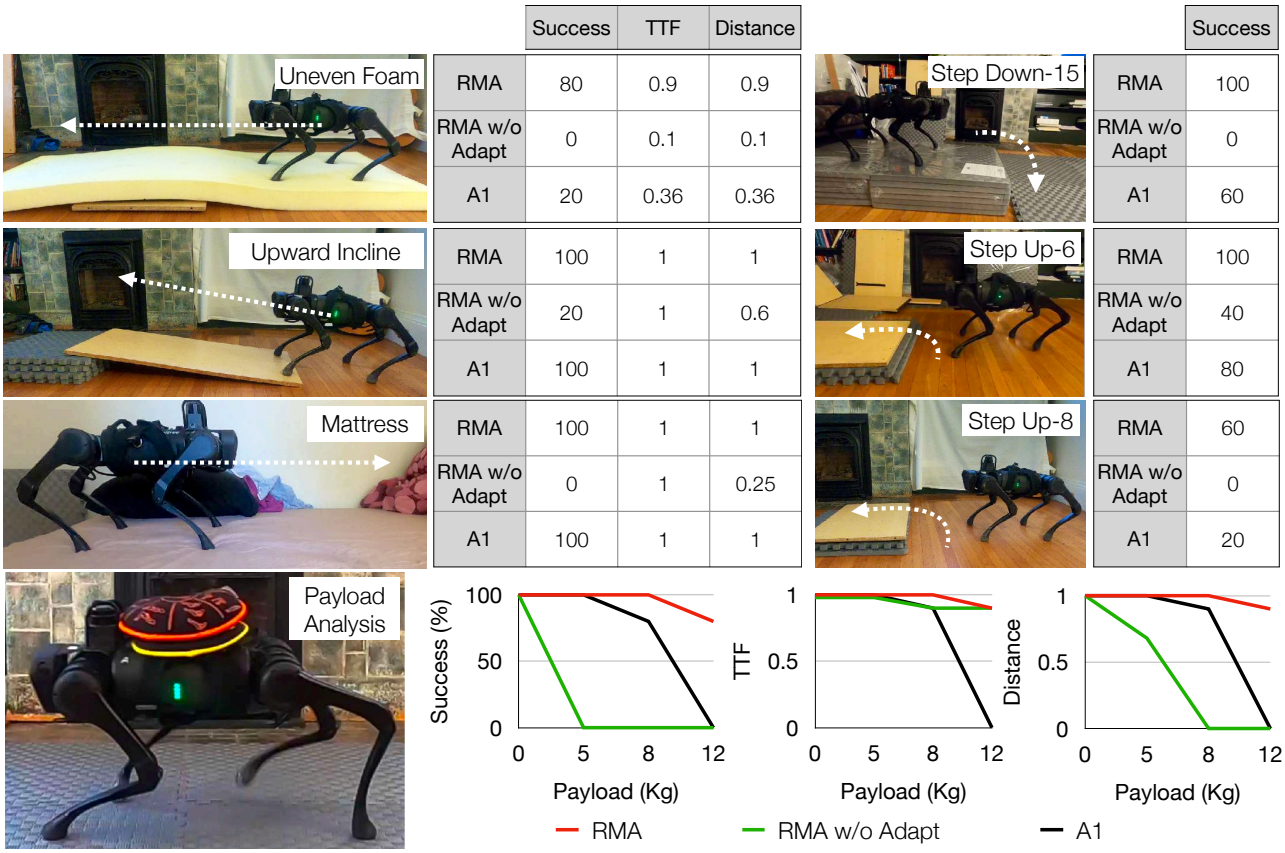
我们完全在仿真中训练 RMA，然后在不进行任何修改或微调的情况下将其部署到现实世界中。RMA 的两个子系统异步运行，并且频率相差很大，因此可以很容易地使用有限的板载计算资源运行。适应策略较慢，因为它基于 50 个时间步的状态-动作历史，大约每 0.1 秒（10 Hz）更新一次外部向量 $\hat{z}_t$。基础策略以 100 Hz 运行，并使用适应模块生成的最新 $\hat{z}_t$，以及当前状态和前一个动作来预测 a_t。这种异步执行在实践中不会影响性能，因为 $\hat{z}_t$ 在现实世界中变化相对较慢。

另一种方法是，我们可以训练一个基础策略，该策略直接以状态和动作历史为输入，而无需将它们解耦为两个模块。我们发现这（a）会导致不自然的步伐并在仿真中表现不佳，（b）只能在板载计算上以 10Hz 运行，（c）缺乏异步设计，而这种设计对于在无需任何同步或校准两个子系统的情况下将 RMA 无缝部署到真实机器人上至关重要。这种异步设计本质上是通过将相对不常变化的外部向量与快速变化的机器人状态解耦来实现的。

IV. 实验装置

A. 环境详情

硬件细节：我们在所有现实世界的实验中使用 Unitree 的 A1 机器人。A1 是一个相对低成本的中等大小的四足机器人。它有 18 个自由度，其中 12 个是驱动的（每条腿 3 个电机），重量约为 12 公斤。为了测量机器人



	Success	TTF	Distance
RMA	80	0.9	0.9
RMA w/o Adapt	0	0.1	0.1
A1	20	0.36	0.36
RMA	100	1	1
RMA w/o Adapt	20	1	0.6
A1	100	1	1
RMA	100	1	1
RMA w/o Adapt	0	1	0.25
A1	100	1	1

	Success
RMA	100
RMA w/o Adapt	0
A1	60
RMA	100
RMA w/o Adapt	40
A1	80
RMA	60
RMA w/o Adapt	0
A1	20

图 3: 我们在现实世界中的多个分布外设置中评估了 RMA。我们将 RMA 与 A1 的控制器以及没有适应模块的 RMA 进行比较。我们发现，RMA 能以 80% 的成功率迈出 15 厘米的高度，并能以 100% 的成功率走过未见过的可变形表面，例如记忆棉床垫和略微不平的泡沫。它还能成功地爬上斜坡和台阶。A1 的控制器无法在不平的泡沫上行走。在底部，我们还分析了三种方法的负载承载极限。我们看到，A1 控制器在负载容量为 8Kg 时性能开始下降。没有适应模块的 RMA 在负载超过 8Kg 时无法移动，但很少会摔倒。参考一下，A1 机器人的重量是 12Kg。总体而言，所提出的方法始终优于基准方法。报告的数字是基于 5 次试验的平均值。

Parameters	Training Range	Testing Range
Friction	[0.05, 4.5]	[0.04, 6.0]
K_p	[50, 60]	[45, 65]
K_d	[0.4, 0.8]	[0.3, 0.9]
Payload (Kg)	[0, 6]	[0, 7]
Center of Mass (cm)	[-0.15, 0.15]	[-0.18, 0.18]
Motor Strength	[0.90, 1.10]	[0.88, 1.22]
Re-sample Probability	0.004	0.01

表 I: 环境参数的值域。

的当前状态，我们使用电机编码器的关节位置和速度、IMU 传感器的滚动和俯仰以及脚部传感器的二值化足部接触指示器。部署的策略对机器人的关节使用位置控制。预测的期望关节位置通过具有固定增益的 PD 控制器转换为扭矩（$K_p = 55$ 和 $K_d = 0.8$ ）。

仿真设置：我们使用 RaiSim 仿真器 [22] 进行刚体和接触动力学仿真。我们从 Unitree 导入 A1 URDF 文件 [53]，并使用内置的分形地形生成器生成不平坦地形（分形八度 $= 2$，分形间隙 $= 2.0$，分形增益 $= 0.25$，z-比例 $= 0.27$ ）。每个强化学习回合最多持续 1000 步，如果机器人的高度降至 0.28 米以下，身体滚转幅度超过 0.4 弧度或俯仰角超过 0.2 弧度时将提前终止。策略的控制频率为 100 赫兹，仿真时间步长为 0.025 秒。

状态-动作空间: 状态是 30 维的，包含关节位置 (12 个值)、关节速度 (12 个值)、躯干的滚转和俯仰以及二进制足部接触指示器 (4 个值)。对于动作，我们对 12 个机器人关节使用位置控制。RMA 预测期望的关节角度 $a = \hat{\mathrm{q}} \in \mathbb{R}^{12}$，该角度通过 PD 控制器转换为力矩 $\boldsymbol{\tau}$：$\boldsymbol{\tau} = K_p\left(\hat{\mathrm{q}} - \mathrm{q}\right) + K_d\left(\hat{\dot{\mathrm{q}}} - \dot{\mathrm{q}}\right)$。$K_p$ 和 K_d 是手动指定的增益，目标关节速度 $\hat{\dot{\mathrm{q}}}$ 设置为 0。

环境变化：所有环境变化及其值域如表 I 所示。其中，e_t 包括机器人质量及其位置 (3 维)，电机强度 (12 维)，

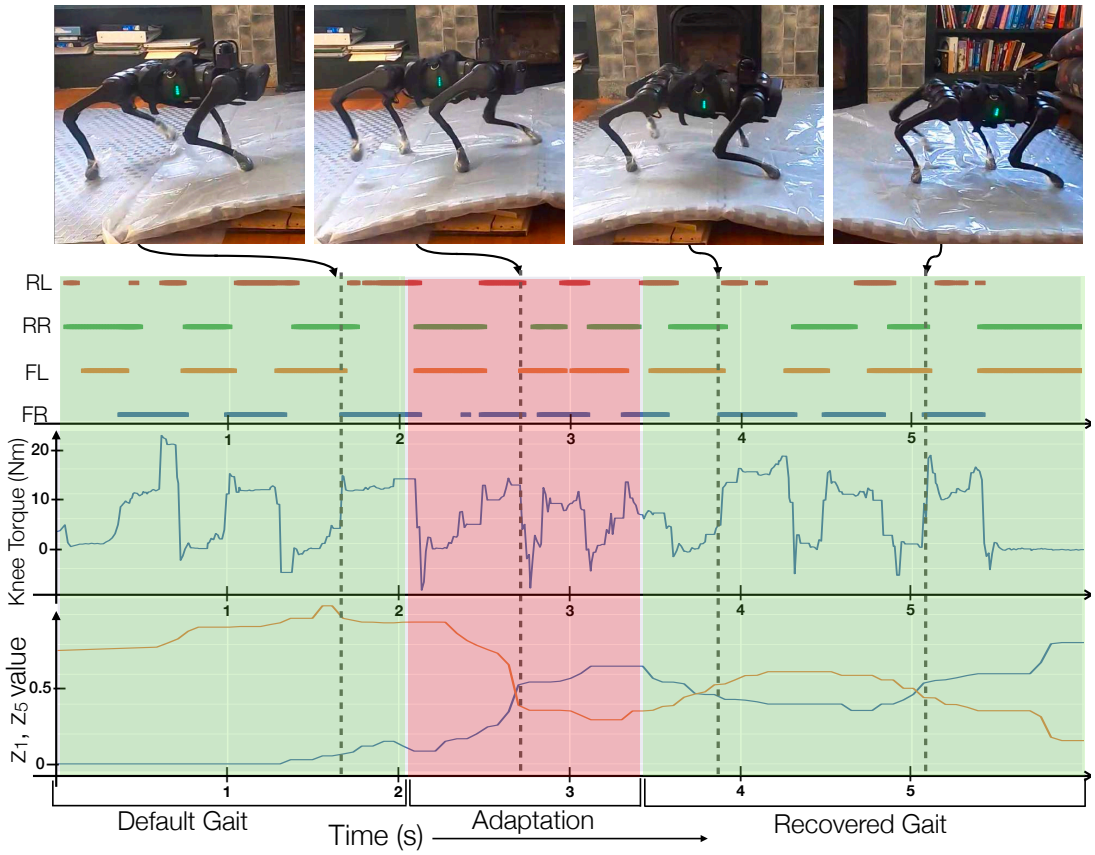


图 4: 我们分析 RMA，当机器人在有油的塑料板上行走，并且其脚部有额外的塑料覆盖。我们绘制了膝盖的扭矩和步态模式，该模式表明四个脚的接触情况（F/R 表示前/后，R/L 表示右/左）。底部图表显示了适应模块预测的外在向量 $\hat{z}$ 的中值滤波后的 1st 和 5th 分量。当机器人进入滑腻区域时，我们看到外在向量 $\hat{z}$ 的两个分量发生变化，表明适应模块已经检测到滑动事件。请注意，在适应之后，恢复的步态周期与原始相似，扭矩幅度增加，$\hat{z}$ 继续捕捉表面仍然滑腻的事实。RMA 在有油区域的运行中成功率为 90%。

摩擦力（标量）和局部地形高度（标量），构成一个 17 维向量。请注意，虽然地形轮廓的难度是固定的，但局部地形高度会随着智能体移动而变化。我们将每只脚下的地形高度离散化到小数点后第一位，然后取四只脚的最大值以得到一个标量。这确保了控制器不会严重依赖于对局部地形的快速和精确感知，并允许在部署期间以较低的更新频率异步使用基础策略。

B. 训练细节

基础策略和环境因子编码器架构： 基础策略是一个 3 层的多层感知机（MLP），它接收当前状态 $x_t \in \mathbb{R}^{30}$ 、前一个动作 $a_{t-1} \in \mathbb{R}^{12}$ 和外在向量 $z_t \in \mathbb{R}^8$ ，并输出 12 维的目标关节角度。隐藏层的维度是 128。环境因子编码器是一个 3 层的 MLP（隐藏层大小为 256, 128），用于将 $e_t \in \mathbb{R}^{17}$ 编码为 $z_t \in \mathbb{R}^8$ 。

适应模块架构： 适应模块首先使用 2 层 MLP 将最近的状态和动作嵌入到 32 维表示中。然后，3 层 1 -D CNN 在时间维度上卷积这些表示，以捕捉输入中的时间相关性。每层的输入通道数、输出通道数、核大小和步幅为 $[32, 32, 8, 4], [32, 32, 5, 1], [32, 32, 5, 1]$ 。展平的 CNN 输出被线性投影以估计 $\hat{z}_t$ 。

学习基础策略和环境因子编码器网络： 我们使用 PPO [48] 联合训练基础策略和环境编码器网络，每个 $15,000$ 迭代使用批量大小为 $80,000$ 的数据，分成 4 个小批量。学习率设置为 5e−4 。奖励项的系数在第III 节中给出。在普通台式机上训练大约需要 24 小时，其中 1 个 GPU 用于策略训练。在此期间，它模拟了 1.2 十亿步。

学习适应模块: 我们使用监督学习和同策略数据来训练适应模块。我们使用 Adam 优化器 [29] 来最小化均方误差损失。我们以学习率为 5e−4 的方式运行最优化过

程 1000 迭代，每次使用 80,000 的批量大小，拆分为 4 个小批量。在普通台式机上训练此模块需要 3 小时，其中使用 1 个 GPU 来训练策略。在此期间，它模拟了 80 百万步。

V. 结果与分析

我们比较了 RMA 在仿真中的性能（表II）与多个基准。我们还在真实世界的室内设置中与 A1 随附的制造商控制器进行了额外比较（图3），并在非常多样化的地形中进行了 RMA 的野外测试（图1）。视频见 https://ashish-kmr.github.io/rma-legged-robots/

基准方法：我们与以下基准方法进行比较：

1) A1 控制器：默认的机器人制造商控制器，采用基于力的控制方案和 MPC。
2) 通过领域随机化（鲁棒性）的鲁棒性：基础策略在不使用 z_t 的情况下进行训练，以使其在训练值域 [52, 40] 中具有鲁棒性。
3) 专家适应策略（专家）：在仿真中，我们可以使用外在向量 z_t 的真实值。这是 RMA 性能的上限。
4) RMA 无适应: 我们也可以评估基础策略在没有适应模块情况下的性能，以消融分析适应模块的重要性。
5) 系统辨识 [57]: 不再预测 $\hat{z}_t$ ，而是直接预测系统参数 $\hat{e}_t$ 。
6) 优势加权回归用于领域自适应（AWR） [41]: 在测试环境中使用策略的实际世界滚动结果，通过 AWR 优化 $\hat{z}_t$ 离线。

学习基准使用相同的架构、奖励函数和其他超参数进行训练。

指标：我们使用以下指标来比较 RMA 与基准的性能：(1) 跌倒时间除以最大回合长度以获得介于 $0-1$ 之间的规范化值 (TTF)；(2) 平均向前奖励，(3) 成功率，(4) 覆盖距离，(5) 适应所需的探索样本，(6) 施加的扭矩，(7) 作为扭矩导数的平滑度以及 (7) 地面冲击（补充材料中有详细说明）。

A. 室内实验

在现实世界中，我们将 RMA 与 A1 的控制器以及与 RMA 不带适应模块的情况进行比较（图 3）。我们仅将比较限制在这两个基准上，以避免对机器人硬件造成损坏。我们为每种方法运行 5 次试验，并报告成功概率、跌倒时间（TTF）和覆盖距离。请注意，如果某种方法在任务中严重失败，我们只运行两次试验，然后报告失败。这是为了尽量减少对机器人硬件的损坏。我们有以下室内设置：

- n-kg **载荷**: 带着 n-kg 载荷行走 300 厘米。
- StepUp-n: 用 n 厘米高的台阶向上迈步。
- **不均匀泡沫**: 在中心抬高的泡沫上行走 180 厘米。
- **床垫**: 在记忆棉床垫上行走 60 厘米。
- **降步**-n: 降低一个 n 厘米高的台阶。
- **斜坡**: 沿 6 度的斜坡向上行走。
- **油性表面**: 穿过一个油污区域。

每次 StepUp-n 和 StepDown-n 的试验在成功或失败后都会终止。因此，我们仅报告这些任务的成功率，因为其他指标是没有意义的。

我们观察到 RMA 在所有这些设置中都能实现高成功率，在某些情况下，其性能远超 A1 的控制器。我们发现关闭适应模块会显著降低性能，这表明适应模块对于解决这些任务至关重要。A1 的控制器在不平坦的泡沫和大台阶上下时遇到困难。在大多数失败情况下，控制器因不稳定的立足点而变得不稳定。在负载分析中，A1 的控制器能够处理高于标称负载（5Kg）的负载，但随着负载增加，开始下垂，最终掉落。相比之下，RMA 保持了高度，并能够以高成功率携带高达 12Kg（体重的 100%）。RMA 无适应模块大多不会掉落，但也不会向前移动。我们还在一个更具挑战性的任务中评估了 RMA，即在塑料包裹脚部的情况下穿越油性路径。机器人成功地走过了油性区域。有趣的是，RMA 无适应模块在没有微调或仿真校准的情况下，能够在木制地板上成功行走。这与现有方法形成对比，现有方法即使在平坦和静态环境中也会进行仿真校准 [51, 23] 或在测试时微调其策略 [41]。

B. 户外实验

我们展示了 RMA 在多个具有挑战性的户外环境中的性能，如图 1 所示。机器人在所有试验中都能成功地在沙子、泥巴和泥土上行走，没有任何失败。这些地形由于脚部下沉和卡住而使运动变得困难，这要求机器人动态地改变立足点以确保稳定性。RMA 在在高草或穿越灌木丛上行走时的成功率为 100%。这种地形会阻碍机器人的脚部，在行走时使其周期性地不稳定。为了在这些设置中成功行走，机器人必须对抗脚部缠绕，并

	Success (%)	TTF	Reward	Distance (m)	Samples	Torque	Smoothness	Ground Impact
Robust [52, 40]	62.4	0.80	4.62	1.13	0	527.59	122.50	4.20
SysID [57]	56.5	0.74	4.82	1.17	0	565.85	149.75	4.03
AWR [41]	41.7	0.65	4.17	0.95	40k	599.71	162.60	4.02
RMA w/o Adapt	52.1	0.75	4.72	1.15	0	524.18	106.25	4.55
RMA	73.5	0.85	5.22	1.34	0	500.00	92.85	4.27
Expert	76.2	0.86	5.23	1.35	0	485.07	85.56	3.90

表 II: **仿真测试结果**: 我们在仿真中将我们方法的性能与基准方法进行了比较。我们的训练和测试情景如表 I 所示。在测试期间，每一步都以 0.01 的重采样概率在回合内重新采样环境参数。基准方法和指标在第 V 节中定义。报告的数字是基于 3 个随机初始化策略和每个随机初始化 1000 个回合的平均值。RMA 的性能优于所有基准方法，与专家相比仅略有下降。

积极地穿过一些障碍物。我们还在徒步小径上的一些楼梯上评估了我们的机器人。机器人在 70% 的试验中取得了成功，考虑到机器人在训练期间从未见过楼梯，这仍然令人印象深刻。最后，我们在建筑废墟上测试了机器人，当沿着泥堆下坡时，机器人成功率为 100%，而在横跨水泥堆和碎石堆时成功率为 80%。水泥堆和碎石堆本身位于一个侧向陡峭倾斜的地面上，这使得机器人横跨这些堆非常具有挑战性。

C. 仿真结果

我们将在仿真中将我们的方法与基准方法进行比较（表 II）。我们根据表 I 对训练和测试参数进行采样，并在回合内以 0.004 和 0.01 的重采样概率分别对训练和测试进行重采样。报告的数字是基于 3 个随机初始化的策略和每个随机初始化 1000 个回合的平均值。RMA 在仅与专家性能略有下降的情况下表现最佳。不断变化的环境导致 AWR 性能较差，因为它适应速度非常慢。由于鲁棒基准对内外部因素不敏感，它学习了一个非常保守的策略，从而在性能上有所损失。需要注意的是，SysID 的低性能表明显式估计 e_t 是困难的，并且不是实现卓越性能所必需的。我们还与 RMA 无适应进行了比较，这表明没有适应模块时性能显著下降。

D. 适应性分析

我们分析步态模式、扭矩曲线和估计的外在向量 $\hat{z}_t$ 以适应滑腻表面（图 4）。我们在地面的塑料表面上倒油，并且另外用塑料覆盖机器人的脚部。然后机器人尝试穿过滑腻区域并成功适应了它。我们发现 RMA 在 90% 的油污区域运行中是成功的。对于一次这样的试验，我们在图 4 中绘制了膝盖的扭矩曲线、步态模式以及外在向量 $\hat{z}_t$ 的中值滤波后的 1st 和 5th 分量。当机器人在大约 2 秒时第一次开始打滑时，打滑扰乱了机器人的正常运动，之后它进入适应阶段。这在外在向量的绘制分量中可以明显看出，这些分量会随着打滑而变化。检测到的打滑使机器人能够恢复并继续在滑腻区域上行走。请注意，虽然适应后，扭矩稳定到稍高的幅度，步态周期大致恢复，但外在向量并未恢复，并继续记录表面是滑腻的事实。请参见补充材料中的更多分析。

VI. 结论

我们提出了 RMA 算法，用于在各种地形中对腿部机器人进行实时适应。不需要示范或预定义的运动模板。尽管只能访问本体感觉数据，机器人也可以下楼并跨过岩石。然而，一个没有视觉的机器人存在局限性。较大的扰动，例如下楼时突然跌倒，或由于岩石导致的多条腿受阻，有时会导致失败。为了开发真正可靠的行走机器人，我们需要不仅使用本体感觉，还要使用配备机载视觉传感器的外感受。视觉在指导长距离、快速运动中的重要性已被广泛研究，例如由 [35]，这是未来工作的重要方向。

致谢

我们感谢黄珍敏（Jemin Hwangbo）在仿真平台方面提供的帮助，以及库希尔 · 斯里纳瑟（Koushil Sreenath）和斯图尔特 · 安德森（Stuart Anderson）在本项目进行过程中提供的有益反馈。我们还要感谢克莉尔 · 托明（Claire Tomlin）、尚卡尔 · 萨斯特里（Shankar Sastry）、克里斯 · 阿特金森（Chris Atkeson）、阿拉文德 · 西瓦库马尔（Aravind Sivakumar）、伊利亚 · 拉多萨沃维奇（Ilija Radosavovic）和拉塞尔 · 门东萨（Russell Mendonca）对论文提出的高质量反馈。这项

研究是 BAIR-FAIR 合作项目的一部分，最近也得到了 DARPA 机器常识计划的支持。

参考文献

[1] MYM Ahmed and N Qin. Surrogate-based aerodynamic design optimization: Use of surrogates in aerodynamic design optimization. In International Conference on Aerospace Sciences and Aviation Technology, 2009.

[2] Aaron D Ames, Kevin Galloway, Koushil Sreenath, and Jessy W Grizzle. Rapidly exponentially stabilizing control lyapunov functions and hybrid zero dynamics. IEEE Transactions on Automatic Control, 2014.

[3] Taylor Apgar, Patrick Clary, Kevin Green, Alan Fern, and Jonathan W Hurst. Fast online trajectory optimization for the bipedal robot cassie. In Robotics: Science and Systems, 2018.

[4] Monica Barragan, Nikolai Flowers, and Aaron M. Johnson. MiniRHex: A small, open-source, fully programmable walking hexapod. In Robotics: Science and Systems Workshop on "Design and Control of Small Legged Robots", 2018.

[5] Gerardo Bledt, Matthew J Powell, Benjamin Katz, Jared Di Carlo, Patrick M Wensing, and Sangbae Kim. Mit cheetah 3: Design and control of a robust, dynamic quadruped robot. In 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018.

[6] Adrian Boeing and Thomas Bräunl. Leveraging multiple simulators for crossing the reality gap. In 2012 12th International Conference on Control Automation Robotics & Vision (ICARCV). IEEE, 2012.

[7] Josh C Bongard and Hod Lipson. Nonlinear system identification using coevolution of models and tests. IEEE Transactions on Evolutionary Computation, 2005.

[8] Roberto Calandra, André Seyfarth, Jan Peters, and Marc Peter Deisenroth. Bayesian optimization for learning gaits under uncertainty. Annals of Mathematics and Artificial Intelligence, 2016.

[9] Krzysztof Choromanski, Atil Iscen, Vikas Sindhwani, Jie Tan, and Erwin Coumans. Optimizing simulations with noise-tolerant structured exploration. In 2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018.

[10] Ignasi Clavera, Anusha Nagabandi, Simin Liu, Ronald S. Fearing, Pieter Abbeel, Sergey Levine, and Chelsea Finn. Learning to adapt in dynamic, real-world environments through meta-reinforcement learning. In International Conference on Learning Representations, 2019.

[11] Martin De Lasa, Igor Mordatch, and Aaron Hertzmann. Feature-based locomotion controllers. ACM Transactions on Graphics (TOG), 2010.

[12] Jared Di Carlo, Patrick M Wensing, Benjamin Katz, Gerardo Bledt, and Sangbae Kim. Dynamic locomotion in the mit cheetah 3 through convex model-predictive control. In 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018.

[13] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In International Conference on Machine Learning. PMLR, 2017.

[14] Scott Fujimoto, Herke Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In International Conference on Machine Learning. PMLR, 2018.

[15] Christian Gehring, Stelian Coros, Marco Hutter, Carmine Dario Bellicoso, Huub Heijnen, Remo Diethelm, Michael Bloesch, Péter Fankhauser, Jemin Hwangbo, Mark Hoepflinger, et al. Practice makes perfect: An optimization-based approach to controlling agile motions for a quadruped robot. IEEE Robotics & Automation Magazine, 2016.

[16] Hartmut Geyer, Andre Seyfarth, and Reinhard Blickhan. Positive force feedback in bouncing gaits? Proceedings of the Royal Society of London. Series B: Biological Sciences, 2003.

[17] Xiaoxiao Guo, Wei Li, and Francesco Iorio. Convolutional neural networks for steady flow approximation. In Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining, 2016.

[18] Tuomas Haarnoja, Sehoon Ha, Aurick Zhou, Jie Tan, George Tucker, and Sergey Levine. Learning to walk via deep reinforcement learning. In Robotics: Science and Systems, 2019.

[19] Josiah Hanna and Peter Stone. Grounded action transformation for robot learning in simulation. In Proceedings of the AAAI Conference on Artificial Intelligence, 2017.

[20] Marco Hutter, Christian Gehring, Dominic Jud, Andreas Lauber, C Dario Bellicoso, Vassilios Tsounis, Jemin Hwangbo, Karen Bodie, Peter Fankhauser, Michael Bloesch, et al. Anymal-a highly mobile and dynamic quadrupedal robot. In 2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2016.

[21] Jemin Hwangbo. RaisimGymTorch. https://raisim.com/sections/RaisimGymTorch.html, 2020-2021.

[22] Jemin Hwangbo, Joonho Lee, and Marco Hutter. Per-contact iteration method for solving contact dynamics. IEEE Robotics and Automation Letters, 2018. URL www.raisim.com.

[23] Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun, and Marco Hutter. Learning agile and dynamic motor skills for legged robots. Science Robotics, 2019.

[24] Dong Jin Hyun, Jongwoo Lee, SangIn Park, and Sangbae Kim. Implementation of trot-to-gallop transition and subsequent gallop on the mit cheetah i. The International Journal of Robotics Research, 2016.

[25] Atil Iscen, Ken Caluwaerts, Jie Tan, Tingnan Zhang, Erwin Coumans, Vikas Sindhwani, and Vincent Vanhoucke. Policies modulating trajectory generators. In Conference on Robot Learning. PMLR, 2018.

[26] Aaron M Johnson, Thomas Libby, Evan Chang-Siu, Masayoshi Tomizuka, Robert J Full, and Daniel E Koditschek. Tail assisted dynamic self righting. In Adaptive Mobile Robotics. World Scientific, 2012.

[27] Mrinal Kalakrishnan, Jonas Buchli, Peter Pastor, Michael Mistry, and Stefan Schaal. Fast, robust quadruped locomotion over challenging terrain. In 2010 IEEE International Conference on Robotics and Automation. IEEE, 2010.

[28] Mahdi Khoramshahi, Hamed Jalaly Bidgoly, Soroosh Shafiee, Ali Asaei, Auke Jan Ijspeert, and Majid Nili Ahmadabadi. Piecewise linear spine for speed–energy efficiency trade-off in quadruped robots. Robotics and Autonomous Systems, 2013.

[29] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In 3rd International Conference on Learning Representations, 2015.

[30] Jens Kober, J Andrew Bagnell, and Jan Peters. Reinforcement learning in robotics: A survey. The International Journal of Robotics Research, 2013.

[31] Sylvain Koos, Jean-Baptiste Mouret, and Stéphane Doncieux. Crossing the reality gap in evolutionary robotics by promoting transferable controllers. In Proceedings of the 12th annual conference on Genetic and evolutionary computation, 2010.

[32] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. Science robotics, 2020.

[33] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. In ICLR, 2016.

[34] Jingru Luo and Kris Hauser. Robust trajectory optimization under frictional contact with iterative learning. Autonomous Robots, 2017.

[35] Jonathan Samir Matthis, Jacob L Yates, and Mary M Hayhoe. Gaze and the control of foot placement when walking in natural terrain. Current Biology, 2018.

[36] Hirofumi Miura and Isao Shimoyama. Dynamic walk of a biped. The International Journal of Robotics Research, 1984.

[37] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In International conference on machine learning. PMLR, 2016.

[38] Ofir Nachum, Michael Ahn, Hugo Ponte, Shixiang Shane Gu, and Vikash Kumar. Multi-agent manipulation via locomotion using hierarchical sim2real. In Conference on Robot Learning. PMLR, 2020.

[39] Michael Neunert, Thiago Boaventura, and Jonas Buchli. Why off-the-shelf physics simulators fail in evaluating feedback controller performance-a case study for quadrupedal robots. In Advances in Cooperative Robotics. World Scientific, 2017.

[40] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In 2018 IEEE international conference on robotics and automation (ICRA). IEEE, 2018.

[41] Xue Bin Peng, Erwin Coumans, Tingnan Zhang, Tsang-Wei Edward Lee, Jie Tan, and Sergey Levine. Learning agile robotic locomotion skills by imitating animals. In Robotics: Science and Systems, 2020.

[42] Delyle T Polet and John EA Bertram. An inelastic quadrupedal model discovers four-beat walking, two-beat running, and pseudo-elastic actuation as energetically optimal. PLoS computational biology, 2019.

[43] Marc H Raibert. Hopping in legged systems—modeling and simulation for the two-dimensional one-legged case. IEEE Transactions on Systems, Man, and Cybernetics, 1984.

[44] Nathan Ratliff, Matt Zucker, J Andrew Bagnell, and Siddhartha Srinivasa. Chomp: Gradient optimization techniques for efficient motion planning. In 2009 IEEE International Conference on Robotics and Automation. IEEE, 2009.

[45] Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In Proceedings of the fourteenth international conference on artificial intelligence and statistics, 2011.

[46] Uluc Saranli, Martin Buehler, and Daniel E Koditschek. Rhex: A simple and highly mobile hexapod robot. The International Journal of Robotics Research, 2001.

[47] John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In 4th International Conference on Learning Representations, 2016.

[48] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017.

[49] Xingyou Song, Yuxiang Yang, Krzysztof Choromanski, Ken Caluwaerts, Wenbo Gao, Chelsea Finn, and Jie Tan. Rapidly adaptable legged robots via evolutionary meta-learning. In International Conference on Intelligent Robots and Systems (IROS), 2020.

[50] Koushil Sreenath, Hae-Won Park, Ioannis Poulakakis, and Jessy W Grizzle. A compliant hybrid zero dynamics controller for stable, efficient and fast bipedal walking on mabel. The International Journal of Robotics Research, 2011.

[51] Jie Tan, Tingnan Zhang, Erwin Coumans, Atil Iscen, Yunfei Bai, Danijar Hafner, Steven Bohez, and Vincent Vanhoucke. Sim-to-real: Learning agile locomotion for quadruped robots. In Robotics: Science and Systems, 2018.

[52] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schnei-

der, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In 2017 IEEE/RSJ international conference on intelligent robots and systems (IROS). IEEE, 2017.

[53] Xingxing Wang. Unitree Robotics. https://www.unitree.com/.

[54] Zhaoming Xie, Xingye Da, Michiel van de Panne, Buck Babich, and Animesh Garg. Dynamics randomization revisited: A case study for quadrupedal locomotion. arXiv preprint arXiv:2011.02404, 2020.

[55] Yuxiang Yang, Ken Caluwaerts, Atil Iscen, Tingnan Zhang, Jie Tan, and Vikas Sindhwani. Data efficient reinforcement learning for legged robots. In Conference on Robot Learning. PMLR, 2020.

[56] KangKang Yin, Kevin Loken, and Michiel Van de Panne. Simbicon: Simple biped locomotion control. ACM Transactions on Graphics (TOG), 2007.

[57] Wenhao Yu, Jie Tan, C. Karen Liu, and Greg Turk. Preparing for the unknown: Learning a universal policy with online system identification. In Robotics: Science and Systems, 2017.

[58] Wenhao Yu, C Karen Liu, and Greg Turk. Policy transfer with strategy optimization. In International Conference on Learning Representations, 2018.

[59] Wenhao Yu, Visak C. V. Kumar, Greg Turk, and C. Karen Liu. Sim-to-real transfer for biped locomotion. In 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2019.

[60] Wenhao Yu, Jie Tan, Yunfei Bai, Erwin Coumans, and Sehoon Ha. Learning fast adaptation with meta strategy optimization. IEEE Robotics and Automation Letters, 2020.

[61] Wenxuan Zhou, Lerrel Pinto, and Abhinav Gupta. Environment probing interaction policies. In 7th International Conference on Learning Representations, ICLR 2019, 2019.

[62] J Zico Kolter and Andrew Y Ng. The stanford littledog: A learning and rapid replanning approach to quadruped locomotion. The International Journal of Robotics Research, 2011.

[63] Matt Zucker, J Andrew Bagnell, Christopher G Atkeson, and James Kuffner. An optimization approach to rough terrain locomotion. In 2010 IEEE International Conference on Robotics and Automation. IEEE, 2010.

[64] Matt Zucker, Nathan Ratliff, Martin Stolle, Joel Chestnutt, J Andrew Bagnell, Christopher G Atkeson, and James Kuffner. Optimization and learning for rough terrain legged locomotion. The International Journal of Robotics Research, 2011.

附录
RMA：用于腿式机器人的快速运动适应

S1. 指标

我们使用多个指标（以国际单位制单位）来评估和比较 RMA 与基准的性能：

- 成功率：在下一节中定义的顺利完成任务的平均比率。
- 下落时间（TTF）：测量发生下落前的时间。我们将其除以回合的最大持续时间，并报告一个介于 0 和 1 之间的规范化的值。
- 奖励：如主论文第 III-A 节所述的多个回合中平均步进前向奖励加上侧向奖励。
- 距离：每个回合中覆盖的平均距离。对于现实世界实验，我们报告规范化的距离，其中通过特定于任务的最大距离进行归一化。
- 适应样本：为了使运动策略适应，测试环境中需要探索的控制步骤数量。
- 力矩：每个关节力矩的平方 L2 范数 $\|\boldsymbol{\tau}^t\|^2$.
- 扰动：delta 扭矩的平方 L2 范数 $\|\boldsymbol{\tau}^t - \boldsymbol{\tau}^{t-1}\|^2$ 。
- 地面冲击：每个脚的地面反作用力变化的平方 L2 范数 $\|\mathrm{f}^t - \mathrm{f}^{t-1}\|^2$ 。

S1. 额外训练和部署细节

训练流水线如算法 1 所示，而部署流水线如算法 2 所示。

我们使用 PPO [48] 来训练基础策略和环境因子编码器。我们总共训练 $15,000$ 迭代。在每次迭代中，我们收集一个批量的 $80,000$ 状态-动作转移，该批量被平均分成 4 个小批量。每个小批量依次输入到基础策略和环境因子编码器中进行 4 轮计算损失和误差反向传播。损失是代理策略损失和 0.5 倍价值损失的总和。我们将动作对数概率比率限制在 0.8 和 1.2 之间，并将目标值限制在相应旧值的 $0.8 - 1.2$ 倍范围内。我们排除了基础策略的熵正则化，但将参数化高斯动作空间的标准差约束为大于 0.2 以确保探索。泛化优势估计 [47] 中的 λ 和 γ 分别设置为 0.95 和 0.998 。我们使用 Adam 优化器 [29] ，其中我们将学习率设置为 5e−4 ，β 设置为 $(0.9, 0.999)$ ，ϵ 设置为 1e−8 。参考实现可以在 RaisimGymTorch 库 [21] 中找到。

如果我们天真地使用聚合所有项的奖励函数来训练我们的智能体，由于罚项，它会学会摔倒。为了防止这种崩溃，我们遵循 [23] 中描述的策略。除了所有奖励项的缩放因子外，我们按照主论文第三节 A 部分的定义，对罚项 $3 - 10$ 应用一个小的乘数 k_t。我们从一个非常小的 k_0 开始训练，将其设置为 0.03，然后使用固定的课程表指数增加这些系数：$k_{t+1} = k_t^{0.997}$，其中 t 是迭代次数。学习过程如图S2所示。

S1. 额外的现实世界适应性分析

除了主论文图 4 中的油面行走实验外，我们还分析了质量适应情况下的步态模式和扭矩剖面，如图S3所示。我们在运行过程中将 5 公斤的负载扔在机器人的背部，并绘制了膝盖的扭矩剖面、步态模式以及外参向量 $\hat{z}_t$ 的 2th 和 7th 组件，如图S3 所示。我们观察到额外的负载干扰了机器人的正常运动，之后它进入适应阶段并最终从干扰中恢复。当负载落在机器人上时，可以注意到外参向量的绘制组件会随着滑动而变化。适应后，我们看到扭矩稳定到比之前更高的幅度以应对负载，步态周期大致得到恢复。

S2. 额外的仿真测试

在图 S4 中，我们进一步在极端仿真环境中测试 RMA，并展示了其在三种环境变化类型中的性能：在 A1 机器人基础上增加的负载、地形高程变化（z-scale 在分形地形生成器中的使用，详细内容见主论文第 IV 节 Simulation Setup），以及机器人脚部与地形之间的摩擦系数。我们展示了 RMA 在成功率、TTF 和奖励方面的优势，这些定义见章节 S1。

Algorithm 1: Rapid Motor AdaptationTraining

Phase 1 Randomly initialize the base policy π; Randomly initialize the environmental factor encoder μ; Empty replay buffer D_1;

```
for 0 ≤ itr ≤ N^1_itr do
    for 0 ≤ i ≤ N_env do
        x_0, e_0 ← envs[i].reset();
        for 0 ≤ t ≤ T do
            z_t ← μ(e_t);
            a_t ← π(x_t, a_{t−1}, z_t);
            x_{t+1}, e_{t+1}, r_t ← envs[i].step(a_t);
            Store ((x_t, e_t), a_t, r_t, (x_{t+1}, e_{t+1})) in D_1;
        end
    end
    Update π and μ using PPO [48];
    Empty D_1;
end
```

Phase 2 Randomly initialize the adaptation module ϕ parameterized by θ_ϕ; Empty mini-batch D_2;

```
for 0 ≤ itr ≤ N^2_itr do
    for 0 ≤ i ≤ N_env do
        x_0, e_0 ← envs[i].reset();
        for 0 ≤ t ≤ T do
            ẑ_t ← φ(x_{t−k:k}, a_{t−k−1:k−1});
            z_t ← μ(e_t);
            a_t ← π(x_t, a_{t−1}, ẑ_t);
            x_{t+1}, e_{t+1}, _ ← envs[i].step(a_t);
            Store (ẑ_t, z_t) in D_2;
        end
    end
    θ_φ ← θ_φ − λ_{θ_φ} ∇_{θ_φ} 1/(T N_env) Σ ||ẑ_t − z_t||^2;
    Empty D_2;
end
```

Algorithm 2: Rapid Motor AdaptationDeployment

```
Process 1 operating at 100 Hz;
t ← 0;
while not fall do
    a_t ← π(x_t, a_{t−1}, ẑ_async);
    x_{t+1} ← env.step(a_t);
    t ← t + 1;
end

Process 2 operating at 10 Hz;
while not fall do
    ẑ_async ← φ(x_{t−k:k}, a_{t−k−1:k−1});
end
```

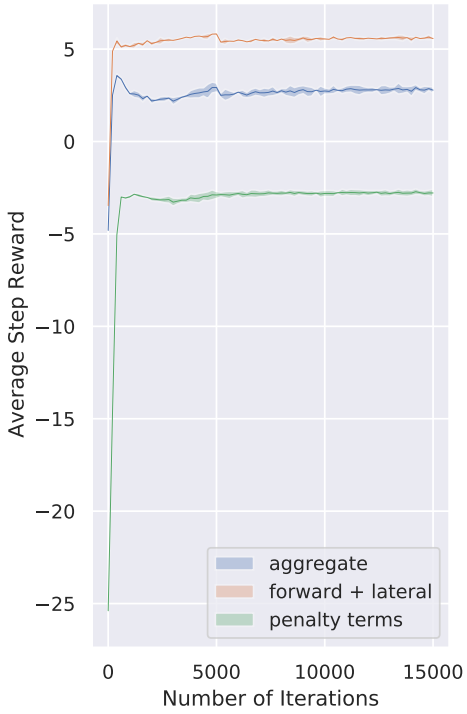


图 S2: 我们绘制了在总 15,000 次训练迭代中的平均步数奖励。我们展示了所有奖励项聚合后的奖励收敛趋势，前向 + 侧向奖励，以及罚项的总和。它还显示了在训练开始时对罚项应用一个小乘数的必要性；否则，机器人最初只有负面经验，无法快速学会行走。

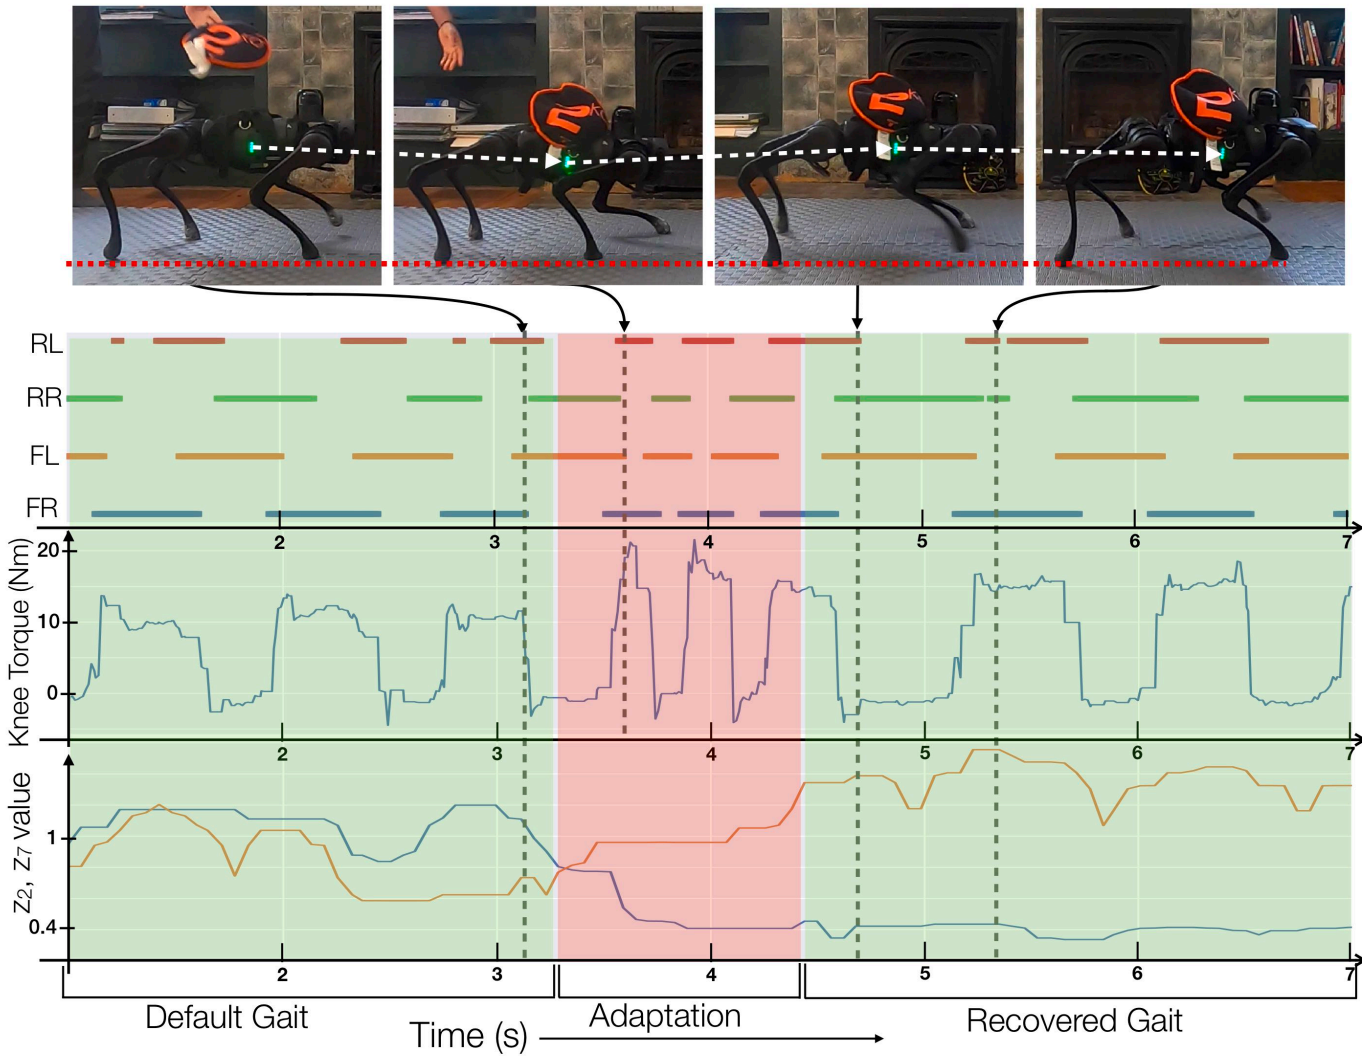


图 S3: 我们分析当我们在机器人背部放置一个 5 千克的有效载荷时，RMA 行为的变化。需要说明的是，我们已经翻转了图像，以便运动看起来是从左到右，这就是为什么沙袋上的标签看起来是 2 千克。我们绘制了膝盖的扭矩曲线和步态模式。底部的图显示了由适应模块预测的外在向量 $\hat{z}$ 的中值滤波后的 2nd 和 7th 分量。当 5 千克的有效载荷被扔到机器人背部时，我们看到机器人的质心下降，随后适应模块从中恢复。在底部的图中，我们看到估计的外在向量的绘制分量有一个响应跳跃，表明适应模块已经检测到了额外的有效载荷。请注意，在适应之后，恢复的步态周期大致与原来相似，扭矩大小增加，并且外在向量继续捕捉到机器人背部 5 千克有效载荷的存在。

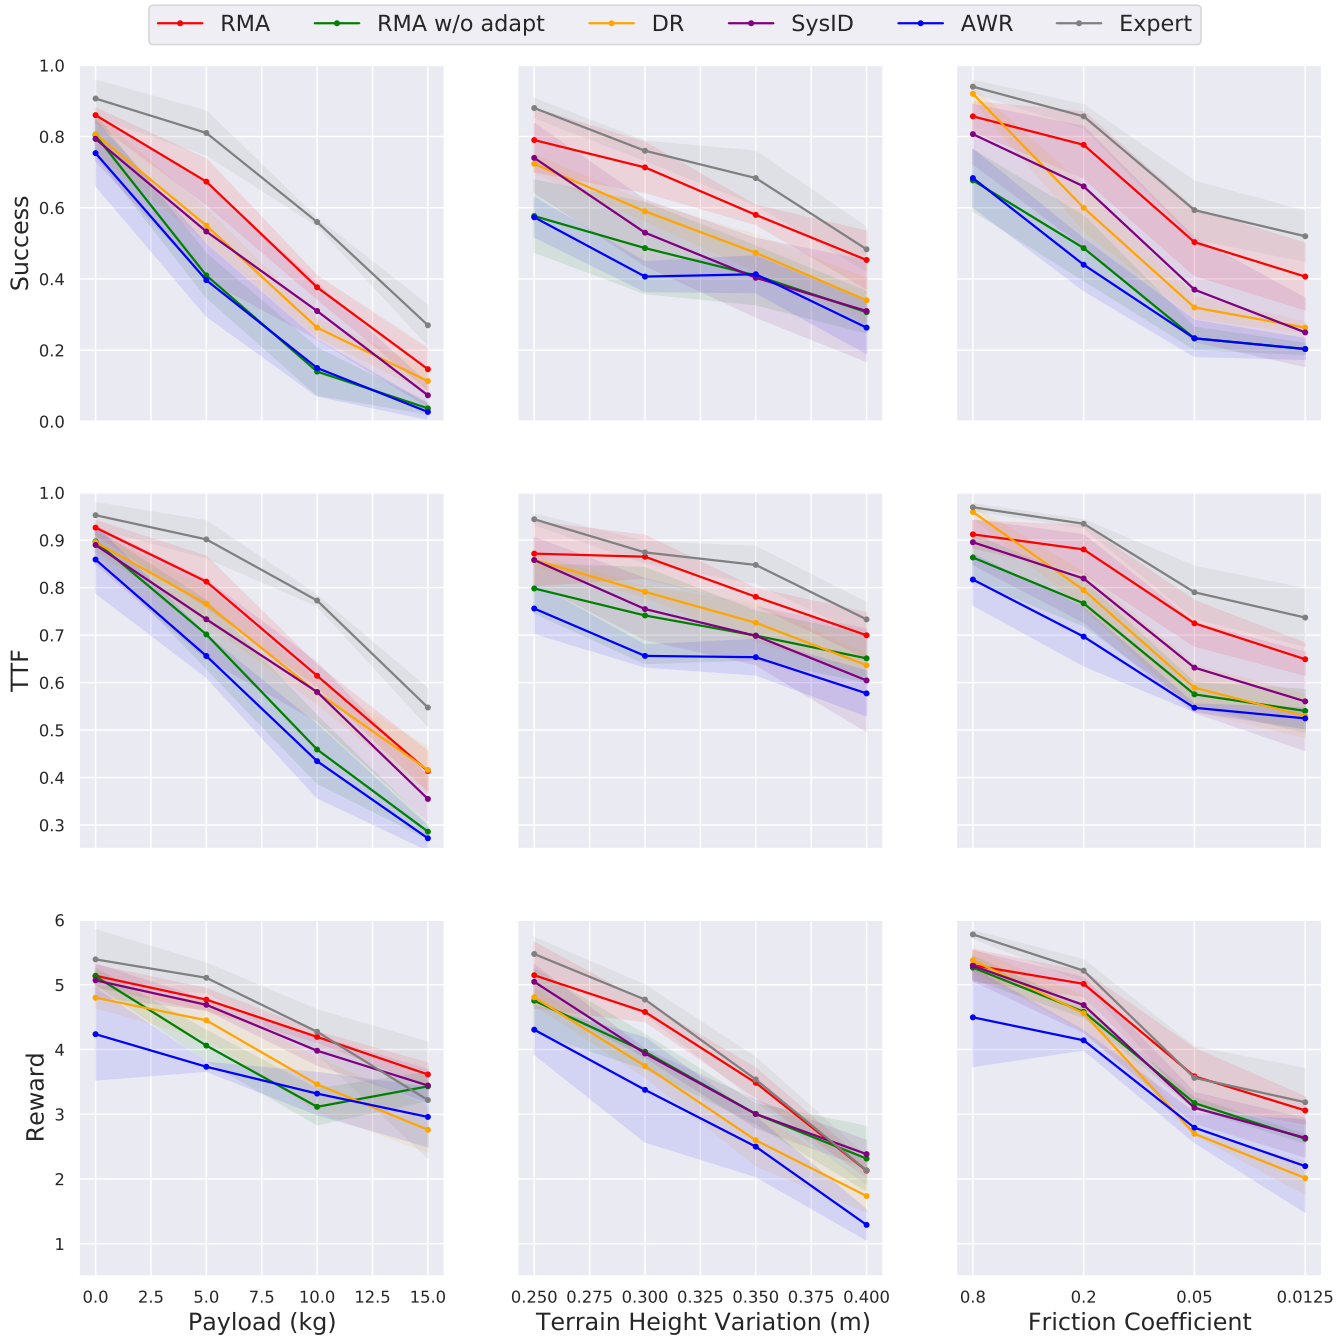


图 S4: **仿真泛化结果：**我们进一步在仿真中比较了我们方法与基准方法的泛化性能。我们选取了三个可能在现实世界中变化较大的物理参数：机器人上的负载、地形高度变化以及机器人脚与地形之间的摩擦系数。我们根据主论文中表 II 的训练值域设置其他环境参数。基准方法和指标在主论文第五节和附录S1中定义。我们报告了 3 个随机初始化策略的性能均值和标准差，该性能由给定情景下的 100 次测试试验的平均值来表征。尽管没有测试环境样本，RMA 的表现最佳，最接近专家的表现。作为参考，A1 机器人不带额外负载时重 12 kg，高 0.35 m。橡胶与混凝土之间的静摩擦系数为 1.00 。