SRMA 最终方案

> 状态：方案定稿，尚未实现。
>
> 日期：2026-10-18。
>
> 目标文件：`src/mjlab/tasks/srma/doc/最终方案.md`。

0. 一句话概括

SRMA 借鉴 RMA 的“特权教师 + 在线适应学生”思路改造 DreamWaQ：第一阶段让 actor 使用真实速度和由局部地形、摩擦、上一时刻外力编码出的 16 维外部 latent 学出强策略； 第二阶段冻结教师，用学生自己的 on-policy 轨迹做 DAgger，让学生仅凭可部署的本体历史 同时估计速度与外部 latent，并训练新的学生 actor。学生不使用 CENet 的 VAE 重建目标， 不直接使用足端接触、滞空时间、高度图或摩擦。

1. 动机与目标

DreamWaQ 原有 CENet 通过重建下一帧本体观测学习 16 维 latent。已有实验表明：

- 速度和任务跟踪可以学到，但 latent 更容易编码步态相位、身体状态等快变量；
- 仅用 t-SNE 是否按地形聚类来评价 latent 不够，且不能证明 latent 对控制有用；
- 环境随机的摩擦、地形等外部因素才是希望被快速适应的主要对象。

RMA 的关键启发是：不需要重建完整环境或估计真实物理参数，而是先学习一个能改善控制 的低维特权 latent，再蒸馏成只依赖历史的在线估计。

本方案的目标是：

1. 用仿真特权信息训练一个对控制直接有用的 16 维外部环境 latent；
2. 用 50 帧本体历史的学生网络在线估计速度和外部 latent；
3. 用 DAgger 蒸馏出新 actor，而不是直接冻结教师 actor 后硬切换输入；
4. 部署时完全不依赖高度图、摩擦、真实速度或外力。

2. 核心口径

项目	最终决定
机器人/环境	先基于 Go1 rough velocity 任务实现
教师外部信息	身体下方局部高度图、足底摩擦、上一时刻外力
教师 actor 输入	`[o_t(45), v_gt(3), l_teacher(16)]`，共 64 维
学生 actor 输入	`[o_t(45), v_hat(3), l_hat(16)]`，共 64 维
学生历史	50 个控制帧，50 Hz 下约 1 秒
学生时序模型	固定 50 帧窗口的单层 GRU
外部 latent	16 维，经过 LayerNorm
第二阶段	学生估计器预训练 + DAgger 训练新 actor

项目	最终决定
部署	只运行 50 帧 GRU 和学生 actor，与 50 Hz actor 同步
已删除信息	VAE 解码器、下一帧观测重建、contact、air time、足端高度

这里不把四足接触状态和滞空时间放入教师或学生输入。硬件部署时无法稳定获得这些信号， 并且它们变化快，放入外部 latent 容易重新引入步态相位。

3. 符号

- `o_t`：45 维可部署本体观测，沿用 DreamWaQ actor 观测： 角速度、投影重力、关节位置、关节速度、上一动作、速度指令。
- `v_t`：仿真真值基座线速度，3 维。
- `H_t`：机身下方的局部地形高度图。
- `f`：足底摩擦参数，3 维。
- `d_{t-1}`：上一控制步施加的外力/速度冲击，机身系 6 维。
- `l_t`：教师外部编码器输出的 16 维 latent。
- `v_hat_t, l_hat_t`：学生从 50 帧本体历史估计出的速度和外部 latent。
- `pi_T`：第一阶段特权教师 actor。
- `pi_S`：第二阶段新训练的学生 actor。

4. 教师外部信息

4.1 局部地形高度图

地形图覆盖机身下方的小范围区域，不覆盖完整周围环境，也不只限制在当前接触脚附近。

初始网格：

```
x: -0.25 ~ +0.25 m
y: -0.20 ~ +0.20 m
分辨率: 0.05 m
网格: 11 x 9
高度值数量: 99
```

坐标口径：

- 水平网格以机身中心为原点；
- 只按 yaw 对齐，不随机身 pitch/roll 旋转；
- 高度沿世界竖直方向采样；
- 不使用世界绝对位置或绝对高度作为网络输入。

垂直归一化参考使用支撑脚高度的中位数，而不是机身中心高度：

```
z_ref = median(world_z of contact feet)
h_norm(i, j) = clip((h_world(i, j) - z_ref) / 0.15, -3.0, 3.0)
```

理由：

- 水平坐标已经以机身为中心，空间关系是自车相对的；
- 垂直方向减去支撑高度可以去掉机身起伏，使 latent 更关注地形本身；
- 相对机身中心会把身体上下运动、pitch/roll 等状态混入高度图，容易再次编码相位和躯体状态。

边界条件：

- 至少一只脚接触时，取接触脚高度中位数；
- 四脚腾空时，沿用上一控制步的 `z_ref`；
- 不建议拟合倾斜平面，因为双脚踩在不同高度台阶时会产生错误倾斜；
- 若 `z_ref` 在触地切换时跳变明显，可加入轻微低通，但训练和部署标签口径必须一致；
- 无效或未命中单元格使用 0 和可选 mask，具体在实现时二选一，不能混用。

4.2 足底摩擦

当前 Go1 环境对全部足底 geom 共享摩擦随机化，使用 3 个轴：

```
mu_slide
mu_spin
mu_roll
```

由于 spin/roll 跨多个数量级，编码前使用对数：

```
f = [
  log(mu_slide),
  log(mu_spin),
  log(mu_roll),
]
```

再做固定范围裁剪或 running normalization。摩擦只在教师外部编码器中使用，学生通过本体 响应估计它。

4.3 上一时刻外力

使用现有的 push 记录，时间索引明确为 `d_{t-1}`：

```
d_{t-1} = [
  delta_vx, delta_vy, delta_vz,
  delta_wx, delta_wy, delta_wz,
]
```

该量位于机身系。只使用上一时刻而不是当前时刻，避免教师获得学生不可能及时获得的 前馈信息。

4.4 明确排除的信息

以下信息不进入教师外部编码器，也不进入学生 actor：

- 四足 contact；
- foot air time；
- 足端 clearance；
- 周围完整高度图；
- 全局位置、全局地形坐标；
- 地形类别 one-hot；
- payload、质心、电机强度。它们继续由域随机化覆盖，首版不做显式适应；
- 当前时刻外力。

地形类别可以在实验分析中作为标签，但不能作为控制训练目标。

5. 第一阶段：特权教师

5.1 数据流

```
局部高度图(11 x 9)
        |
       CNN ----\
                +--> 外部编码器 --> l_teacher(16) --> LayerNorm
摩擦(3) --------/
外力(6) --------/

[o_t(45), v_gt(3), l_teacher(16)]
        |
   教师 actor
   64 -> 512 -> 256 -> 128 -> 12
        |
       a_t
```

5.2 外部编码器结构

建议初始结构：

```
height map 1 x 11 x 9
  -> Conv2d(1, 16, kernel=3, padding=1) + ELU
  -> Conv2d(16, 32, kernel=3, stride=2, padding=1) + ELU
  -> Flatten
  -> Linear(64)

[friction(3), prev_push(6)]
  -> Linear(32) + ELU

concat(height_feature(64), vector_feature(32))
  -> Linear(64) + ELU
  -> Linear(16)
  -> LayerNorm(16)
```

外部编码器是教师 actor 的子模块，和 actor 共用第一阶段的 PPO 优化器。

5.3 `l_teacher` 的语义

`l_teacher` 不要求还原高度图、摩擦或外力，也不要求按地形类别聚类。它只要求成为对 教师控制有用的低维条件向量。加入 LayerNorm 的目的是稳定教师与学生 latent 的尺度， 避免直接 MSE 被任意尺度和少数维度主导。

第一版不额外加入重建损失。外部编码器只接收 PPO 梯度，这保留了 RMA 中“latent 从 控制目标中出现”的思想。

5.4 PPO 配置

首版沿用当前 HIM/mjlab 的稳定训练口径，并保持与既有 Go1 rough 实验可比：

```
seed: 42
num_envs: 4096
num_steps_per_env: 24
max_iterations: 3000
num_learning_epochs: 5
num_mini_batches: 4
learning_rate: 1e-3
schedule: adaptive
desired_kl: 0.01
gamma: 0.99
lam: 0.95
clip_param: 0.2
entropy_coef: 0.01
max_grad_norm: 1.0
```

训练预算为初始值。若最近 300-500 轮内回报、地形课程和跟踪指标均无实质提升，可提前 停止教师训练。

5.5 第一阶段必须通过的检查

第一阶段不是只看总回报。至少检查：

1. 教师策略是否达到或超过当前 DreamWaQ/velocity 基线的运动质量；
2. `teacher no external`、`teacher map`、`teacher map + friction`、`teacher map + friction + force` 的差异；
3. latent 各维是否有有效变化，不能全部塌缩到常数；
4. 将 `l_teacher` 置零或打乱后，教师动作和成功率是否明显下降；
5. 在相同地形等级和固定指令下比较，避免课程进度混淆。

如果外部信息教师没有优于无外部信息教师，应停止第二阶段，先检查外部信息或奖励设计， 不能把学生蒸馏当作补救手段。

6. 第二阶段学生估计器

6.1 输入

学生估计器只使用部署可获得的 45 维本体观测：

```
o_{t-49}, ..., o_t
```

不输入 contact、air time、足端高度、高度图、摩擦或外力。

历史顺序统一为旧到新。50 Hz 下 50 帧覆盖约 1 秒。episode 开始前不足 50 帧时，用该 episode 的第一帧左填充，禁止跨 episode 拼接。

6.2 网络

```
每帧 o_t(45)
  -> Linear(64) + ELU
50 帧
  -> GRU(hidden=64)
  -> 最后一步 hidden
       |-> Linear(3)  -> v_hat
       |-> Linear(16) -> LayerNorm(16) -> l_hat
```

初始默认：

```
history_length = 50
frame_dim = 45
hidden_dim = 64
latent_dim = 16
history_order = oldest_first
```

GRU hidden 128 作为后续消融。第一版使用固定窗口，不在 PPO 中维护 recurrent hidden state；这样每一步都能代表性地同步前向，训练和部署口径一致。

6.3 观测归一化

- 45 维 actor 观测量沿用 running `EmpiricalNormalization`；
- 50 帧共享同一组 45 维统计量；
- 教师 `l_teacher` 和学生 `l_hat` 都经过 LayerNorm；
- 速度回归使用原始单位，指标保持 m/s。

7. 学生 actor

学生 actor 与教师 actor 完全同构：

```
[o_t(45), v_hat(3), l_hat(16)]
-> 512 -> 256 -> 128 -> 12
```

学生 actor 从教师 actor 权重初始化。DAgger 阶段只监督动作均值，不要求匹配教师动作 标准差。部署时使用确定性动作均值。

8. 第二阶段训练协议

8.1 冻结范围

第二阶段冻结：

- 教师 actor `pi_T`；
- 教师外部编码器 `Enc_e`；
- 教师 latent 的 LayerNorm。

只更新：

- 学生 GRU；
- 学生 `v_hat` 和 `l_hat` 输出头；
- 学生 actor `pi_S`。

8.2 阶段 2A：学生估计器预训练

先运行教师策略 30-50 轮，用教师的真值速度和 latent 预训练学生 GRU：

```
L_pretrain = L_v + L_l
```

每轮规模：

```
4096 envs x 24 steps = 98,304 transitions
```

目的：

- 让学生在 actor 蒸馏开始前具备基本可用的 `v_hat/l_hat`；
- 避免 DAgger 前几十轮主要在学习随机估计器噪声；
- 给新 actor 一个接近教师输入分布的初始环境。

8.3 阶段 2B：DAgger

每轮流程：

1. 用当前学生 actor 和 GRU 收集 on-policy 轨迹；
2. 在学生访问到的每个状态上，用冻结教师计算 `l_teacher = Enc_e(e_t)` 和 `a_teacher = pi_T(o_t, v_gt, l_teacher)`；
3. 教师标签和训练观测使用同一个 `o_t`，教师额外获得真值速度和外部 latent；
4. 更新学生 GRU 和学生 actor；
5. 重复，逐步提高学生自身状态占比。

教师动作使用动作均值作为目标，不能使用教师 rollout 中随机采样的单个动作。

8.4 数据配比

以环境实例为单位混合教师和学生动作，不在一条 episode 内随机切换：

DAgger 轮次	教师动作轨迹	学生动作轨迹
1-20	50%	50%
21-50	25%	75%
51-150	0%	100%

无论轨迹由教师还是学生产生，状态都由教师重新打动作和 latent 标签。

8.5 损失函数

先对速度和动作误差做尺度归一化，使三个损失处于可比量级：

```
sigma_v = running_std(v_gt), clamp_min=0.1
sigma_a = running_std(a_teacher), clamp_min=0.05

L_v = mean(((v_hat - v_gt) / sigma_v)^2)
L_l = mean((l_hat - l_teacher)^2)
L_a = mean(((mean(pi_S) - mean(pi_T)) / sigma_a)^2)

L = L_v + lambda_l * L_l + lambda_a * L_a
```

初始值：

```
lambda_l = 1.0
lambda_a = 1.0
```

教师 latent 和教师动作都使用 stop-gradient。

8.6 优化设置

初始建议：

```
optimizer: Adam
learning_rate: 5e-4
learning_epochs_per_round: 4
num_mini_batches: 4
max_grad_norm: 1.0
max_dagger_rounds: 150
```

每轮 98,304 条 transition。支持根据验证集动作误差、latent 误差和固定地形成功率提前 停止。

8.7 是否加入 PPO

第一版保持纯 DAgger，不同时做 PPO。若满足以下任一条件，再增加 100-300 轮小学习率 PPO 微调作为独立消融：

- actor 动作误差已经较低，但闭环成功率仍明显低于教师；
- 学生估计器误差稳定，但策略对估计噪声过于敏感；
- 纯 DAgger 在分布外地形上明显退化。

PPO 微调阶段冻结教师外部编码器，建议学习率 `1e-4` 到 `3e-4`。

9. 部署接口

部署时只保留：

```
50 帧 x 45 维本体历史
        |
       GRU
        |
[v_hat(3), l_hat(16)]
        |
学生 actor
        |
12 维期望关节角
```

不运行教师 actor、外部编码器、高度图 raycast、friction lookup 或外力记录。

运行频率：

```
GRU 与学生 actor: 50 Hz，同步
输入历史长度: 50
覆盖时间: 约 1.0 s
```

50 帧固定窗口在部署端只需要约 `50 x 45 x 4 = 9 KB` 的 float32 ring buffer。

本机 CPU 微基准中，50 帧单层 GRU 加 actor 的 batch=1 推理约 0.47 ms。实际机器人 性能仍需在目标板载计算上测量，控制周期预算为 20 ms。

10. 训练数据与存储

不能为每个 transition 重复保存完整 50 帧窗口。

如果直接按当前 observation-history 方式存储：

```
50 x 45 x 4096 envs x 24 steps x 4 bytes
≈ 844 MiB / 份
```

这还没有计算其他观测、advantage、动作和临时张量。实现时必须采用以下方案之一：

1. 每个 env 保存单帧 ring buffer，按 rollout 时间索引现场生成 50 帧窗口；
2. storage 只保存单帧和窗口起止索引，minibatch 前物化窗口；
3. 若要进一步压缩训练成本，再实现 stateful GRU 和 hidden-state replay。

第一版优先方案 1 或 2，部署和训练都应保持固定 50 帧、旧到新的顺序。

11. 建议代码结构

实现时可以新建以下模块，最终命名以实际代码为准：

```
src/mjlab/tasks/srma/
  srma_env_cfg.py
  config/go1/env_cfg.py
  config/go1/rl_cfg.py
  rl/network/external_encoder.py
  rl/network/student_estimator.py
  rl/network/actor.py
  rl/algorithm/srma_teacher_ppo.py
  rl/algorithm/srma_dagger.py
  rl/runner.py
```

第一阶段和第二阶段的 checkpoint 必须分开保存：

```
teacher.pt
  actor_state_dict
  external_encoder_state_dict
  latent_normalizer_state_dict

student.pt
  actor_state_dict
  student_estimator_state_dict
```

教师外部编码器不进入最终 ONNX。最终 ONNX 输入是 50 帧本体历史，输出是 12 维动作。

12. 观测组设计

建议新增的教师专用观测组：

```
teacher_height_map       (B, 11, 9) 或展平 (B, 99)
teacher_friction         (B, 3)
teacher_prev_push        (B, 6)
teacher_velocity_gt      (B, 3)
```

学生训练/部署使用：

```
student_history          (B, 50, 45)
```

`teacher_height_map` 的归一化需要当前接触脚高度中位数，但 contact 本身不会进入任何 actor 输入，只用于仿真侧构造教师特权信息。

13. 评测矩阵

13.1 教师消融

臂	外部输入
T0	无外部信息，只使用 `v_gt`
T1	`v_gt + local height map`
T2	`v_gt + local height map + friction`
T3	`v_gt + local height map + friction + prev push`

目的：确认每类特权信息是否真的改善教师控制和鲁棒性。

13.2 学生消融

臂	说明
S0	原 DreamWaQ β=0.04
S1	学生速度估计 + DAgger，但 `l_hat` 置零或不输入
S2	学生完整 `v_hat + l_hat`
S3	使用教师 `v_gt + l_teacher` 的教师上界

如果需要，再增加：

- 学生 GRU hidden 64 vs 128；
- history 25 vs 50；
- 有 friction vs 无 friction；
- 纯 DAgger vs DAgger + 少量 PPO。

13.3 固定评测

训练曲线只用于过程监控，结论必须来自固定口径评测：

- 固定地形等级 3 和 5；
- 固定命令序列和扰动 seed；
- 相同 teacher、student、DreamWaQ 初始化；
- push 1x-4x；
- 摩擦、台阶高度、局部高度图的训练内和训练外范围；
- 至少 2-3 个训练 seed，条件允许时优先 3 个。

13.4 指标

策略指标：

- reward；
- episode length；
- illegal contact / falls；
- terrain level；
- linear/angular tracking error；
- peak joint velocity；
- 固定扰动下的 survival。

估计指标：

- `Metrics/velocity_est_error`，单位 m/s；
- `MSE(l_hat, l_teacher)`；
- 可选 cosine similarity；
- 学生与教师动作均值的闭环误差。

latent 指标：

- 每维 running std 和有效 rank；
- teacher latent 置零、打乱、替换成其他环境 latent 后的动作变化；
- 学生 latent 与教师 latent 在固定状态上的差异；
- t-SNE 只做可视化，不作为主要结论。

一个有用的行为测试是：

```
同一 o_t、同一 v，
分别输入 teacher l、student l_hat、零 latent，
比较 actor 输出动作和后续闭环表现。
```

这比单纯检查 latent 是否按地形聚类更接近“latent 是否被策略使用”。

14. 风险与回退方案

14.1 教师依赖未接触地形

局部高度图包含摆动脚尚未接触的区域。教师可能有轻微提前预判，学生只能通过历史事后 适应。

应对：

- 比较 `teacher no map` 和 `teacher map`；
- 若学生始终落后，限制高度图只保留机身中心附近，或降低前向覆盖；
- 不把完整周围地图加入首版。

14.2 摩擦或高度 latent 不可辨识

学生可能只能学习环境分布的平均值。

应对：

- 延长 GRU 历史到 75/100 帧做消融；
- 在训练中增加包含明显打滑或台阶响应的课程；

- 检查学生 latent 是否是常数，而不是只看动作最终是否可走。

14.3 latent 塌缩

如果 `l_teacher` 被 actor 忽略，PPO 可能学出接近常数的 latent。

应对：

- 监控每维 std 和有效 rank；
- 做 `l = 0`、shuffle latent 的教师动作敏感性测试；
- 必要时加入轻微 variance/covariance 正则，但不加入完整重建损失。

14.4 DAgger actor 过拟合

如果学生只模仿当前轨迹，闭环后仍可能偏离。

应对：

- 保持 on-policy 重新收集；
- 逐步提高学生轨迹比例；
- 增加教师坏状态和恢复状态；
- 最后才考虑 PPO 微调。

14.5 GRU 训练成本过高

固定 50 帧窗口可能使训练存储和吞吐变差。

应对：

- 使用 ring buffer，不重复保存窗口；
- 先测试 25 帧，再扩到 50 帧；
- 如仍不可接受，再实现 stateful GRU + hidden-state replay。

15. 成功判据

首版实现完成后，至少满足：

1. 教师 T3 在固定评测中不弱于无外部信息的 T0，且在至少一个外部扰动维度上更强；
2. 学生 50 帧 GRU 能稳定估计速度，速度误差接近原 DreamWaQ CENet 的量级；
3. 学生 DAgger 后的闭环 reward、生存率和跟踪误差接近教师；
4. 学生 latent 不是常数，置零或替换后动作和闭环性能会下降；
5. 学生部署接口只依赖 45 维本体历史；
6. 固定扰动下学生不弱于 DreamWaQ，且至少在摩擦、台阶或外力中的一类分布外条件上更好。

如果学生性能接近教师但没有任何外部信息敏感性，说明蒸馏只学到了速度和普通步态， 不能宣称学会了外部环境 latent。